



博士研究生综合考试报告

题目： 云计算环境下的人工智能相关
技术研究

姓 名： 李炎

学 号： 2001111305

院 系： 信息科学技术学院

专 业： 计算机软件与理论

研究方向： 云计算与普适计算

导 师： 梅宏

二〇二一年五月

摘要

21世纪10年代以来，云计算和人工智能可谓计算机科学领域最为炙手可热的两个研究方向。以虚拟化、资源管理和服务化为代表的云计算核心技术在近十余年里取得了丰硕的研究成果。当前，云计算已成为工业化社会重要的信息基础设施，支撑并推动着大数据和人工智能产业的快速发展。与此同时，人工智能技术在近十年内也相继在计算机视觉、自然语言处理等多个领域取得了突破，“智能化”已然成为现代社会的重要标签之一。

本文将以上述两大领域的蓬勃发展为背景，研究云计算与人工智能相互影响、相互支持、相辅相成的相关技术。本文将按照如下几章展开。

第一章对相关的技术背景做出介绍。首先对云计算近十年的发展做简要回顾，并介绍具有代表性的若干核心技术。其次简要概述人工智能的发展历史，及其近十年在计算机视觉、自然语言处理等领域的代表性成果。最后分析二者在交叉领域现有的相关研究。

第二章开始探究二者的关系，研究云计算环境中用以支持人工智能的系统软件技术。随着人工智能算法和系统研究的发展，其训练-测试-部署的流程愈发复杂。主流的公有云厂商基于本地化的云原生技术，构建了一站式的机器学习模型开发-部署软件栈供用户使用。然而云厂商提供的大而全的一站式机器学习系统很难覆盖所有的应用场景。在一些成本敏感的、性能敏感的应用场景中，部分学者也在尝试利用公有云提供的服务搭建第三方的机器学习系统，以实现特异性的需求。同时，随着以 Serverless Computing 为代表的新兴云计算模式的出现，部分研究者也在探索如何将其应用在机器学习系统的构建上，使机器学习应用在云上具有更高的弹性。

第三章讨论云环境中的新硬件（如 GPU, AI 专用芯片, Intel SGX 等）为人工智能技术带来的新的机遇与挑战。以 GPU 为代表的加速型硬件的发展导致的算力的提升，也是人工智能近年发展迅速的重要原因之一。如何使机器学习任务在这类加速硬件上更快的运行，并提升集群的资源利用率，是学术界关注的重要问题。同时，以 Intel SGX 为代表的可信执行环境技术的兴起和发展，为增强人工智能应用的安全性提供了新的解决方案。

第四章从另一角度，即“服务于云计算系统架构的 AI 技术”这一视角展开，研究人工智能对云计算的增强技术。云计算本质上是一个巨大的公共资源池，用户如何在资源池中选取资源，云厂商如何为不同用户的任务调度资源，是云计算领域的两个重要话题。近五年来，部分研究者开始尝试利用一系列基于机器学习的算法来辅助解决

上述两个问题。

第五章总结了上述三个方向的重要文献和相关研究团队概况。

第六章介绍了作者下一步的研究计划。

关键词：云计算，人工智能，机器学习，异构硬件

目录

第一章 引言	1
1.1 云计算的基本概念	1
1.1.1 云计算的传统服务模型	1
1.1.2 云计算的新兴服务模型	2
1.2 人工智能技术发展简介	3
1.2.1 1980s: 登上历史舞台	4
1.2.2 1990-2012: 走向成熟和应用	4
1.2.3 2012 之后: 深度学习时代来临	5
1.3 云计算和人工智能交叉领域的常见研究问题	6
1.3.1 云上的机器学习系统	6
1.3.2 新硬件对人工智能的影响	7
1.3.3 利用机器学习算法解决云计算中的资源配置与调度问题	8
第二章 面向人工智能的云计算软件系统研究	9
2.1 分布式机器学习系统的两种架构范式	9
2.1.1 数据并行架构	9
2.1.2 模型并行架构	12
2.2 公有云厂商提供的云上机器学习系统	12
2.2.1 AWS Sagemaker	13
2.3 基于公有云服务的第三方机器学习系统	17
2.3.1 基于云厂商动态资源的机器学习模型训练系统	17
2.3.2 基于 FaaS 的模型训练系统	26
2.3.3 基于公有云服务的模型部署系统	32
2.3.4 基于 FaaS 的模型部署系统	34
2.4 小结	37
第三章 云环境中的新硬件为人工智能带来的机遇与挑战	39
3.1 云环境中机器学习作业对 GPU 的利用	39
3.1.1 GPU 简介	39
3.1.2 One Job on Multi GPUs: 机器学习集群中的 GPU 调度算法	41
3.1.3 Multi Jobs on one GPU: 机器学习集群中的 GPU 共享机制	44

3.2 可信执行环境技术的发展对机器学习任务的影响	48
3.2.1 SGX 技术简介	49
3.2.2 基于 SGX 技术的上层应用	51
3.2.3 集群中 SGX 资源的管理	52
3.2.4 在机器学习任务中应用 SGX 技术	55
3.3 小结	57
第四章 人工智能对云计算的增强技术研究	59
4.1 基于机器学习算法的云资源配置优化技术	59
4.1.1 数据驱动的线下建模方法	60
4.1.2 基于搜索的线上优化方法	64
4.2 基于机器学习算法的云资源调度优化技术	65
4.3 小结	67
第五章 重要文献与研究团队总结	69
5.1 重要文献总结	69
5.2 重要研究团队总结	71
第六章 下一步的研究设想	73
6.1 研究动机	73
6.1.1 基于 FaaS 的模型部署系统现状	73
6.1.2 基于 SGX 的模型部署系统现状	73
6.2 研究计划	74
6.2.1 SLO 可感知的 Serverless 机器学习模型部署系统	74
6.2.2 SGX 环境下机器学习模型部署干扰及调度策略研究	74
参考文献	75

第一章 引言

1.1 云计算的基本概念

云计算（Cloud Computing），根据美国国家标准技术研究所（NIST）的定义，指的是一种可以实现对可配置计算资源共享池（如网络、服务器、存储、应用和服务）进行随时随地、便捷、按需网络访问的模型。这些资源可以迅速地配分配和释放，并且这个过程只需要最低限度的资源管理工作以及与服务提供商最少的交互。美国亚马逊公司再 2006 年 3 月推出了 Amazon Web Service（AWS）[1]，这一事件一般被认为代表着云计算时代的正式开启。经过十几年的发展，凭借着“方便易用、弹性伸缩、按需服务”的技术特征，云计算概念已被广泛接受，云计算产业取得了商业上的巨大成功，云计算平台已成为当今社会的关键信息基础设施，云计算技术为大数据、人工智能的领域的蓬勃发展提供了重要的支撑作用。

1.1.1 云计算的传统服务模型

NIST 将云计算分为了三种服务模型。

这三种服务模型分别是基础设施即服务（Infrastructure as a Service, IaaS）、平台即服务（Platform as a Service, PaaS）以及软件即服务（Software as a Service, SaaS）[2]。IaaS 为消费者提供用来运行应用的计算资源，包括服务器、存储、网络等。其中虚拟机是云厂商提供的最核心的 IaaS 产品。与 IaaS 只提供最基础的底层资源不同，PaaS 强调为消费者提供云开发环境，除计算资源以外，PaaS 为用户提供中间件开发，运行平台及工具，帮助用户更方便地开、管理、测试和运行应用。SaaS 是厂商提供的基于云的软件，用户无需下载安装软件，通过浏览器即可访问服务。

图1.1给出了云计算三种服务模型的代表产品。亚马逊公司的 AWS EC2[3]，谷歌公司的 Google Compute Engine[4] 以及阿里云公司的 ECS[5] 都是典型的 IaaS 产品。其主要服务形态是云厂商向消费者售卖虚拟机或者裸金属服务器以及连带的网络、存储等附属产品。PaaS 的代表性产品包括 AWS Beanstalk、Google App Engine、Microsoft Azure App Services 等。此类产品为用户提供在云中快速部署和管理应用的能力，提供包括应用扩容，负载均衡，应用监控和安全管理等功能。相比于 IaaS 仅售卖以虚拟机为主的基础设施，PaaS 降低了用户开发、管理、运维应用的成本，使得用户可以更加专注于构建应用本身。在云计算已经发展了十几年的当今时代，越来越多的 SaaS 产品涌现了出来。谷歌公司开发的 Google Docs、Google Maps 以及微软公司开发的 Microsoft Office

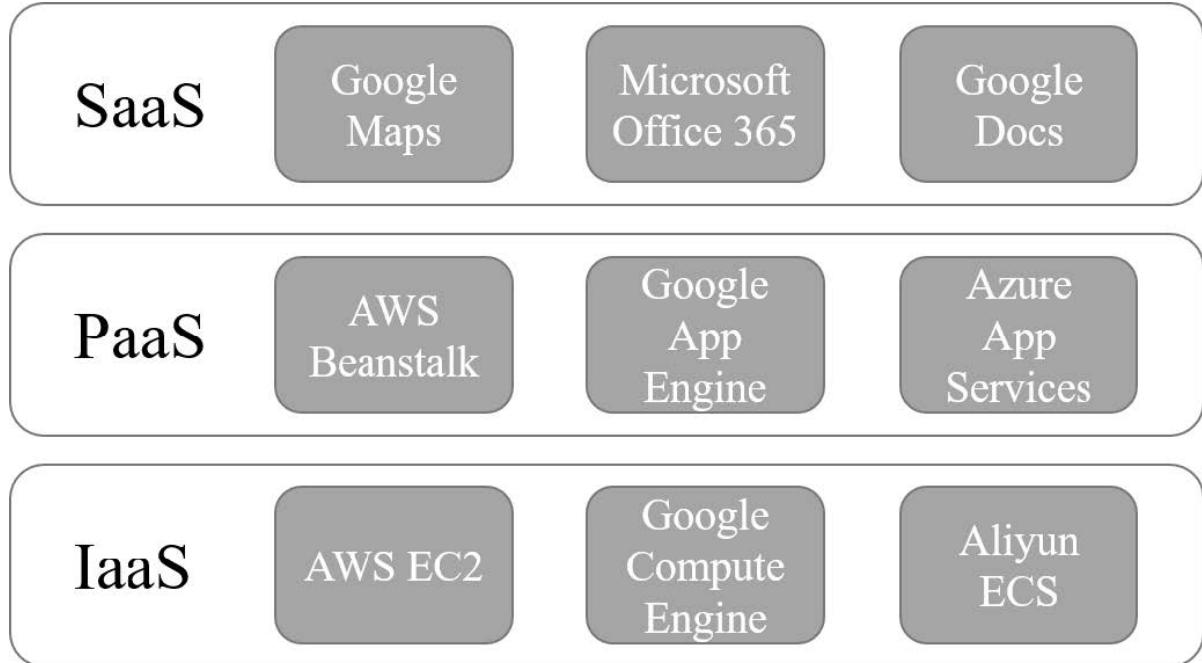


图 1.1 云计算服务模型代表产品

365 都是典型的 SaaS 产品。以 Google Docs 为例，与传统的文件处理办公软件相比，用户无需在本地花费大量存储空间来安装软件，只需要打开浏览器，输入 URL，即可使用 Google Docs 服务处理文件，并且所有的文件都会被及时同步保存到云端。另一个代表性的 SaaS 产品是 Google Maps。Google Maps 与 Google Docs 类似，为个人用户提供在浏览器中直接使用的地图服务。与传统软件相比，SaaS 在使用方式上具有方便灵活，跨平台的特性，同时用户存储在云端的数据经过云厂商的冗余备份也具有更高的可靠性。

1.1.2 云计算的新兴服务模型

云计算发展至今日，其服务模型已经不严格局限于 NIST 最初总结的这三种基本形态，世界各地各领域的研究者们已经提出了众多不同的 X as a Service，包括 Blockchain as a Service[6]，Sensing as a Service[7]，Workspace as a Service[8] 等。与传统的三种服务形态相比，这些服务不单纯是硬件服务或者软件服务，其结合二者的特点，面向特定的领域方向进行更深度的定制，如区块链、物联网、分布式共识等。服务形态的日益丰富，服务内容的日益复杂体现了云计算更见领域化，精细化的发展趋势。而近几年来最热门的概念莫过于 FaaS，即 Function as a Service[9]。

FaaS 是一种新兴的计算模式，亦被称为 Serverless Computing。从字面理解，Serverless Computing 即为“无服务器计算”之意。然后，其并非意味着真的没有服务器，而已说开发者不用过多考虑服务器的相关问题。在传统的 IaaS 服务中，开发者需要自己

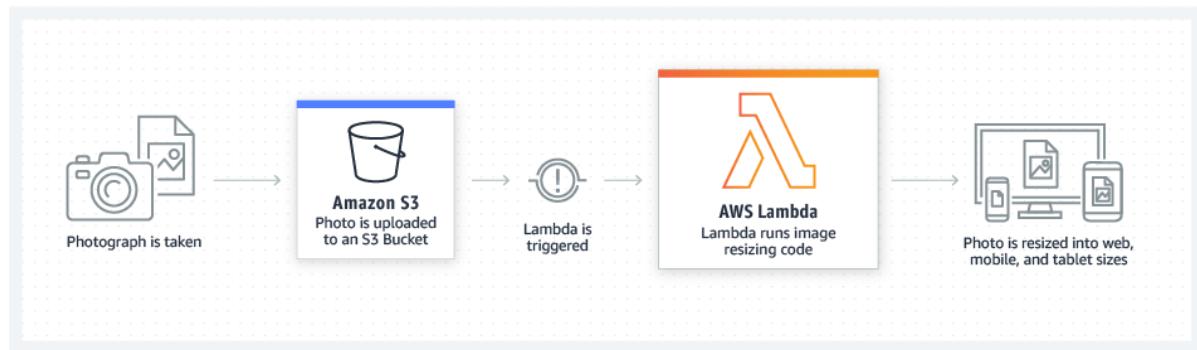


图 1.2 AWS Lambda 中示例程序：照片大小调整

惊醒服务器管理与运维，负责服务的发布，在流量变化时对服务器集群进行扩容或缩容。而在 FaaS 中，开发者只需要关注业务逻辑，至于服务的发布、管理、弹性伸缩等，则交由云厂商来完成。

FaaS 背后的机制一般是以容器技术为基础的。典型地，开发者上传自己的业务代码后，云厂商并不会直接收费。当对该服务的请求到来之时，云厂商将启动一系列容器来运行该服务，从而对用户的请求进行响应。通常而言，开发者指定的服务会与某些时间绑定（hook），在发生该事件时，立即触发开发者定义的服务。我们以 AWS 的 serverless computing 服务 Lambda[10] 中的一个示例程序为例，讲述整个流程。图1.2所示的是一个为照片调整大小的服务。该服务与 AWS S3（AWS 的对象存储服务）的上传事件绑定，当云厂商检测到有用户向 S3 上传图片时，会立即触发开发者定义的图片大小调整函数。整个流程中，开发者需要关注的只有第四步的函数开发工作，至于该函数的横向拓展，全部由云厂商来负责。

主流的云厂商均提供了 FaaS 服务，例如 AWS 的 Lambda，阿里云的函数计算等，近年来越来越受到开发者的青睐。一方面是因为它的高弹性，易于开发。另一方面则是因为其细粒度的收费模式。通常而言，FaaS 的服务是按照请求次数进行收费。当函数闲置时，并不产生额外的费用。

1.2 人工智能技术发展简介

人工智能是一个范围很广的概念，广义上的人工智能泛指通过计算机（机器）来实现人的头脑思维，使得机器像人一样做出决策。机器学习是实现人工智能的一种技术途径。一般可以认为人工智能的发展和机器学习技术的进步是同步的，因此，这两个概念大多数场景下会出现在同一个语境中。根据机器学习的发展史，即可勾勒出人工智能领域的发展轨迹，因此本节将简介机器学习技术的发展简史。

虽然机器学习这一名词以及其中某些零碎的方法可以追溯到 1958[11] 年甚至更早，

但真正作为一门独立的学科要从 1980 年算起，在这一年诞生了第一届机器学习的学术会议和期刊。到目前为止，机器学习的发展经历了 3 个阶段：1980 年代是正式成形期，尚不具备影响力。1990-2010 年代是蓬勃发展期，诞生了众多的理论和算法，真正走向了实用。2012 年之后是深度学习时期，深度学习技术诞生并急速发展，较好的解决了现阶段 AI 的一些重点问题，并带来了产业界的快速发展。

1.2.1 1980s：登上历史舞台

十九世纪八十年代，机器学习作为一股独立的力量开始登上历史舞台。此后的十年内，出现了一些重要的方法和理论，典型的代表是：分类与回归树 [12]、反向传播算法 [13] 和卷积神经网络 [14]。

分类与回归树。分类与回归树由 L. Breiman 等人在 1984 年提出，是决策树的一种经典实现，至今它还在很多领域里被使用。决策树是一种基于规则的方法，它由一系列嵌套的规则组成一棵树，完成判断和决策。和之前基于人工规则的方法不同，这里的规则是通过训练得到的，而不是人工总结出来的。

反向传播算法。人工神经网络是对动物神经系统的一种简单模拟，属于仿生方法。从数学的角度看，它是一个多层的复合函数。反向传播算法是神经网络训练时使用的算法，来自于微积分中复合函数求导的链式法则，至今深度学习中各种神经网络的训练使用的还是这种方法。反向传播算法的出现使得多层神经网络真正成为一种可以实现、具有实用价值的算法。在这一时期，神经网络的理论性研究也是热门的问题，神经网络数学上的表达能力的分析和证明大多出现在 1980 年代末和 1990 年代初。

从理论上来说，加大神经网络的规模可以解决更复杂的模式识别等问题。但是网络层数的增加会导致梯度消失问题，另外神经网络还面临着局部最优解的问题。训练样本的缺乏，计算能力的限制，都使得神经网络在接下来的 20 多年里没有太大的进展和出色的表现。

卷积神经网络。早在 1989 年，Y. LeCun 在贝尔实验室就开始使用卷积神经网络识别手写数字 [14]，这是当前深度学习中深度卷积神经网络的鼻祖；1998 年，LeCun 提出了用于字符识别的卷积神经网络 LeNet5，并在手写数字识别中取得了较好的结果。卷积神经网络借鉴了动物视觉神经系统的原理，它能够逐层的对输入图像进行抽象和理解。

1.2.2 1990-2012：走向成熟和应用

在这一阶段的 20 余年里，机器学习的理论和方法得到了完善和充实，代表性的工作包括：支持向量机（SVM）[15]、AdaBoost 算法 [16]、循环神经网络（RNN）和长短

时记忆网路（LSTM）[17]、流形学习[18]以及随机森林[19]。

SVM。SVM 基于最大化分类间隔的原则，通过核函数巧妙的将线性不可分问题转化成线性可分问题，并且具有非常好的泛化性能。和神经网络相比，SVM 有完善的数学理论作为支撑，训练时求解的问题是凸优化问题，因此不会出现局部极值问题。

AdaBoost。AdaBoost 和随机森林同属集成学习算法，它们通过将多个弱学习器模型整合可以得到精度非常高的强学习器模型，且计算量非常小。AdaBoost 算法在机器视觉领域的目标检测问题上取得了成功，典型的代表是人脸检测问题。2001 年，使用级联 AdaBoost 分类器和 Haar 特征的算法在人脸检测问题上取得了巨大的进步，是有里程碑意义的成果。此后这一框架成为目标检测的主流方法，直到后来被深度学习取代。

循环神经网络。循环神经网络作为标准前馈型神经网络的发展，具有记忆功能，在语音识别、自然语言处理等序列问题的建模上取得了成功，是当前很多深度学习算法的基础。

流形学习。流形学习作为一种非线性降维技术，直观来看，它假设向量在高维空间中的分布具有一定的几何形状。在 2000 年出现之后的一段时间内名噪一时，呈现出一片繁荣的景象，但在实际应用方面缺乏成功的建树。

随机森林。随机森林由 Breiman 等人在 2001 年提出，是多棵决策树的集成，在训练时通过对样本进行随机抽样构造出新的数据集训练每一棵决策树。它实现简单，可解释性强，运算量小，在很多实际问题上取得了相当高的精度。时至今日，在很多数据挖掘和分析的比赛中，这类算法还经常成为冠军。

在这一时期机器学习算法真正走向了实际应用。典型的代表是车牌识别，印刷文字、(OCR)，手写文字识别，人脸检测技术（数码相机中用于人脸对焦），搜索引擎中的自然语言处理技术和网页排序，广告点击率预估（CTR），推荐系统，垃圾邮件过滤等。

1.2.3 2012 之后：深度学习时代来临

在与 SVM 的竞争中，神经网络长时间内处于下风，直到 2012 年 [20] 局面才被改变。SVM、AdaBoost 等所谓的浅层模型并不能很好的解决图像识别，语音识别等复杂的问题，在这些问题上存在严重的过拟合。为此产业界需要更强大的算法，历史又一次选择了神经网络。

由于算法的改进以及大量训练样本的支持，加上计算能力的进步，训练深层、复杂的神经网络成为可能，它们在图像、语音识别等有挑战性的问题上显示出明显的优势。

深度学习的再度兴起可以追溯到 2006 年，G. Hinton 等人 [21] 提出了一种训练深

层神经网络的方法，用受限玻尔兹曼机训练多层神经网络的每一层，得到初始权重，然后继续训练整个神经网络。2012 年 Hinton 小组发明的深度卷积神经网络 AlexNet[20] 首先在图像分类问题上取得成功，随后被用于机器视觉的各种问题上，包括通用目标检测，人脸检测，行人检测，人脸识别，图像分割，图像边缘检测等。在这些问题上，卷积神经网络取得了当前最好的性能。在另一类称为时间序列分析的问题上，循环神经网络取得了成功。典型的代表是语音识别，自然语言处理，使用深度循环神经网络之后，语音识别的准确率显著提升，直至达到实际应用的要求。

与此同时，在策略、控制类问题上，深度强化学习技术取得了成功，典型的代表是 AlphaGo[22]。在各种游戏、自动驾驶等问题上，深度强化学习显示出了接近人类甚至比人类更强大的能力。另外，以生成对抗网络（GAN）[23] 为代表的深度生成框架在数据生成方面取得了惊人的效果，可以创造出逼真的图像，流畅的文章，动听的音乐，为解决数据生成这种“创作”类问题开辟了一条新思路。这一时期 AI 的产业化明显加速，人工智能已经成为当前计算机科学领域最炙手可热的方向。随着机器学习任务的规模越来越大，其对算力的要求也越来越高，大量机器学习任务开始向有着近乎无限资源的公有云迁移。

1.3 云计算和人工智能交叉领域的常见研究问题

云计算和人工智能是两个息息相关的热门领域。一方面，以深度学习为典型代表的人工智能技术在当今社会被应用的越来越广泛，研发、调试、发布新的模型的需求日益增长。与这种发展趋势对应，多数主流的云厂商都提供了机器学习模型训练-测试-部署的 pipeline。学术界也不断探索“云上机器学习”这一话题，在各种不同的业务场景下，利用不同的云服务更便捷、更经济高效地在公有云上开展 ML 模型的训练和部署。同时得益于近年硬件技术的发展，多种异构硬件在云环境中得到应用，为提升机器学习任务的性能和增强机器学习任务的安全性提供了新的可能。另一方面，机器学习技术也越来越多被用于解决云计算中常见的问题。例如使用机器学习算法解决置优化问题和利用强化学习解云环境中的资源调度问题。下文对这几个常见问题做简单概述，具体研究将在后续几章展开。

1.3.1 云上的机器学习系统

1.3.1.1 产业界的一站式系统

主流的云厂商都提供了面向机器学习的平台系统，例如 AWS 和 Sagamaker[24–26]，Azure 的 Azure ML Studio[27]，腾讯的 Angel[28] 等。这些基于云的平台提供了一站式调试、训练和部署 ML 模型的能力。一般而言此类平台被视为 SaaS 类的服务，因

为其是基于云资源构建的上层软件栈，使得用户能够直接使用 web 的方式使用。例如 Sagemaker 就支持用户直接在浏览器中用 jupyter notebook 编写和调试模型代码。

1.3.1.2 基于传统云服务的第三方系统

一般而言，产业界的平台系统面向的是用户最普遍的需求。因此，对于有特殊需求的用户，通常会有与产业界的解决方案并行的工作。例如，为了以尽可能低的成本在云上完成模型的训练，相关工作 [29, 30] 尝试利用云上的动态资源（价格低但是稳定性/可用性低）进行模型的训练，并辅以一定的策略增强其可靠性。再比如，机器学习模型的在线服务会有低延迟、高吞吐率的要求。为了实现上述需求，相关工作 [31] 利用云上的多种资源，根据负载的动态变化，敏捷地在不同资源之间切换，充分利用不同类型资源的优点，规避掉其缺点，实现高效、经济的模型在线服务。一般而言，学术界的此类研究构建于云厂商服务的上层，是一种 Cloud-of-Clouds 的模式。

1.3.1.3 基于新兴云服务的第三方系统

以 FaaS 为代表的新型云计算模式，以其高弹性、灵活的计费方式等特点吸引了众多研究者的注意。一般而言，用来训练机器学习模型的集群大小是固定的，很难动态地进行伸缩。同时，开发者还需要自行对该集群进行维护和管理，从而徒增一些不必要的时间和人力开销。因此，学术界开始探讨如何使得机器学习工作流享用到 FaaS 的诸多优点 [32]，从而使得其计算资源在模型训练时能按需伸缩，结束训练后自动将模型存储在持久化存储中，计算资源随即释放。

除了模型训练，也有部分研究者尝试利用 FaaS，以 serverless 的模式部署模型。虽然这一想法非常自然，但是还有诸多问题需要解决。例如，现有的 serverless 服务，如 AWS Lambda，其单个 instance 所能使用的内存有限，也无法使用 GPU 等加速芯片，同时其冷启动时间也较长（相比于服务对 latency 的要求）。如何优化 FaaS 的系统架构，使其更适合模型的部署，也是一个值得研究的问题。

1.3.2 新硬件对人工智能的影响

根据1.2中的描述，人工神经网络早在上世纪 80 年代就被提出。然而直到本世纪 10 年代左右，神经网络才再次进入学术界和产业界的视野，并得到了飞速发展。除了理论的进步，更重要的原因是算力的大幅进步。以 GPU, FPGA 等为代表的并行化加速硬件，极大地加快了深度学习模型的训练速度，使得学术界对于新模型架构的探索周期大幅缩短。在这种背景下，除了深度学习算法理论的迭代加快，也催生了一批针对机器学习系统的研究工作。这些工作关注如何使异构的硬件更好地支持机器学习模型的训练。

除了训练速度，安全也是人工智能领域的一个重要问题。当今时代数据已经成为重要的资产，开发者在将机器学习任务部署到云端的同时，也会对数据和模型的安全性有所担忧。虽然诸如同态加密之类的软件层面的解决方案可以提升 ML 任务的安全性，但是由于性能的制约始终未能得到大规模应用。以 Intel SGX[33] 为代表的安全计算环境技术，给人工智能安全带来了新的解决方案。

1.3.3 利用机器学习算法解决云计算中的资源配置与调度问题

1.3.3.1 利用机器学习算法解决配置优化问题

公有云厂商所提供的计算资源类型和计费模式越来越复杂。据不完全统计，截至目前，AWS EC2 提供了超过 400 种配置的虚拟机，阿里云提供了超过 500 种虚拟机。除了虚拟机配置不同之外，其收费模型也存在多种。例如，除了传统的包年包月、按量付费等，还有抢占式实例（在 AWS 中成为 Spot Instance）[34] 等计费方式。在此场景中，用户所面临的一个重要问题在于如何为自己的应用程序/负载选择合适配置和收费方式的资源。

部分研究者利用机器学习算法来解决此类问题。有的将其看作一个推荐问题 [35]，用协同过滤等推荐系统中常用的算法为不同的应用程序匹配合适的配置。有的将其建模为回归问题 [36–39]，将应用程序的信息、资源的配置信息等作为输入，预测在某种配置下某个应用程序的性能或者花费，从而得到最佳的配置。还有的将其视作在线优化问题 [40, 41]，利用贝叶斯优化等方法，通过有限次的尝试逐渐逼近最优解。

1.3.3.2 利用机器学习算法解决资源调度问题

资源调度是操作系统、分布式系统和云计算领域中的经典问题，其本质在于为系统中的每个任务分配合适的资源，从而使得系统达到某种状态，如资源利用率最高、闲置资源最少或者吞吐率最高等。近年来深度学习的流行，尤其是强化学习的兴起，使得部分研究者开始思考利用机器学习算法解决资源调度问题 [42–44]。一般而言，此类算法旨在从过去的任务执行记录中“学习”相关的规律，以指导为未来系统的调度动作。

第二章 面向人工智能的云计算软件系统研究

以深度学习为代表性技术的人工智能领域在 21 世纪 10 年代再度兴起，社会各界对于人工智能的需求也愈发旺盛。遍布超市和餐馆中的扫脸支付技术、智能手机上的语音智能助手、工厂中检测废件的自动检测装置等，都离不开人工智能技术的加持。上述场景都需要适当的机器学习模型在线部署以提供服务。

机器学习的工作流一般遵循如下几个步骤：1) 模型开发与调试。在此阶段中，开发者根据具体的场景，编写并调试模型代码。2) 模型参数调整。在这个步骤中，开发者使用训练集不断调整模型的超参数，使其在测试集上的表现符合某种标准（如准确率高于某个阈值）。3) 模型部署，开发者将开发完成的模型部署到对应的场景中对外提供服务。

为了方便开发者专注到模型的开发流程中，各大主流云厂商均实现了支持机器学习模型开发-调试-部署整个流程的软件栈。同时，云厂商提供的一般性的平台可能无法满足用户特定的需求。因此针对具体场景，学术界也提出了一系列基于云服务的机器学习软件，以达到降低开发成本、提高模型在线服务的质量等目标。本章对上述内容涉及到的相关工作展开具体研究。

2.1 分布式机器学习系统的两种架构范式

得益于云上近乎无限的资源，机器学习模型在云上的训练可以以分布的形式展开，以加快训练效率。本节介绍分布式 ML 系统的两种架构范式：数据并行架构和模型并行架构。本章所述的所有系统，皆是遵循这两种架构范式来设计的。

2.1.1 数据并行架构

2.1.1.1 Parameter Server 架构

大模型的训练一般难以在单机上运行，需要分布式的环境将更多的算力和存储资源组织起来。A. Smola 等人 [45] 在 2010 年为了解决大型自然语言处理模型的训练，提出一种并行的分布式训练架构。在该架构中，模型的参数通过 key-value 的形式存储在一部分节点上，另一部分节点负责训练，同时在完成训练后将参数 push 到存储参数的节点上。该架构实际上就是后来业界流行的 Parameter Server 架构，即参数服务器架构（简称为 PS Model），的雏形。

此后类似的架构在产业界得到了广泛使用。直到 2014 年，M. Li 等人 [46] 在 OSDI

上发表论文，综合地描述了 PS Model 的设计和实现，并完善了 PS Model 的通信模型、参数同步和异步的 push/pull 模型、server 节点的一致性模型。至此，PS Model 实际上已经开始逐渐成为业界大型分布式机器学习系统的设计范式。

如图 2.1 所示，在一个基于 PS Model 的集群中，服务器被分为两种，分别为 worker 和 server。其中 server 负责保存模型所有需要训练的参数，worker 负责具体的训练。在 worker 完成一轮迭代之后，会将更新后的参数变化量 push 到 server 端，并同步等待所有其它的 worker 完成此轮迭代。同步完成后，server 汇总从 worker 端得到的变化量并对参数进行更新，而后 worker 再从 server 端 pull 更新后的参数，并继续进行下一轮迭代。值得一提的是，实际场景中为了追求训练速度，有时也会允许异步的参数更新，即不要求 worker 等待其它 peer 节点完成本轮计算，而是完成本地计算后就可以向 server 请求 pull 新的参数。这种弱一致性的设计会加快训练速度，通过也可能牺牲模型的质量。

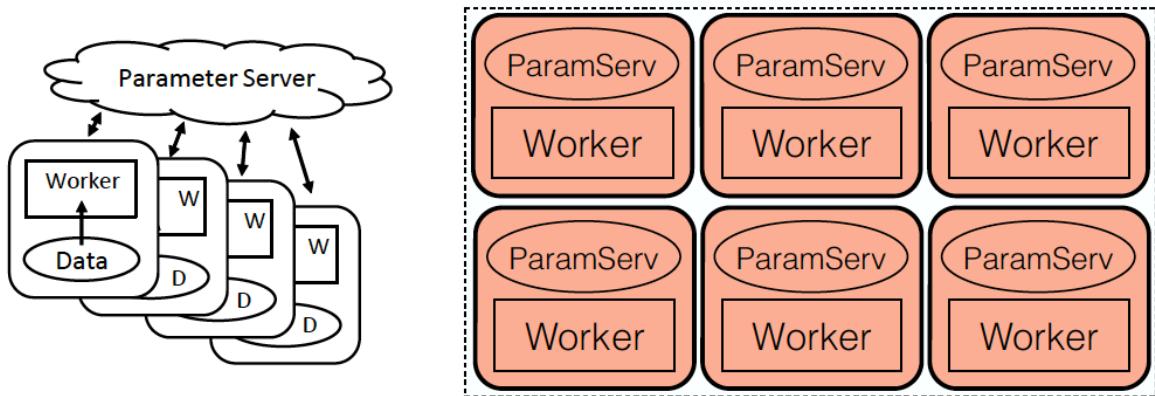


图 2.1 参数服务器系统架构。

PS Model 之所以能够高效，与其 worker push 和 pull 参数时的设计是密切相关的。图 2.2 阐述了在 PS Model 中使用梯度下降训练模型时的流程。值得注意的是，生产环境中的数据集一般都是稀疏的。例如用户画像数据，每个用户几乎不可能将所有表示其特征的列填满，很大概率会空余一些特征。如图中所示，每个 worker 被分配到的数据所对应的特征实际上只是整体数据集特征的一个子集。因此，在 PS Model 中，每个 worker 只会计算本地特征对应的参数增量，并这部分参数 push 到 server 节点上。在本轮结束后，再从 server 节点 pull 本地需要的参数。这种场景下，key-value 形式的参数存储就体现出了优势。每个 worker 通过 key 指定自己需要的参数，从而大大降低了节点之间的数据传输量。




图 2.2 在参数服务器架构中使用梯度下降训练模型的流程。

2.1.1.2 All-reduce 架构

PS Model 并非没有缺陷，事实上，当 worker 数目增加到一定数量时，worker 与 server 之间的网络通信就会成为瓶颈，worker 平均可以使用的带宽减少将会减少，集群中的通信复杂度与 node 的数量几乎是成线性的。为了解决这个问题，all-reduce 架构应运而生。其中最为常用的是 ring-allreduce。

事实上，all-reduce 并非机器学习系统中的新概念，而是从传统的高性能计算通用接口 MPI[47] 中借鉴而来的。图 2.3 展示了 ring-allreduce 的数据流图。在 ring-allreduce 算法中， N 个节点中的每个节点与其两个对等节点进行 $2(N - 1)$ 次通信。在此通信期间，节点发送和接收数据缓冲区的块。在前 $N - 1$ 次迭代中，将接收到的值添加到节点缓冲区中的值。在第二批 $N - 1$ 次迭代中，接收到的值替换了节点缓冲区中保存的值。先前的工作表明该算法是带宽最佳的，这意味着如果缓冲区足够大，它将最佳地利用可用的网络。

在产业界，Horovod[48] 和 BytePS[49] 就是使用 all-reduce 架构开发的分布式机器




图 2.3 ring-allreduce 示意图。

学习系统。

2.1.2 模型并行架构

除了数据并行之外，另外一种分布式训练架构称为模型并行 [50, 51]。顾名思义，该架构将模型拆分为多份分布在集群中的不同节点上，以流水线的方式对模型进行训练。图 2.4 展示了模型并行的工作流示意图。该类分布式架构常应用于两种场景下：1) 大模型的训练或部署；2) 在性能受限的节点上（例如边缘节点）训练或部署模型。




图 2.4 模型并行示意图。

2.2 公有云厂商提供的云上机器学习系统

本节以 AWS Sagemaker 为代表，介绍公有云厂商一站式的云上机器学习系统的设计。其它厂商中类似系统中对计算模型的抽象、使用方式等均与 Sagemaker 大同小异。

2.2.1 AWS Sagemaker

AWS 作为公有云领域的先驱者，在云计算的前沿技术领域一直处于领先地位。其某些代表性技术甚至成为了多数公有云厂商所共识的标杆和规范。在机器学习系统这一分领域，其代表性系统为 AWS Sagemaker。

Sagemaker 是一个实现和产品化机器学习模型的框架 [24]，用户可以将其模型训练需要的数据存储到 AWS 的对象存储服务 S3 中。然后，用户可以通过 web 的方式访问部署在云端的 Jupyter Notebook 服务，在线访问数据、编写并调试代码。当模型训练完毕后，可以使用 Sagemaker 内置的推理服务对模型进行发布。用户在发布时还可以根据平台的不同（云端或边缘节点）将模型打包编译成不同的版本。此外，Sagemaker 还内置了一些常用的算法和数据集，方便开发者直接调用。

在训练算法和系统机制方面，Sagemaker 旨在解决工业规模的模型训练场景中的如下几个常见问题：

- **支持增量式的训练和模型更新。** 在真实的工业场景中，几乎不存在完全静态的数据集。用来训练模型的数据集大多都是不断增长的。例如电商网站的用户行为数据，每天都在以相当的速度增长。在这样的动态数据上训练模型，势必要进行如下权衡：在全量数据上进行训练，可以获得质量更高的模型，然而时间和经济上的开销却会非常高；在最新更新的数据上（例如最近几天的数据）进行训练，可以快速的得到新的模型，却有可能在一定程度上牺牲模型的准确性。
- **容易估算训练模型产生的花销。** 对于体量非常大的数据集，用户需要较为准确地估计训练模型将会产生的时间和经济花销。当今的云计算一般遵循按量付费的收费模式，因此云上的机器学习用户会格外关注花销的问题。
- **支持暂停和恢复模型训练，有一定的弹性。** 生产环境中，大模型的训练通常包含跨越数十甚至上百台机器的并发任务。在一些场景中，由于超参数调整的需要或者计算资源的限制，开发者需要对这些任务进行中断和恢复。这就要求云上的 ML 系统能够支持大型训练任务中断和恢复时中间结果的保存和复原。
- **能够处理非持久性数据。** 在很多场景中，数据并不一定是持久化的，也会有很多“瞬时”的数据，例如直播时的视频流等。这些数据一般不会被持久化保存，因此如何支持对这些数据的挖掘和学习也是一个重要的问题。
- **支持自动调参。** 自动调参是一项非常耗时耗力的工作，特别是在生产环境的大数据集下。因此，如何能够支持高效的自动调参，方便用户选取合适的模型，对于云上的 ML 系统而言也是非常重要的。

下面将从计算模型、支持算法和具体的实现方式介绍 Sagemaker 如何解决上述问题。

2.2.1.1 计算模型

Sagemaker 将机器学习训练的工作流抽象为三个阶段：initialize，update 和 finalize。 initialize 阶段：对相关的变量进行初始化。 update 阶段：系统以数据流及其状态作为输入，根据用户编写算法更新状态。在 Sagemaker 的后台，状态更新是在多台计算节点上同步执行的。 finalize 阶段：对之前所有的更新进行汇总，并输出最后的结果（对于机器学习任务而言，一般是一个模型）。通过上述抽象，用户只需编写 initialize、update 和 finalize 三个函数，就可以将整个训练过程交由 Sagemaker，等待最后的模型输出。

算法 1 用伪代码的形式讲述了三个阶段的具体流程。这里以计算一列数据的中位数为例，使用随机梯度下降（SGD）进行求解。对于如下一列数据： $x_1, x_2, x_3, \dots, x_n$ ，则由如下公式给出这一列数据的中位数： $\operatorname{argmin}_z \sum_{i=1}^n \|x_i - z\|$ 。算法中的 initialize 函数首先对 median 和 n 两个参数做初始化。这里 state 可以理解为一个 key-value 存储结构。在 update 阶段，函数将接收到的数据流 data_stream 分为若干 mini_batch，对每个 batch 没的数据，迭代式的对 median 值进行更新，同时更新 n 的值。最后，在 finalize 函数中，对最终的 median 值进行汇总。同时，系统还支持用户在算法的任意位置设置 barrier（第 15 行），以对整个训练过程进行同步操作。

Algorithm 1 Sagemaker 计算模型

```

1: function INITIALIZE(state)
2:   state.initialize('median', 0)
3:   state.initialize('n', 0)
4:
5: function UPDATE(state, data_stream, synchronized)
6:   for mini_batch ∈ data_stream do
7:     current_median ← state.pull('median')
8:     n ← state.pull('n')
9:     inc ← 0
10:    batch_size ← 0
11:    for item ∈ mini_batch do
12:      if item > current_median then
13:        inc += 1
14:      else
15:        inc -= 1
16:      state.push('n', batch_size)
17:      state.push('median',  $\frac{\text{inc}}{\sqrt{n+batch\_size}}$ )
18:      if synchronized then
19:        state.barrier()
20:
21: function FINALIZE(state)
22:   return state.pull('median')
```

2.2.1.2 支持算法

尽管深度学习在近年越来越流行，特别是在学术界，各种刷新 SOTA（即 state-of-the-art，当前最优）效果的模型层出不穷。然而在产业界，经典的机器学习模型适用性依然非常广。本节对 Sagemaker 支持的广泛应用于产业界的经典机器学习模型做简单介绍。

Linear Learner. 即线性回归模型，一般用来解决回归或者分类问题。在 Sagemaker 中，其支持使用随即梯度下降（SGD）来训练一个线性模型。特别地，Sagemaker 还支持对一个模型指定不同的目标函数，并且并行地训练其对应的多个模型。

Factorization Machines (FM)[52]. FM 常用于推荐系统中很多任务（例如 CTR 预估），是一种适用于分类和回归任务的更为通用的监督学习算法。FM 是对线性模型的一种拓展，考虑了高维稀疏数据集中不同特征之间的关联。在 Sagemaker 中，FM 也是通过 SGD 来进行训练的。

K-Means Clustering[53]. K-Means 聚类是一类无监督学习算法，可以将一个数据集聚为 K 个不同的类别。Sagemaker 实现了一个流式计算版本的 K-means，综合运用了来自随机优化、核心集和在线选址问题的思想。

Principal Component Analysis (PCA).[54] 即主成分分析，是一种通过尽可能保留数据集的方差来对数据进行降维的算法。Sagemaker 实现了两种 PCA 算法。第一类是准确型的，通过适量的采样和特征提取，需要 $O(d^2)$ 量级的内存大小。另一种是粗略型的，通过随即投影来减小内存开销到 $O(kd)$ 。这里 k 和 d 分别代表主成分的个数和数据的维度。

Neural Topic Models (NTM). 在 Sagemaker 中，NTM 是一种用来在大型离散数据集中抽取 latent representation 的无监督学习算法，例如抽取文档中的语料库。为了实现更快的推理，NTM 是基于 variational autoencoder (VAE) 模型实现的。

Time Series Forecasting with DeepAR. 这是一种基于循环神经网络 (RNN) 的概率预测算法。和其它流行的时间序列预测算法不同，DeepAR[55] 使用一系列数据集训练了一个全局的模型，从而重点关注了在生产环境中常见的时间序列预测问题。

2.2.1.3 实现方式

经济和高效是云用户总是在关心的两类问题。Sagemaker 为了满足这样的用户需求，充分利用了其底层的异构资源池，并通过上层的系统软件使得机器学习可以在成百上千台 VM 上横向拓展。

在异构硬件上运行 ML 任务。为了实现在异构的资源上（主要是 CPU 和 GPU），Sagemaker 中的大多数算法使用 MXNet[56] 的库作为使用底层硬件的接口。MXNet 通

过一个张量算子构成的计算图来描述一个机器学习算法，同时通过将算子分配到具体的设备进行执行来实现并发地训练模型。

利用参数服务器模型（Parameter-Server Model，即 PS Model）[46] 实现分布式训练和参数共享。如图 2.5 所示，在 Sagemaker 中，分布式训练就是通过参数服务器模型来实现的，且一般默认使用的是弱一致性的模式。同时，为了方便 push 和 pull 的操作，AWS 实现了一个 key-value 的存储系统 KVStore。

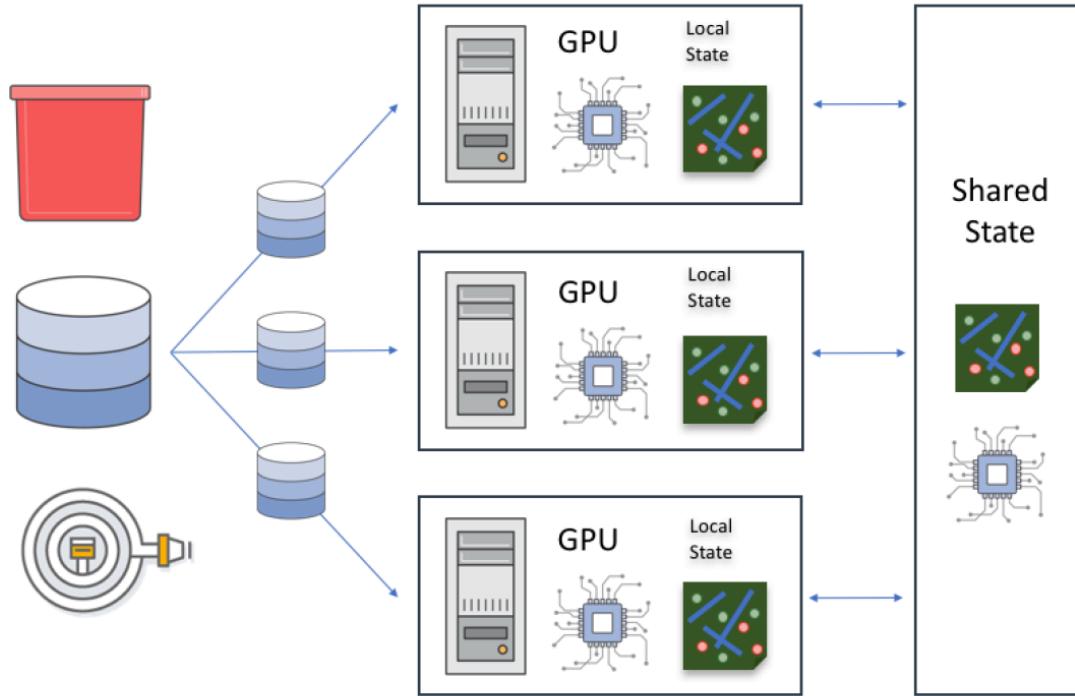


图 2.5 基于 PS Model 的 Sagemaker 系统架构。

模型抽象与参数表达。 Sagemaker 在上层为用户提供了模型抽象和参数的表示方式。对于一个模型而言，有两个与其绑定的函数需要用户来实现：1) *score* 函数，为一个模型打分以衡量模型在该数据集的训练程度，在调试或者超参数调整阶段会被用到；2) *evaluate* 函数，接受一个 batch 的数据并计算该模型的输出。需要指明的是，对于不同的模型而言，输出的格式可能是不同的，例如对于分类问题，输出可能是一个 label 也可能是不同类别的概率。参数的表达方式同样需要统一的上层抽象。在 Sagemaker 中，不同类型的模型有着不同的表达形式。例如，K-means 算法的模型就表现为一个核心集，因此，对于任意 $k < k_{max}$ ，用户都无需重新训练模型，而是可以直接得到结果。对于 K 邻近算法，Sagemaker 也有类似的设计。

模型微调与超参数调整。 通常而言，一个超参数调整任务（Hyperparameter Tuning Optimization，即 HPO）[57] 由多个并行的模型训练任务构成，这些训练任务每个都尝

试一个不同的超参数组合，最后得到一个最优的配置。上述过程需要耗费大量计算资源和时间，对于寻常用户而言是非常耗时耗力的。而 Sagemaker 基于 PS 的计算模型设计保证了任意一个 ML 训练任务都可以随时启动和停止。这种机制使得模型微调和超参数调整变得更为容易操作：1) 用户可以增量式地更新数据集，但却不用每次都重新训练模型，因为整个训练过程都是流式的；2) HPO 可以同时启动多个训练任务，然后提前发现那些劣质的模型并将其终止，从而降低 HPO 的成本。

2.2.1.4 模型部署

作为一站式的机器学习系统，除了模型训练和调参，Sagemaker 还支持模型部署。在部署时，首先，用户需要对其模型指定一个 endpoint，然后将部署该模型的代码打包成容器镜像，存储在 EC2 Container Registry 中。在模型实际对外提供服务时，模型文件会从对象存储 S3 中传输到容器中，进而以容器为单位对外提供服务。

2.3 基于公有云服务的第三方机器学习系统

尽管公有云厂商实现了相当完备的一站式机器学习系统，但是随着生产环境中业务场景的日渐复杂，大而全的公有云解决方案已经无法解决个性化的用户需求。例如，某些用户希望以尽可能低的成本完成大型模型的训练，或者在保证模型服务的 SLO 前提下，能够尽可能低成本的部署机器学习模型。在上述场景中，为了完成用户的具体需求，需要综合利用各类云资源，并制定一定的策略。本节对近几年来几个构建于公有云资源上层的机器学习系统做具体介绍。

2.3.1 基于云厂商动态资源的机器学习模型训练系统

机器学习模型的训练是一个不断在给定数据集上迭代更新参数的过程。对于一些较大的模型，训练时间一般会非常长。特别是深度神经网络模型再度兴起后，模型开始变得越来越庞大。例如 Open AI 的自然语言模型 GPT-3，包含 1750 亿个参数，单单存储这些参数就需要 450GB 的空间。而训练该模型的成本，据估计更是达到了 1200 万美元。对于一些个人开发者和小型公司，大模型的训练往往显得遥不可及。

除了上述可训练的参数之外，还存在大量不可训练的参数。例如，SVM 模型中核函数的类型，树模型中树的深度，深度神经网络模型中网络的宽度和深度等。这些参数需要由开发者在训练之前事先决定，一般被称为超参数。不同的参数组合在一起，就构成了巨大的搜索空间。例如，如果存在 6 个超参数，每个超参数有 4 种不同的选择，就会产生 $4^6 = 4096$ 种不同的超参数组合。

完全遍历所有的超参数组合是非常费时费力的，通常情况下也是不切实际的。研究者为了减少超参数搜索的此时，提出了诸如网格搜索、贝叶斯搜索等技术。但即便如此，仍然需要大量的算力来支撑整个搜索过程。

而与此同时，在云计算时代，云上资源的易用性、高度的弹性以及收费模式的多样性使得以较低的成本完成费时费力的模型训练和超参数搜索变为可能。如上一小节所述，一些云厂商提供了一些价格低廉的动态资源。和一般的可以获得可用性保障的资源相比，这类资源拥有相同的计算能力，但是可用性比较低，在某些场合会被云厂商主动回收。基于上述事实，可以形成一个直观的想法：在这类廉价的资源上运行机器学习模型训练和调参任务，并辅以一定的容错策略和资源选择策略，可以显著降低成本。

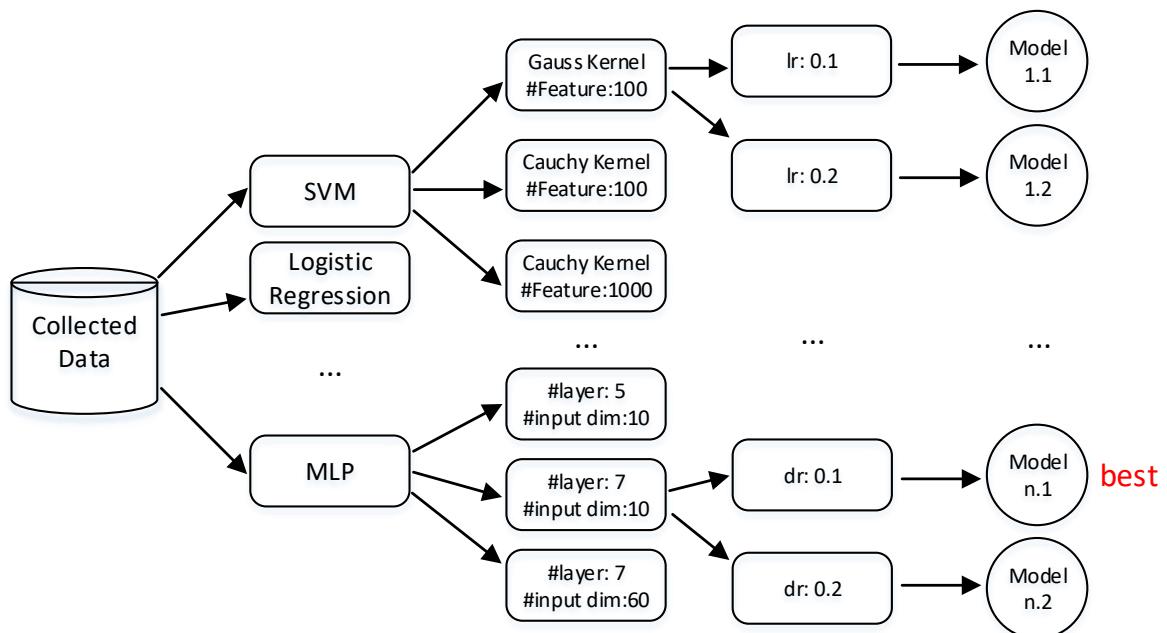


图 2.6 一个超参数调整的例子。

但是，在动态资源上运行机器学习模型训练和调参，虽然直觉上会降低成本，但是可能会产生额外的风险。因此，要做到高效并可靠地在动态资源上运行上述作业，还有如下若干问题需要解决：

1. 及时处理中断。 动态资源之所以廉价，是因为其稳定性比较低。通常情况下，在某些特殊情况下（例如集群中的负载比较高，需要动态资源来补充资源池），云厂商有权利主动回收这些动态资源。如果不处理这种回收引起的中断，机器学习模型的训练就要被动终止。因此需要采取一些手段，例如提前保存模型或者迁移任务，以及时处理中断。

2. 合理的资源选取算法。事实上，这是在云上运行任务时需要考虑的一个通用问题。用户在云上运行作业时，一般会有一个目标，例如作业运行时间最短或者最终的总体成本最低。因此需要通过一定的算法，为用户选取能满足其需求的资源。对于机器学习模型训练与调参任务亦是如此。

3. 充分利用云的弹性。事实上，在机器学习模型训练过程中，存在大量的无效计算。如图 2.6 所示，经过大量的参数尝试，最终只剩余一个有效模型（即效果最好的模型）。因此，在参数搜索的过程中，大量的计算是无效计算。而云计算的一个重要特点就是高弹性，即用户可以因为负载增加随时获取资源，也可以因为资源闲置随时释放资源。如果效果不好的模型能够被提前发现，并释放掉其占用的计算资源，则可以避免大量无效计算，从而进一步节省成本。

4. 对计算框架进行定制。现有的流行的机器学习框架如 Tensorflow[58], PyTorch[59], MXnet[56] 等，一般都假设底层的计算资源是可靠的，因此都没有针对上述动态资源进行适配。如果要在动态资源上运行 ML 任务，则需要对框架进行深度定制，使其具备一定的容错能力。

为了解决上述问题，使 ML 模型训练和调参都可以在云上经济高效地进行，许多研究者提出了若干解决方案。A. Harlap 等人在 2017 年提出了 ML 模型训练系统 Proteus[29]，针对 Parameter Server 架构的 ML 模型训练框架对 AWS 和 Google Cloud 的动态资源做了适配，使其能高效经济地在之上运行。Y. Peng 等人在 2018 年提出基于 PS Model 的深度学习集群调度器 Optimus[60]，通过动态调整集群中 PS Model 的 server 和 worker 的数量比例，并结合对任务完成时间的预测，使集群的吞吐率最大化。Y. Li 等人在 2020 年提出了 SpotTune[30]，将 ML 调参任务部署在 AWS 动态资源上，并结合一定的资源选取算法和训练趋势预测算法，使调参任务节省大量的无效计算，最终达到了经济高效的目的。下文对较有代表性的 Proteus 和 SpotTune 做较为详细的介绍。

在介绍相关系统之前，有必要对目前云市场上常见的资源类型、本节重点研究的动态资源及其收费模式做简要介绍。

云计算作为互联网时代下的一种新型计算模式，通过虚拟化和软件定义技术将服务器、存储、网络甚至软件等各种资源聚集为共享资源池。这些虚拟资源用则进行分配，而且种类和数量均可按需配置并按实际用量计费，不用则回收到资源池中等待下次分配。相比传统的 IT 资源使用模式，云计算这种按需使用、按量付费的特点增加了用户的灵活性，但也导致了用户需求的不确定性。比如：在销售旺季，用户使用云的频率就会增加，云服务商的负载压力会持续增大甚至超过峰值，进而可能导致故障；而在销售淡季，用户使用云的频率就会大幅下降，云服务商的负荷压力也会大幅降低，导致了空闲资源的浪费。为了充分利用云资源池中的空闲资源，云服务商推出了多种的

计费模式，试图以多样化的价格来吸引用户的同时，确保自己在需求高峰时可以回收部分资源。

表 2.1 亚马逊公有云 EC2 计费模式分析

比较 计费模型	计费公式	计费特点	适用场景
按需实例	实例运行时长 * 单位时间对应实例费率	单位时间费率固定，无需用户有任何使用承诺，价格较高	适合使用需求周期较短、对实例运行环境需求多变的用户
预留实例	$\text{签约金} + \sum_{i=1}^n \text{第 } i \text{ 次运行时间} * \text{单位时间费率}$	用户与亚马逊签订长时间使用合约，并交付签约金，在“合同”期内使用 EC2 需额外支付费用，但费率适中	适合使用需求周期长且实例对运行环境性能要求稳定的用户
竞价实例	实例运行时长 * 单位时间对应实例费率	单位时间实例费率变动，根据实例的需求情况以拍卖的方式决定，费用较低	适用于没有即时性要求、任务可中断的业务

以亚马逊公有云为例，如表 2.1 所示，EC2 按照计费模式可划分为按需实例 (On-demand Instance)、保留实例 (Reserved Instance) 和竞价实例 (Spot Instance) 这三类。相比较于按需实例和保留实例，竞价实例可提供超低折扣，但其价格会随着供需关系而不断调整。用户需要为获取该实例设置一个最高的出价，如果当前市场的价格低于用户的出价，则用户获得实例资源进行计算。一旦市场价格高出用户的出价，则该计算资源会被亚马逊收回。对于公有云厂商来说，竞价实例通过市场机制发掘了云资源的真正价格，达到了其尽可能以最合理的价格卖出最多闲置资源的目标。而对于云平台上的虚拟云用户来说，各种无状态、或者具有容错能力的应用程序可以基于竞价实例来大幅度降低运行成本，代表负载包括：大数据、容器化工作负载、CI/CD、Web 服务器、高性能计算 (HPC) 以及其它测试和开发工作负载。尽管竞价实例的出现为非在线业务或者成本敏感业务提供了一种全新的计算资源类型，但是目前来看，无论用户的业务类型为哪种，大部分用户选择的资源依旧是为在线业务所准备的按需实例和保留实例。

竞价实例与按需实例、保留实例的合理使用，可以帮助虚拟云用户优化工作负载的成本和性能。根据 AWS 官方博客，已经有不少大型企业（如本田汽车）成功使用 AWS 的竞价实例把部分业务的计算成本下降高达 70%。然而有效的使用竞价实例除了对负载自身的要求以外（如可中断等），还需要用户针对自身的应用场景选择“正确”的实例类型。由于竞价实例在价格和回收方面的不确定性，这是比较复杂的。

Proteus[29] 是一个基于 PS Model 架构的机器学习系统。PS 是大规模机器学习系统中常用的架构，其系统架构在2.2.1中已描述。如其文中描述，其使用了敏捷的弹性机制并辅以“激进的”竞价策略，使得机器学习任务在云上高效经济地完成。Proteus 由两个主要组件构成：AgileML 和 BidBrain。

其中，AgileML 是负责协调整个 PS 架构的主要组件。其通过如下的基本思想，在保证整个系统可用性的前提下，尽可能多使用动态资源（即 AWS Spot Instances）以降低成本：1) 将 PS 的关键功能节点（即保存模型参数的 server 节点）部署在可靠资源上（如 AWS 的按需实例或者预留实例）；2) 将 PS 的 worker 节点（即负责实际计算和参数更新的节点）部署在动态资源；3) 当动态资源和可靠资源的比例不同时，AgileML 会采取不同的策略。具体地，当比例比较小时（例如 2:1），其简单地将 server 节点分布在所有的可靠资源上，而当比例比较大的时候（例如 63:1），其将可靠资源作为 BackupPSS 而将动态资源作为 ActivePSS，当发生参数更新时，更新会先到达 ActivePSS。同时，在网络带宽允许的前提下，ActivePSS 上会启动相应的后台任务将参数同步到 BackupPSS 上。

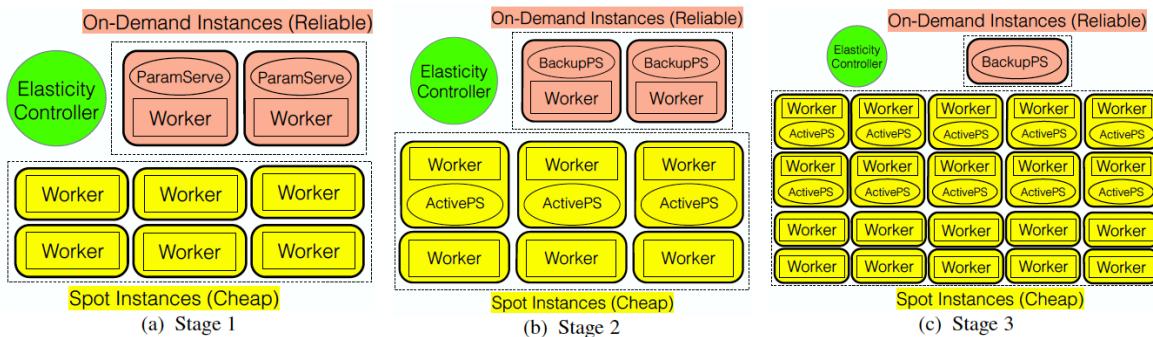


图 2.7 AgileML 架构中的三个阶段。Stage 1: 只存在部署在可靠资源上的 ParamServs。Stage 2: ActivePSS 部署在动态资源上，BackupPSS 部署在可靠资源上。Stage 3: 所有的 ActivePSS 都部署在动态资源上，可靠资源上没有 worker。

BidBrain 是 Proteus 中的资源管理模块，决定何时获取和释放动态资源。据文中所描述，BidBrain 是专为 AWS EC2 定制的，但是其经过少量的修改和定制化也可以适用于其它环境（如私有集群和其它公有云市场）。其秩序性地监控云市场中动态资源的价格，并即时地竞标那些可能给当前计算带来增益的资源（文中通过 work per dollar 来衡量增益，即单位花费可以完成的工作量）。类似地，当一种资源在达到其第一个小时的末端时，就有可能因为性价比降低而被释放掉。另外 BidBrain 还利用了 AWS EC2 的一项特殊规则：当资源在其第一个小时内被释放时，其所有花费会被退回。因此其也会主动获取那些在接下来的一小时内会被释放掉的资源，以进一步降低整个成本，此种策略被作者成为激进的竞标策略。总体而言，BidBrain 会在激进的竞标策略和保守策

略之间权衡，以寻求整个系统的收益最大化。

AgileML 的具体功能和技术特点，下文通过一个示例来说明。图 2.7 描述了 AgileML 架构中的三个阶段，分别对应不同的资源类型比例。

Stage 1: 参数服务器仅位于可靠节点上。此阶段为整个 ML 训练过程的启动阶段。对于大多数 ML 的应用程序而言（例如 K-means, DNN, Logistic Regression, MF, LDA 等），其在 PS 模型的场景下 worker 节点是无状态的，其当前轮次更新的参数数据会 push 到 server 节点进行持久化存储。因此，在启动时，AgileML 会将所有的 server 节点部署到可靠资源上，而将所有的 worker 节点部署到动态资源上。在这种情形下，当 worker 因为云厂商的主动回收而宕机时，整个训练过程并不会受到影响，也不需要进行 checkpointing。但是在模式下，当动态资源与可靠资源相比比例过于悬殊时，网络会成为瓶颈。例如当存在 60 个动态节点和 4 个可靠节点时，MF 的训练速度会下降 85%

Stage 2: ActivePSs 部署在动态节点上，BackupPSs 部署在可靠节点上。为了解决 Stage 1 中的网络瓶颈问题，Stage 2 中将 server 节点分为 ActivePS 和 BackupPS 两种，其中 ActivePS 分布在动态资源上，BackupPS 分布在可靠资源上。这种策略合理控制了 server 节点和 worker 节点的比例，解决了网络的瓶颈问题。所有的参数在 ActivePS 内部是共享的，并且在后台批量地 push 到 BackupPS 上，因此当 ActivePS 因厂商主动回收而宕机时，BackupPS 可以恢复其相关状态，并启动新的动态节点。需要注意的是，在 Stage 2 中，计算节点，即 worker，仍然存在于 ActivePS 上。




图 2.8 AgileML 动态地添加并删除资源。

Stage 3: 所有的计算节点，即 worker 都位于动态节点上。实验证明，当动态资源和可靠资源的比例超过 15:1 时，和 BackupPS 共同部署的 worker 会造成“落后者效应”（即 Straggler Effect）。因此，Stage 3 中简单地移除了所有位于 BackupPS 中的 worker。何时由 Stage 2 转移到 Stage 3，依赖于网络带宽，动态资源和可靠资源地比例以及 ML 模型的大小等等。

上述三个 stage 之间的转移一般是由 AgileML 根据动态资源和可靠资源之间的比例动态决定的。当发生阶段转移时，AgileML 会根据实际情况做出相应的动作。例如，

当从 Stage 1 转移到 Stage 2 时，AgileML 会将模型的状态（一般是模型的参数）转移到新增的动态资源上，当动态资源和可靠资源的比例超过一个阈值时，AgileML 会将相应的 worker 在 BackupPS 上删除，并将相关的训练数据重新分布到其余 worker 上。图 2.8 所示的是一个 stage 转移的示例。

BidBrain 是 Proteus 中的资源管理模块，决定何时获取和释放动态资源。其持续性地监控当前和历史的动态资源价格数据，并在相关的时刻根据预测出的花费做出决策，选择当前最优的资源加入动态资源池。简而言之，其资源选取策略较为激进，会考虑那些在未来一个小时就会被回收的 Spot Instances，以获取相应的退款，进而进一步降低使用成本。其细节策略与相关的公式推导本文不再赘述。

总体而言，Proteus 运用了激进的资源选取策略，将动态资源和可靠资源相结合，进行云上的 ML 模型训练。经过其实验证，与仅使用可靠资源相比，Proteus 可以实现约 85% 的成本节省，和一般的基于 checkpoint 的云上 ML 训练系统相比，其效率约可以提升 50%。

与单个模型的训练相比，模型的超参数调整（Hyper-parameter Tuning，下文简称 HPT）在整个 ML 模型产出周期中位于更上一层。其一般需要开发者尝试模型的多个超参数组合，以得出最优的一个。SpotTune 是一个云上自动调参管理系统，通过运用公有云上廉价的动态资源来协调整个 HPT 过程。据文中所述，SpotTune 同样是基于 AWS 的公有云服务实现的，但是经过一定程度的修改和定制，其可以应用与其它云厂商。为了妥善处理因厂商主动回收产生的中断，SpotTune 根据厂商提前发出的通知事先对模型进行 checkpoint 并将其保存到持久化对象存储中。同时其运用了两个关键技术来保证 HPT 的经济高效：

1. 基于花费的细粒度资源管理。SpotTune 计算花费的粒度非常细。其通过预测动态资源的回收概率和在线对 HPT 任务进行性能建模，预测出接下来一小时内“单步成本”最低的资源并进行任务部署。

2. 基于训练趋势预测的早停机制。SpotTune 将 ML 模型的训练曲线建模为一个可以预测的、多阶段的函数。简而言之，其可以通过当前时刻收集到的关于模型的质量信息（通常是模型的 score 函数所得出的结果，例如分类模型的分类准确率，回归模型的平均平方误差等等）来预测该模型在最终收敛时的质量，以提前结束那些劣质模型，节省计算资源。

SpotTune 的系统架构如图 2.9 所示。其主要功能模块包含 Provisioner 和 Orchestrator 两部分。其中 **Provisioner** 负责与 AWS 互动以请求和获取资源。通过结合历史数据和在线更新的性能数据，Provisioner 可以细粒度地预测每种资源带来的收益，进而选择最适合 HPT 任务的资源。**Orchestrator** 负责监控每个超参数组合的训练进度。通过当




图 2.9 SpotTune 系统架构。

前收集到的模型质量数据，其可以预测模型的最终质量。Orchestrator 一直监听 AWS 市场的消息，当收到回收提醒时，其会立即将模型 checkpoint 到持久化存储系统 AWS S3 中。另一方面，SpotTune 认为运行超过一小时的实例性价比是比较低的，在没有特殊情况出现时，Orchestrator 会主动将其停止。

SpotTune 之所以能做到经济高效，是由 Provisioner 和 Orchestrator 中的 RevPred 模型和 EarlyCurve 模型决定的。其中 RevPred 通利用历史数据预测每一种动态资源在将来一小时内被回收的概率，进而用该概率结合在线更新的性能数据预测每一种资源在将来一段时间的效率，其量纲为“\$每步”。具体计算过程如下：

1. 计算每种资源在接下来一小时内单价的数学期望。公式 2.1 给出了计算方法。公式中的参数 p 为该示例在一小时内被回收的概率。如果该资源被回收（概率对应为 p ），则价格为零，因为 AWS 会将该部分费用全数退回给用户。如果该资源没有被回收（对应概率为 $1 - p$ ），则按照当前单价收费。

$$\begin{aligned}\mathbb{E}[eCost] &= [(1-p) \cdot \overline{\text{price}} + p \cdot 0] \cdot 1 \text{ hour} \\ &= (1-p) \cdot \overline{\text{price}} \cdot 1 \text{ hour}\end{aligned}\quad (2.1)$$

2. 计算每种资源在接下来一小时内每运行一步（或一个迭代周期，在 ML 作业中通常体现为一个 **batch**）的花费。公式 2.2 给出了计算方法。其中 $M[\text{inst}][\text{hp}]$ 代表了 HPT 任务 hp 在示例类型 inst 上的运行速度（每步的耗时，seconds / step），由 SpotTune 持续在线监控模型在每种实例上的训练情况得出。

$$\begin{aligned}\mathbb{E}[sCost] &= \mathbb{E}\left[\frac{M[\text{inst}][\text{hp}] \cdot eCost}{1 \text{ hour}}\right] \\ &= \frac{M[\text{inst}][\text{hp}] \cdot \mathbb{E}[eCost]}{1 \text{ hour}} \\ &= \frac{M[\text{inst}][\text{hp}] \cdot (1-p) \cdot \overline{\text{price}} \cdot 1 \text{ hour}}{1 \text{ hour}} \\ &= M[\text{inst}][\text{hp}] \cdot (1-p) \cdot \overline{\text{price}}\end{aligned}\quad (2.2)$$

至于实例回收概率 p ，SpotTune 通过一个精心调试的 LSTM 神经网络模型来预测，此处不再赘述。




图 2.10 Logistic Regression 与 Resnet-56 的训练曲线。

另一方面，SpotTune 认为每个 ML 训练任务的曲线都可以使用一个分段函数进行建模，并利用其部分数据来拟合整个曲线实际的形状，进而预测曲线的最终走势。图 2.10 展示了两种 ML 任务的训练曲线，都呈现出明显的反比例特征和阶段性特征（通常而言，阶段性的特征一般是由学习率的突变导致的）。且第一张图显示可以通过部分的曲线形状来预测最终的曲线走势，进而提前淘汰一部分模型。EarlyCurve 将每个 ML 训练任务按照公式 2.3 进行建模，通过当前收集到的部分数据将其拟合为一个分段函数。

$$\hat{\mathcal{L}}_k = \sum_{i=1}^{ST} \left(\frac{1}{\alpha_{i0} \cdot k^2 + \alpha_{i1} \cdot k + \alpha_{i2}} + \alpha_{i3} \right) \cdot \text{sign}(k, l_i, r_i) \quad (2.3)$$

公式 2.3 工作的前提是用户先指定一个早停系数 $\theta \in [0, 1]$ ，当训练完成 θ 时，EarlyCurve 开始预测模型的最终走势，并在此时淘汰一部分模型。这个参数反映了用户对于调参任务的激进程度，小的 θ 可能会使预测准确率降低，但是能更快地结束 HPT，反之亦然。具体 θ 的选择，依赖具体场景和用户的具体需求。




图 2.11 SpotTune 工作流程示例。

图 2.11 给出了 SpotTune 的一个示例工作流程。在该流程中，一个 HPT 任务被启动的第一小时就被回收，因此第一小时的算力对于 SpotTune 而言是免费的。后面该模型再次被调度之后运行超过了一小时，因此被 SpotTune 主动停止，并再次被调度到别的实例上。最终，当任务完成度为 θ 时，SpotTune 判断其是否是一个优秀的模型，如果是的话将继续训练直到结束，否则其占用的计算资源将被直接释放掉。

SpotTune 通过利用云上的动态资源，辅以一定的资源选取策略和 ML 训练过程预测算法，使得 HPT 可以在云上经济高效的运行。与 Proteus 类似，该类系统常常将成本放在系统设计的首位。云计算以其 pay-as-you-go 的使用模型俘获了大量用户，然而大到企业用户，小到个人用户，往往都会将成本放在首位，因为在云上获得的任何算力都会直接或间接地转化为经济开销，对于机器学习这种耗费算力的场景更是如此。正因为这样场景的普遍性存在，类似 Proteus 和 SpotTune 的基于云商服务进行二次开发的第三方系统才层出不穷。

2.3.2 基于 FaaS 的模型训练系统

除了上述基于 IaaS 服务的 ML 系统外，近年来基于新型计算模式 FaaS 的 ML 系统也逐渐进入学术圈的视野。FaaS，亦即 serverless computing，是一种新型的计算模式。其关键词 serverless 是一个用户维度的特征词，并非真的没有服务器，而是在用户的角




图 2.12 基于 PS 架构的 serverless ML 系统。

度感知不到后端服务器的存在。用户只需要上传其业务代码，并声明相应的 hook API，即可在云端部署一个事件驱动的 function，这也是 FaaS，即 function as a service 这一代称的由来。用户的函数一般按照请求次数收费，并且根据请求负载的变化，云厂商会进行弹性伸缩。这种细粒度的收费模式和弹性的使用模式使得应用上云变得更为简单，也自然有学者想到将其与 ML 联系在一起。

然而，serverless computing 实际上并不是天然适用于 ML 系统的，要实现 FaaS 风格的 ML 系统，势必要在当前的 serverless computing 框架之上进行深度修改。总体而言，若要应用于 ML 的工作负载，serverless computing 目前还存在如下问题：

1. 本地内存和磁盘空间小。通常而言，为了更快的横向拓展，轻量是函数计算设计的第一要义。因此，目前流行的 FaaS 架构，所支持的内存大小和磁盘大小都有限。例如 AWS Lambda 仅支持最多 3GB 的本地内存和 512MB 的本地磁盘。而现有的 ML 系统一般会在本地保留一份完整的数据集，并将数据集全部 load 到内存中以加快训练过程，这与 serverless 的设计原则是相违背的。当下的流行的 Tensorflow，Spark 等框架便无法不加修改地在 AWS Lambda 内运行。

2. 带宽有限，无法进行 p2p 通信。与 VM 相比，serverless 函数一般网络带宽非常有限。例如，最大的 AWS Lambda 函数仅支持上线为 60MBps 的带宽，这与数据中心中的千兆网络，万兆网络甚至 Infini-band 相比是非常低的。另外，serverless computing 中的函数一般是无状态的，且不同的函数之间一般无法直接通信（一个函数可以在 service 维度调用另一个函数的 API，但是同一个 service 的不同函数实例一般无法感知其它函数实例的存在）。因此，在本地数据中心中常用的通信策略，例如树形或者环形的

all-reduce 通信在 serverless 环境中是无法实现的。

3. 生命周期短且启动时间不稳定。 Serverless 函数一般是为在线的 service 设计的，因此其生命周期天然较短。同时其启动时间不稳定，例如 AWS Lambda 的启动时间甚至最长可以达到一分钟。因此，基于 serverless computing 的 ML 系统必须能够很好的处理频繁的函数启停。

4. 缺少快速的共享存储支持。 为了解决函数之间无法通信的问题，共享存储是一种常用的手段。但目前云环境中支持 serverless 使用的共享存储仅限于对象存储、数据库等 SaaS 服务，其响应延时、吞吐量等仍然无法与数据中心环境中的共享内存相比。

L. Feng 等人 [61] 在 2018 年提出了一种简单的基于 serverless 的 ML 训练框架，其系统仍然采用 PS 作为主要框架。为了解决不同函数之间无法直接通信的问题，其采用云数据库作为中间存储层，使得不同的函数实例通过共享存储的方式进行通信。这一思想类似操作系统中进程间通信（IPC）的实现方式之一，即共享内存。图 2.12 描绘了该系统的架构图。其 PS 架构中的 server 和 worker 的实体都是函数。由于云数据库本身没有对参数进行聚集、更新、分发的能力，其 server 函数实际上负责参数的 push 和 pull 操作，数据的实际存储位置还是在数据库中。




图 2.13 在 AWS Lambda 和 EC2 上训练一个逻辑回归模型的耗时和花费。每个点代表一个 epoch。

基于上述基本架构，H. Wang 等人 [32] 在 2019 年提出了基于 serverless computing 的 ML 系统 Siren，使用强化学习算法来辅助决策整个系统中的函数个数和分布。其基本假设在于，不同的函数数量会导致不同的训练完成事件和最终花费，且其模式难以通过简单的规律来总结。而且对于不同的 ML 模型，规律也不尽相同。图 2.13 以在一个具有 8 核心 CPU 的 EC2 虚拟机实例上训练模型耗费的时间和产生的花费作为 baseline 对比了不同的函数数量下花费和耗时的不同。

图 2.14 描述了 Siren 的系统架构和工作流。用户基于 Siren 提供的 API Lib 提供其




图 2.14 Siren 系统架构和工作流。

模型代码包和数据集。上传至公有云之后，Siren 对任务进行初始化并开始运行。运行过程中每个 epoch 产生的数据将反馈给 Function Manager，然后 Function Manager 将上述数据反馈给强化学习调度器。调度器根据上述数据计算当前的 reward 并输出下一次决策的 action，并反馈给 scheduler，最终重新配置函数资源，开始下一个 epoch 的训练。与 L. Fang 等人的工作类似，Siren 也采用了基于共享存储的 PS 架构。

事实上，serverless computing 对 ML 的限制不仅仅在于网络通信，函数内部同样存在限制。例如，AWS Lambda 中，代码包的大小被限制到 250MB，运行时长被限制到 300 秒，运行内存大小限制到 3GB。Siren 采取了如下措施规避上述限制：1) 重新编译 MXNet，去掉 USE_CUDA, USE_CUDNN, USE_OPENMP 等并行选项，因为 serverless 函数可以成千上万的并发，因此 Siren 追求的是函数级别的并发，而非函数内部进程级别的并发；2) 每一个 epoch 由调度器重新分配一次函数，这与强化学习的 reward-action 机制也相符合。

Siren 的经济高效是由其强化学习调度器所决定的。该调度器接受每个 epoch 结束后的函数状态作为输入设计 reward 函数，并进行下一次调度。图 2.15 展示了 Siren 的强化学习调度器的决策流程。关于其强化学习算法的细节设计此处不再赘述，亦非本报告所关注的重点。

整个 ML 模型产出的周期中不仅包含模型训练，还包括数据预处理、超参数调整等。在 serverless computing 的环境下支持一站式的 ML 工作流，如下两个问题可能会




图 2.15 Siren 中强化学习调度器的工作流程。

得到解决：

1. 资源超配。在 ML 的整个工作流中，资源利用率实际上变化是十分剧烈的。在以 VM 为计算设施的环境中，开发者为了能够性能，通常会按照整个工作流中的资源利用率峰值来配置和获取资源，这无疑造成了严重的资源浪费。而 serverless computing 拥有优秀的弹性，能够根据工作负载的实际强度为用户配置合适的资源，从而可能解决这类资源超配问题。

2. 透明的资源管理。一般而言，专业的机器学习从业人员并不具备熟练的系统配置与优化技能。因此，现有的基于 VM 的环境配置方案，特别是在分布式场景下，为开发人员施加了很大的压力。因此亟需一直透明的资源管理方法，对于 ML 从业人员而言，其只需关注模型相关的算法代码，其余应该交由系统完成，这与 serverless computing 产生的初衷是类似的，serverless 的计算模型有解决此类问题的天然土壤。

J. Carreira 等人 [62] 在 2020 年提出了 Cirrus，一个基于 serverless 的支持一站式 ML 工作流的框架。其支持了数据预处理、模型训练、模型调优等 ML 工作流中的关键阶段，并为用户提供了友好的 FaaS 风格的 API。与前两个工作类似，Cirrus 也采取 PS 模型作为整个系统的基础框架。图 2.16 描述了 Cirrus 的系统架构。所不同的是，Cirrus 实现了自己的数据存储系统 Data Store。

Cirrus 中的 Data Store 是在云 VM 上实现的，其支持 key-value 的存储接口，例如 set/get，和常用的 PS 架构接口，例如 push/pull 参数。其设计时通过如下几个优化，使得该存储系统实现了高并发、低延迟、高吞吐：

1. 多线程服务器设计。为了达到高吞吐量，Cirrus 的 Data Store 充分利用的多线程的优势，将负载分布在不同的 CPU 核上。实验证明，这样的设计增加了 30% 的吞吐量。




图 2.16 Cirrus 系统架构。

2. 数据压缩。为了减少网络传输的数据量, Cirrus 的 Data Store 在 get 或者 set 时, 都会将需要传输的数据进行预先压缩, 这样一来所传输的数据就会大幅减少。实验证明, 这样的设计将数据传输量减少了 50%。

3. 传输稀疏数据。Cirrus 在传输参数和模型数据时, 只传送那些修改了的数据条目, 也就以稀疏数据的形式进行传输。实验证明, 这样的设计将数据传输量进一步减少了 90%。

Cirrus 屏蔽了底层设计的复杂性, 向上对用户提供简洁的 python 接口, 图 2.17 展示了数据预处理、模型训练和超参数调整阶段 Cirrus 需要用户编写的代码示例。

```

import cirrus
import numpy as np

local_path = "local_criteo"
s3_input = "criteo_dataset"
s3_output = "criteo_norm"

cirrus.load_svmlight(local_path, s3_input)
cirrus.normalize(s3_input, s3_output,
                 MIN_MAX_SCALING)

params = {
    'n_workers': 5,
    'n_ps': 1,
    'worker_size': 1024,
    'dataset': s3_output,
    'epsilon': 0.0001,
    'timeout': 20 * 60,
    'model_size': 2**19,
}
# learning rates
lrates = np.arange(0.1, 10, 0.1)
minibatch_size = [100, 1000]

gs = cirrus.GridSearch(
    task=cirrus.LRRegression,
    param_base=params,
    hyper_vars=[ "learning_rate", "minibatch_size"],
    hyper_params=[lrates, minibatch_size])
results = gs.run()

(a) Pre-process                               (b) Train                                     (c) Tune

```

图 2.17 Cirrus 用户接口 API 示例。

以上述三篇工作为代表, 从 18-19 年的架构和调度算法的优化, 到 20 年开始研究实

现 serverless 专用的共享存储系统，可以看出，学术界正在一步一步深入推动 serverless computing 在 ML 系统中的应用。FaaS 风格的 ML 系统也确实解决了配置难、超配造成资源浪费等常见的问题。

2.3.3 基于公有云服务的模型部署系统

在 ML 的工作流中，训练和调参一旦结束，就意味着产出了可以对外提供服务的模型。接下来这些模型就需要被部署到云端，为用户或者其它开发者提供服务。这类服务在日常生活和科研中是非常常见的。例如，百度提供的看图识花服务，用户只需上传一张图片，便可以得到这是何种花，甚至模型在某些情况下还会给出属于不同种类花的概率。如何将这些模型在线上部署，并且快速对用户的请求做出响应，便是模型部署系统需要解决的问题。

公有云中存在着多种多样的资源可以用来部署模型，例如 IaaS 和 FaaS，都提供了部署模型的能力。其中 IaaS 中的 VM 还可以按照收费方式分为按需实例、预留实例和抢占实例等种类。和模型训练/调参类似，模型部署也同样需要考虑性能和成本两个角度。首先模型的在线服务也属于一种 service，所以其在大多数情况下都存在对该 service 的质量要求，即服务等级目标（Service Level Object, SLO）。例如，一个 SLO 的典型例子便是要求至少 95% 的请求需要在 100ms 内完成响应。因此，在云环境中对于模型部署系统的研究一般都集中在一个问题上，即如何在保证模型服务的 SLO 的前提下，尽量降低成本。

A. Harlap 等人在 2018 年提出了服务部署系统 Tributary[63]。与其前作 Proteus 类似，Tributary 也同样充分利用了云市场中的动态资源，例如 AWS 的 Spot Instances。和 Proteus 类似，Tributary 也采用了基于 LSTM 的价格预测模型，预测接下来一段时间内资源池中的所有实例在运行该服务时的潜在花费，并在其中选取最优实例。和 Proteus 相比，实际上是一种更为简单的场景，因为 service 本质上是一种无状态的负载，在动态实例启停时，无需考虑对先前状态的保存和恢复。

Tributary 虽然利用云上的资源开发的模型部署系统，但仍然没有逃离传统的基于 IaaS 资源部署服务的模式。D. Crankshaw 等人在 2017 年提出了 Clipper[64]，一种基于容器技术的模型部署框架。如图 2.18 所示，Clipper 将整个部署系统抽象应用层、模型选择层、模型抽象层以及模型框架层。其向下兼容了 tensorflow, spark 等主流机器学习框架，向上为用户提供统一的 REST API。Clipper 还采用 adaptive batching 的技术，动态调整模型推断过程中 batch size 的大小，使系统的性能达到最优。

在 Clipper 的基础之上，C. Zhang 等人在 2019 年提出了 MArk[31]，一种基于多种云资源混用的模型部署系统。其充分研究了公有云上不同类型资源的特点和差异性，包




图 2.18 Clipper 系统架构图。

括常规的 VM，容器服务，动态 VM，突发型 VM，以及 GPU 型 VM，以便指定相应的算法，在合适的场合使用合适的资源。这里对突发型的 VM 实例，即 Burstable Instances 做简单介绍。该种类型的实例 CPU 能力在平时维持在一个性能较低的水平，但是用户可以令其在特定时刻以较高的性能维持一段时间。一般而言，该种类型实例的价格比按需型实例要低很多。

其经过一些列的实验，C. Zhang 等人得出如下四条结论：1. 基于 VM 进行模型部署可以达到最优的花费和最优的性能，但是难以处理突发的增量请求。如果将其与 FaaS 服务相结合，或许可以解决上述问题。2. 突发型的实例可能可以应对突发的请求。3. 在按需型实例中，比较小的实例性价比更高，虽然和大型的实例相比其响应延时也要更高。4. 只有将请求进行适当的打包批量处理，才可能发挥 GPU 型实例的优势，使其响应延时和花费优于 CPU 型的实例。

基于上述四条观察，作者提出了 MArk。图 2.19描述了 MArk 的系统架构。其后端将多种云资源视作潜在的资源池，根据负载的动态变化和 SLO 的具体要求来进行资源选择和配置。MArk 的资源配置策略可以概括为如下 3 条，其细节本文不再详述。

1. 确定最佳的 Batching 参数。在 GPU 实例上进行 Batching 可以达到较好的服务质量且较优的花费，但是 Batching 的两个重要参数，batching 队列长度和 batching 等待时间，却需要精心调整。作者根据公式 2.4，辅以线下性能建模的方式，来确定最佳的参数选择。

$$\begin{aligned} W_{batch} + T_b &\leq RT_{max}, \\ W_{batch} + T_b &\leq \frac{b}{\mu_{nb}^*} \end{aligned} \quad (2.4)$$

2. 使用 Lambda 和 Burstable Instances 应付突发的请求。虽然使用 VM 来进行模型部署能达到最优花费和性能，但是 VM 的启动时间过长，在请求数量突然增多时，难以快速横向拓展来进行应对。Lambda 具有较短的启动时间和较强的横向拓展能力，可以用来处理突发请求，当扩容的 VM 启动之后，再将流量导向新增的 VM 实例。同时 MArk 还预先启动了若干单价便宜的 Burstable Instances，当请求增多时，也可以将流量暂时导向这些实例，以利用其短暂的 CPU 峰值性能。具体在上述两种方案之间如何选择，就依赖于 MArk 根据具体的负载曲线和这两种方案产生的花费多少来进行权衡。




图 2.19 MArk 系统架构图。

2.3.4 基于 FaaS 的模型部署系统

FaaS 最常用的使用场景就是服务的云端部署，从这个角度来讲，不考虑 serverless computing 本身的若干缺点，纯 FaaS 的模型部署方式几乎是最理想的。尤其是从 ML 用户的角度而言，一旦模型完成训练和调参，用户只需将模型文件上传到云端，并声明相应的 API，即可完成模型的部署，至于弹性伸缩则交由后端的云商来做即可。

V. Ishakian 等人 [65] 在 2018 年在 AWS Lambda 上基于 MXNet 测试了若干模型对外提供服务的能力。其结论可以用一句话来概括：在热启动的前提下，利用 serverless 服务进行模型的在线部署是可行的，无论性能还是花费都可以接受，但是第一次请求会因为冷启动造成非常明显的高延时。Ishakian 等人测试的主要是图像分类相关的模型，而 Z. Tu 等人 [66] 在 2018 年针对自然语言处理的模型在 AWS Lambda 进行的相关实验。图 2.20 展示了在 AWS 的云环境中部署 NLP 模型的示例。如图所示，除了 Lambda，该系统还用到了 AWS 的云数据库服务 DynamoDB 来存储词向量。模型部署之前用户先将训练得到的词向量上传至云数据库中，在实际对外提供服务时，Lambda 会按需从 DynamoDB 中获取相关的词向量。然而在这种系统设计中仍然存在两个问题。首先，冷




图 2.20 NLP 模型在 AWS 云环境的部署。

启动的问题仍然没有解决。其次，由于 Lambda 没有本地的词向量缓存，在请求频率比较高的场景下，云数据库的延时和吞吐率难以满足服务的 SLO。

因此，现有的公有云上以 AWS Lambda 为代表的 FaaS 服务难以直接应用于模型部署。然而 FaaS 只是一种云资源的使用模式，并非于某个云厂商绑定，学术界也开始更多的探索更为先进的 FaaS 架构。F. Romero[67] 等人在 2019 年提出 INFaaS，一种 model-less 的模型部署系统。该模型部署系统假设用户对一个服务有两个维度的需求，即准确率和延迟。例如，某个图像识别的用户可能要求模型能够以不低于 95% 的识别准确率在 200ms 内输出识别结果。对于不同的用户和不同的场景，这样的 SLO 是不尽相同的。F. Romero 等人注意到，同一任务的不同模型变体在模型效果和延迟上存在很强的多样性，可能可以用来满足不同场景下的需求。例如，对于图像分类任务，VGG16 和 Resnet50 都是常用的模型，但是两个模型在准确率和延迟方面各不相同，VGG16 准确率稍低，但同时延迟也比较低，Resnet50 则与相反。图 2.21 就反映了模型的多样性。

为了满足不同场景下用户的不同需求，F. Romero 等人提出了 INFaaS，根据用户的 SLO 要求在不同的模型变体之间进行选择并对用户的请求做出响应。如图 2.22 所示，INFaaS 的工作流程如下：1) 用户对前端发出请求，而后前端的 Dispatcher 根据用户的 SLO 需求选取当前最合适的模型，并将其反馈给 worker；2) worker 将模型从 model repository 中取出来，并派发到相应的执行器上（一般而言是 CPU 或者 GPU）进行执行；3) 模型推断结果经过前端返回给用户。Metadata Store 用以存储每个模型变体的特征，例如该模型的资源消耗情况、准确率和延迟等等。Model Repository 负责存储模




图 2.21 左图为 158 个图像分类模型的峰值内存利用率、延迟和准确率；右图为这 158 个模型中延迟小于 50ms 的模型。

型，在 INFaaS 中是使用纯内存的方式实现的。同时，开发者还可以向 INFaaS 注册和提交新的模型，提交之后的模型会先由 Variant-profile 对其进行采集相关特征，并存储到 Metadata Store 中。




图 2.22 INFaaS 系统架构图。

值得一提的是，INFaaS 称其模型部署方式为 model-less 的，并不意味着模型（即 model）在其系统中不存在。和 serverless 中用户无需关注后端服务器类似，model-less 意味着用户无需关注其请求到底是由系统中的那个模型变体实际为其服务的。事实上，可以认为 model-less 是更上一层的 serverless 的部署方式，因为用户不仅不需要关注后端到底存不存在服务器，甚至都不需要关注后端的模型到底是什么。

上述工作关注的都是较小的模型（即单个 Function 实例可以容纳下的模型）。然而

随着算法的迭代发展，效果较好的深度学习模型动辄数 GB 甚至数 10GB，FaaS 实例的内存和磁盘空间难以容纳。近年也有学者探究如何利用 FaaS 部署大型模型。M. Yu 等人在 2021 年提出了 Gillis [68]，试图通过模型并行的方式在 FaaS 环境下部署大型模型。




Fig. 3: A workflow overview of Gillis.




Fig. 4: The fork-join model for function coordination.




Fig. 5: An illustration of branch merging, where two parallel branch modules are merged into one layer.

图 2.23 Gillis 系统架构图。

图 2.23 展示了 Gillis 的工作流及其 fork-join 模型。Gillis 是一个基于模型分割的 FaaS-ML 部署系统，旨在支持大型模型在 FaaS 环境中的 serving。Gillis 中的 server 和 worker 同样是函数实例。不同的是，在每次 request 响应之前，其会将模型分割为多个碎片，分布在所有 worker 实例上。在一个调度周期结束后，Gillis 会根据当前的系统状态，通过强化学习模型决定下个调度周期的模型分割策略，使性能逐渐趋向于最优。很显然，Gillis 遵循了前文所述的两种范式中的模型并行范式。

从基于云上 VM，到多种服务混用，再到纯 FaaS，公有云上的模型部署正在一步一步地向简洁高效发展。从云的角度理解，这是一种云原生的发展方式，即云上的模型部署依赖于云本身的能力，生在云上长在云上，将弹性伸缩、容错、高并发等工作交由云商或者第三方服务来做，开发者或者用户只需要关注与业务本身相关的代码逻辑，即“将麻烦留给云商，将方便带给用户”。

2.4 小结

本章按照机器学习模型开发的工作流的顺序，即模型开发与调试-模型超参数调整-模型部署，介绍了面向人工智能的云计算系统软件当前的研究现状。首先介绍了公有云厂商机器学习系统的范式 PS Model，以及一站式机器学习系统的代表 AWS Sage-maker。Sagemaker 支持从训练到部署的全部工作流程。其训练过程中使用了流行的 PS Model，并为模型训练和调参设计了统一的用户 API，用户只需要编写几个函数并定制几个规则即可让 ML 模型的训练和调参在云端自动展开。然而生产环境中的复杂

需求也催生了一批基于云服务的第三方机器学习模型训练和调参系统，这些系统充分利用云资源类型和计费方式上的多样性，使机器学习任务在云上经济高效地运行。对于部署阶段亦是如此，模型部署方式正在经历 VM-混合-FaaS 的模式转变。未来基于 FaaS 如何对模型部署进行更好地支持，将持续成为工业界和学术界的研究热点。

第三章 云环境中的新硬件为人工智能带来的机遇与挑战

随着硬件技术的不断发展，云环境中支持机器学习任务的硬件也从单一的 CPU 变成了 CPU、GPU、FPGA[69]、TPU[70] 以及 SGX[33] 等多种新硬件。利用这些新硬件，可以给机器学习任务带来一定增益。例如 GPU、TPU 和 FPGA 等加速型硬件的 SIMD 计算模式天然适合 ML 这种迭代式、大批量的负载，从而可以大大加速 ML 训练。而诸如 SGX 等新型安全硬件让机器学习安全有了从硬件层面得到解决的可能性。

而新硬件为 ML 任务带来机遇的同时，也带来了一定的挑战。例如，在公有云共享资源池的背景下，如 GPU 和 FPGA 等新兴加速硬件没有成熟和系统的虚拟化方案，用户的使用这些硬件的模式仍然以独占为主。即便是共享，也没有成熟的隔离机制保证性能以及用户之间不会相互干扰。再比如，SGX 加持的安全计算环境中，可信内存的大小十分有限，如何在有限的资源下支持可信的模型部署甚至模型训练，是亟待解决的问题。

本章将以加速型硬件 GPU 和安全型硬件 SGX 为代表，介绍云环境中异构硬件为机器学习任务带来的机遇与挑战。

3.1 云环境中机器学习作业对 GPU 的利用

本节将先对 GPU 的现状做简要介绍，包括现代 GPU 的架构以及常见的 GPU API 和编程模型。然后，本章将从两个角度展开当前学术界针对 ML 任务对 GPU 的利用的研究：1) One Job on Multi GPUs。即一个 ML 任务需要多个 GPU 设备。这种情况一般出现在大型模型的分布式训练中。在一个大规模 GPU 集群中，不同的训练任务对 GPU 数量的需要可能不一样，如何对这些任务进行调度，使系统的资源利用率最高，同时保证训练任务的性能，是学术界研究的重点问题；2) Multi Jobs on one GPU。即在同一个 GPU 设备运行多个 ML 任务。这种情况在资源短缺或多租户的场景下较为常见。

3.1.1 GPU 简介

3.1.1.1 GPU 架构

GPU，即 Graphics Processing Unit，采用了与传统的多核处理器完全不同的架构[71]。GPU 的设计围绕和让吞吐率最大化这一原则，提供了上千个简单的计算核心和高带宽内存。这样的实际使得 GPU 能够使一个应用程序拥有很高的并行度，从而使程

序的吞吐率最大化。理想情况下，对于一个 GPU 应用程序，其包含的若干线程应该分别对应其数据空间的不同位置，而彼此之间由没有因果关联，从而可以并发地执行。与之相反，传统的处理器是为了能更快地执行线性的代码段而优化的。因此其单个核心的复杂度非常高，且单个处理器中的核心数量相对较少。且传统的处理器一般会使用复杂的控制逻辑和较大的本地缓存以处理传统程序中常见的条件分支、上下文切换以及较差的数据本地行。

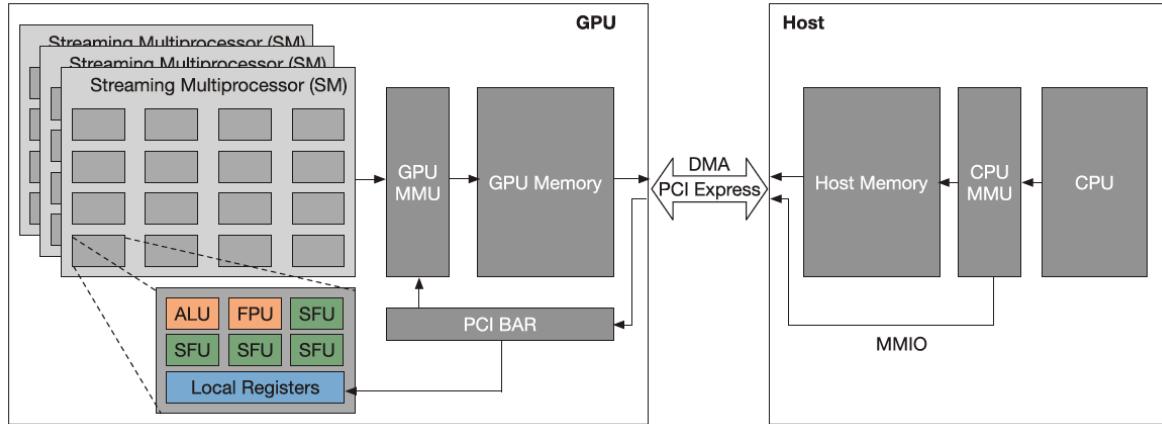


图 3.1 GPU 系统架构。

图 3.1 展示了一个典型的 GPU 系统的架构。图中的 GPU 部分是根据 Fermi 架构的 Nvidia GPU，但是现代的 GPU（例如新一代的 Nvidia GPU 和 AMD GPU）也遵循类似的设计。一个 GPU 拥有多个流式处理器（streaming multiprocessor, SM），每一个 SM 拥有 32 个计算核心。每个 SM 也拥有 L1 数据缓存和低延迟共享内存。每个计算核心拥有本地的寄存器、一个整型计算单元（Integer Arithmetic Logic Unit, ALU）、一个浮点计算单元（Floating Point Unit, FPU）以及若干特殊函数单元（Special Function Units, SFU，用来计算特定的函数值，例如正弦函数 sine 和余弦函数 cosine）。GPU 的内存管理单元（MMU）为 GPU 程序提供虚拟地址空间。MMU 会根据应用程序的页表，会将一个 GPU 地址解析为物理地址。

Host 通过 PCIe 高速通道与 GPU 连接。Host 上的 CPU 通过内存输入/输出映射（MMIO）与 GPU 进行交互。GPU 寄存器以及设备内存可以被 CPU 通过 MMIO 接口直接获取。此外，量比较大的数据交换可以通过 DMA（Direct Memory Access）实现。DMA 可以将数据在设备内存和主机内存之间快速传输。

3.1.1.2 GPU API 和编程模型

常用的 GPU API 和编程模型包括 OpenGL[72], Direct3D[73], CUDA[74] 和 OpenCL[75] 等，在游戏开发、图像处理、高性能计算等场景下非常常用。

OpenGL 是一个利用 GPU 硬件加速图形处理的库，通常应用于电子游戏、图像处理以及科学计算中的数据可视化。OpenGL 实现了一个硬件无关的 API，兼容适配不同的底层硬件。

Direct3D 是由 Microsoft Windows 提供的图形库，通常在一些性能敏感的场景中（例如电子游戏）负责图形渲染工作。Direct3D 同样实现了硬件无关的 API，并且向用户暴露了能够使用 GPU 高级特性的 API，例如 Z-buffering，W-buffering 等。

CUDA 是由 Nvidia 提供了专为 Nvidia GPU 适配的并行加速库。CUDA 允许开发者在 GPU 上利用高并行的特点开发特定的程序，这种情形下的 GPU 被称为 GPGPU (General Purpose GPU)。CUDA API 是与编程语言高度绑定的，例如 C 和 C++。当前流行的机器学习框架，例如 Tensorflow 和 Pytorch，在存在 GPU 设备的环境中，都支持利用 CUDA 对其模型训练进行加速。

OpenCL 也是一个并行加速库，其基础功能和 CUDA 类似，最大的区别在于 OpenCL 可以被应用于非 Nvidia 的 GPU。

3.1.2 One Job on Multi GPUs: 机器学习集群中的 GPU 调度算法

事实上，传统集群中的调度算法例如 FCFS (First-come, first-served)，Round-robin，Priority-based，Fair queuing[76] 等经典算法，在 GPU 集群中仍然适用。这些算法简单地将 GPU 看作一种新的资源单位，并将提交到该集群中的作业调度在其上。

随着深度学习的兴起和快速发展，在计算机视觉、自然语言处理等领域使用的模型参数越来越多，规模越来越大。而对于大规模的深度学习模型，分布式训练 +GPU 硬件加持几乎成为了标配。分布式训练的场景中，GPU 之间的数据传输时有发生。然而在一个多 GPU 的集群环境中，位于整个系统拓扑结构不同位置的 GPU 之间的数据传输速度是有很大差异的。因此，仅使用传统的的调度算法，而不考虑 GPU 设备之间的拓扑结构，很可能会造成糟糕的调度结果，从而严重影响作业性能。

图 3.2 展示了两个 GPU 服务器中 GPU 的和其它硬件之间的拓扑结构图。左图为 IBM 的 Power8 服务器，有两个 CPU 和四个 GPU。右图是 NVIDIA 和 DGX-1 服务器，有两个 CPU、四个 PCI-e 桥接器和 8 个 GPU。绿色的线、蓝色的线和黑色的线分别代表 NVLink[77]、PCI-e 和 Intel 的 QPI 三种连接方式，数据传输速度由快到慢。位于同一个 CPU socket 下的两个 GPU（例如左图中 GPU1 和 GPU2）之间的数据传输可以通过 NVLink 进行，是最快的。位于不同 CPU 上的 GPU，只能通过 PCI-e 通道和 QPI 通道进行通信（例如左图中的 GPU1 和 GPU3、右图中的 GPU1 和 CPU）。而如果位于两台不同服务器上的 GPU 之间需要通信，则除了需要经过上述数据通路之外，还要经过网络传输，即使是万兆网（10Gbps），也要比上述传输方式慢约一个数量级。

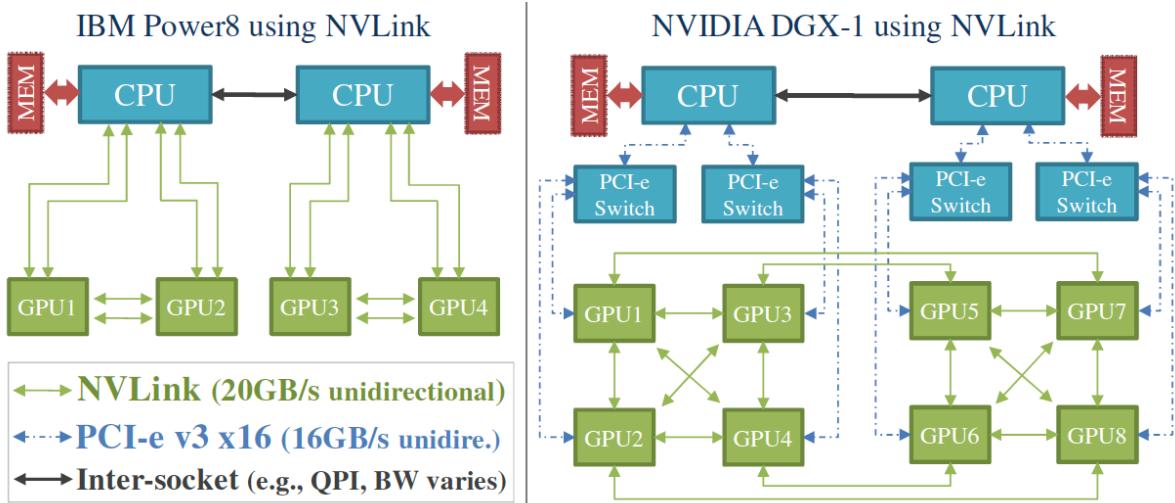


图 3.2 GPU 拓扑结构示例。

因此，在 GPU 集群中调度分布式 ML 训练任务时，需要充分考虑 GPU 之间的拓扑结构，否则可能会造成严重的性能损失。图 3.3 展示了 GPU 调度的两个例子和与其对应的四种调度方案。上面的两张图对应了 P2P（即两个 GPU 之间需要互相通信）的场景中的两种调度方案，显然右边的方案是更优的方案，因为分配到的两个 GPU 位于同一个 CPU socket 上，于左边相比其数据通路具有更高的传输速率。下面的两张图对应了不当分配可能造成的性能干扰。显然，右边的分配方式也是更优的方式，因为左边的分配方式造成了两个 Job 在数据传输时共用同一条数据通路从而造成竞争，使性能降低。

M. Amaral 等人 [78] 在 2017 年提出了一种云环境下基于 GPU 拓扑结构的调度方法。其将 ML 任务和集群都抽象成图的形式。在 ML 的任务图中，图的节点为 GPU，节点之间的边代表两个 GPU 之间存在数据交流。任务图中的边没有权重。在集群的图中，图的节点为 CPU，GPU，PCI-e 桥接器，CPU socket 或者网络交换机。不同节点之间的连线代表这两个节点之间可以相互通信，连线的权重代表通信速度，数值与越小通信速度越快。图 3.4 表示了图 3.2 所对应的拓扑结构图。

M. Amaral 等人通过对两个图进行匹配并最小化公式 3.1 中的目标来实现 GPU 的调度，其中 $\alpha^{cc} + \alpha^b + \alpha^d = 1$ ， t 、 I 和 ω 分别代表 GPU 之间的通信代价、来自外部的资源干扰和资源碎片化程度，分子代表实际的值，分母代表最坏情况下的值。该公式旨在综合考虑减小 GPU 之间的通信代价、降低不同任务之间的干扰以及使整个系统的碎片化尽可能降低，使整个集群处于一个相对最佳的状态。

$$\text{MIN } \alpha^{cc} \frac{t^{cc}}{t_w} + \alpha^b \frac{I^b}{I_w} + \alpha^d \frac{\omega^d}{\omega^w} \quad (3.1)$$




图 3.3 GPU 调度示例。

M. Amaral 等人的工作综合考虑了多项指标，以使得集群达到一个最优状态。在这样的集群中，所有的任务都被视作拥有同样的优先级。因此，可能存在集群中常见的长尾问题。图 3.5 就描述了这样一个场景。租户 A 和租户 B 都需要使用 GPU，然而由于调度问题，虽然集群中还剩余 4 个 GPU，却无法分配给 B。这种情况被称之为调度过程中的异常（anomaly）。

H. Zhao 等人在 2020 年提出了 HiveD[79]，使用 Virtual Private Cluster 的概念和伙伴算法（即 Buddy Cell 算法）来解决调度中的异常。HiveD 中将任务分为两类：高优先级的需要保证资源的任务和低优先级的尽可能用“机会性资源”来提升集群资源利用率的任务。其使用的伙伴算法在 Linux 内核中的内存管理模块中也是常用的算法。图 3.6 表达了 HiveD 中两类任务中不同的资源视角。HiveD 中将 GPU 按照连接方式划分为不同级别的 Cell，如图中单个 GPU 称为 Level 1 的 Cell，位于同一个 CPU socket 上的两个 GPU 称为 Level 2 的 Cell，位于同一 CPU 下的四个 GPU 称为 Level 3 的 Cell，位于同一台服务器下的八个 GPU 称为 Level 4 的 Cell，位于同一机架上的不同服务器上的 GPU 集合称为 Level 5 的 Cell。HiveD 假设任务对于 GPU 需求都是与某一个 Level 的 Cell 中的 GPU 数量匹配的，其基本算法思路如下：当有一个任务需要一个 Level k 的 Cell 时，先查看系统中有无现有空载的 Level k 的 Cell，如果没有则将一个 Level k+1 的 Cell 分裂为两个 Level k 的 Cell，如果再没有则继续向上一层 Cell 请求分裂，直到存在空载的 Cell 为止。同时，如图 3.6 所示，高优先级和低优先级的任务视角中，资源的使用情况是不同的。如果一个 Cell 被高优先级的任务占用，则在低优先级任务的视角中，这个 Cell 被标记为“已使用”，不能被抢占。反之，低优先级任务占用的 Cell 在高




图 3.4 GPU 拓扑结构图。

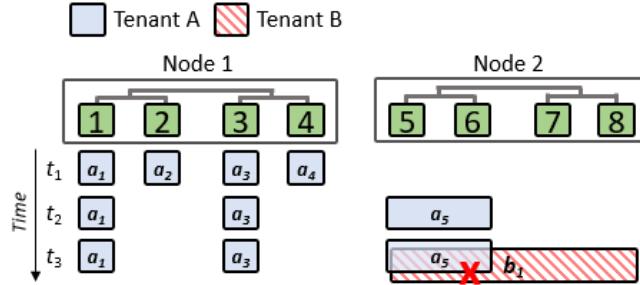


图 3.5 GPU 集群中的调度异常：一个任务被阻塞。

优先级任务的视角中被标记为 **dirty**，在必要的情况下可以抢占其使用。

总体而言，与传统的集群资源调度其类似，以 GPU 设备为最小调度单位的系统调度器中，首要的目标是保证集群的吞吐率，即单位时间内处理任务的数量。近年的做法都是基于 GPU 之间的互联情况对 GPU 设备（组）进行分类，进而使用各种算法使任务的需求与系统当前的状态匹配，达到降低任务运行时间、提升系统吞吐率的目标。在此基础上，在一些碎片化的资源上部署一些低优先级的作业，可以进一步提升系统的资源利用率。

3.1.3 Multi Jobs on one GPU: 机器学习集群中的 GPU 共享机制

除了以单个 GPU 为单位，在真实的业务场景中也存在多个任务共享同一个 GPU 的需求。该需求出现于云计算刚刚兴起的早期，即如何对 GPU 进行虚拟化。常用的应将资源例如 CPU，网络和存储等都有非常成熟的虚拟化方案。以 CPU 为例，常见的虚拟化一般可以分为虚拟机和容器两大类。虚拟机有着比云计算更悠久的历史。IBM 公

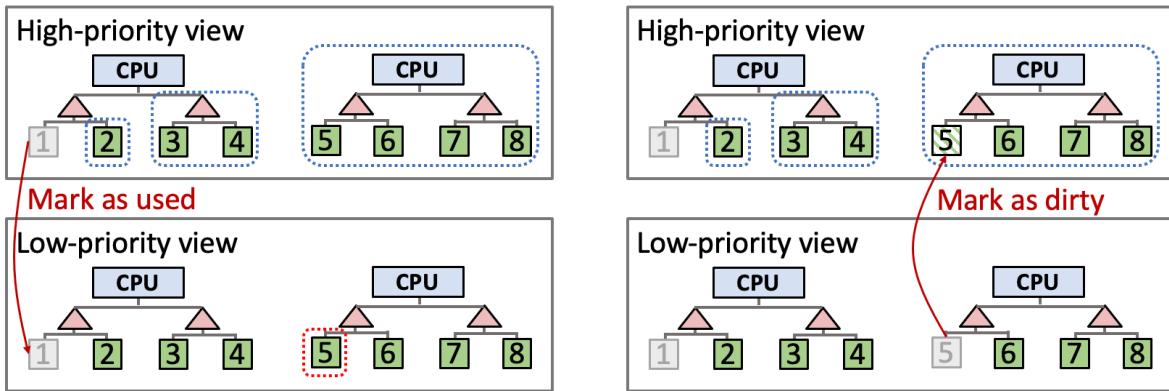


图 3.6 HiveD 中的两种视角。

公司在 1970 年阐述了其最原始的虚拟机系统设计 [80]。在 1972 年，虚拟机第一次在 IBM 公司的大型机上出现。通过 IBM VM370 系统能够将一台大型机分为可独立运行操作系统的多台虚拟机。在计算虚拟化技术中，原本的物理计算机被称为宿主机（Host），运行在宿主机之上的虚拟机被称为客户机（Guest）。虚拟机技术的核心是 VMM（虚拟机监控器 Virtual Machine Monitor 或者虚拟机管理器 Virtual Machine Manager），也被称为 Hypervisor[81]。容器是进些年来更受关注的轻量级虚拟化技术。与虚拟机技术不同，容器并不对 CPU 指令以及硬件设备进行虚拟化，它是一种操作系统级的虚拟化技术。容器通过操作系统内核提供的功能，来实现不同用户进程的资源隔离与访问隔离，形成一个个独立的运行时环境，即“容器”。

云计算的兴起离不开虚拟化的发展。当前，主流的云厂商例如 AWS, Google Cloud 等，都同时提供了虚拟机服务和容器服务。这些服务基于对计算资源（主要是 CPU）、网络资源（带宽、虚拟网络）和存储资源（虚拟云盘）的虚拟化，支持用户在虚拟计算环境中独立且互不干扰地运行各种负载。然而 GPU 作为现今一种重要的计算资源，却始终没有一种统一的、完善的虚拟化方案应用于公有云环境，而是在不同的业务场景中存在不同的虚拟化方案。

根据实现方式的不同，当前 GPU 的虚拟化大致可以分为三类 [71]:

1. API 转发。这种方式在 GPU 架构的上层对 GPU 进行虚拟化。由于 GPU 的厂商一般不会开源 GPU 的驱动源码，因此在驱动层对 GPU 进行虚拟化是非常困难的。基于 API 转发的虚拟化实现方式类似于远程过程调用（Remote Procedure Call, RPC），即在虚拟机 OS 中实现一个 agent，该 agent 会截获应用程序所有对 GPU 的调用，并将相关调用转发到宿主机上的 GPU 设备上进行实际的执行，执行完毕后再返回给虚拟机 OS 中的应用程序。

2. 半/全虚拟化。这种方式在驱动层对 GPU 进行虚拟化（一般由厂商来实现），一

般会定制一个专门的 driver 安装在虚拟机 OS 中。与 API 转发相比，这种方式由 driver 直接调用宿主机的 driver API，不需要你 agent 的转发，从而缩短了调用链，使其性能更优。

3. 基于硬件的虚拟化。这种方式也称为 pass-through（译作直连），即赋予虚拟机直接访问宿主机设备的能力。这种方式产生的额外开销是最小的，但是一般而言隔离型比较差。

上述三种方式中，API 转发是学术界的工作最为常用的方法，无论是在基于虚拟机的环境中，还是在基于容器的轻量级虚拟化环境中。图 3.7 描述了虚拟机环境中基于 API 转发的 GPU 虚拟化的工作流程。




图 3.7 基于 API 转发的 GPU 虚拟化。

在容器环境中基于 API 转发的方式和上图类似。D. Kang 等人在 2017 年提出了 ConVGPU[82]，通过在 docker[83] 容器中安插一个 CUDA wrapper 来对一些与 GPU 显存相关的 API（例如 cudaMalloc, cudaFree 等）进行截获，并实现了一个管理全局显存分配的调度模块。如图 3.8，ConVGPU 实际上是以一个中间件的形式存在于容器环境中的。在正常的 API 调用路径下，插入一个显存管理的组件，在软件层面实现了 GPU 显存的共享和一定程度上的隔离。

而更多的 GPU 共享的解决方案是与具体的应用场景高度绑定的，尤其是在运行机器学习任务的集群中。W. Xiao 等人在 2018 年提出了 Gandiva[84]，主要面向深度学习集群中基于 GPU 的模型训练任务进行调度。有别于传统的 suspend/resume 机制，Gandiva 使用 grow/shrink 机制。图 3.9 表现了 Gandiva 的 grow-shrink 机制。Gandiva 中主要存在如下三种动作：1) grow。即当前如果存在空闲的资源，Gandiva 会让存在空闲资源的节点上的某些任务占用的资源拓展到空闲资源上，以提升系统的资源利用率和模型的训练速度（如图 3.9 中的 Gandiva:(3) Grow-shrink）。2) shrink。当系统中有新的训练任务到达时，Gandiva 一般不会将一个任务直接 shutdown，而是将其所占用的资源进

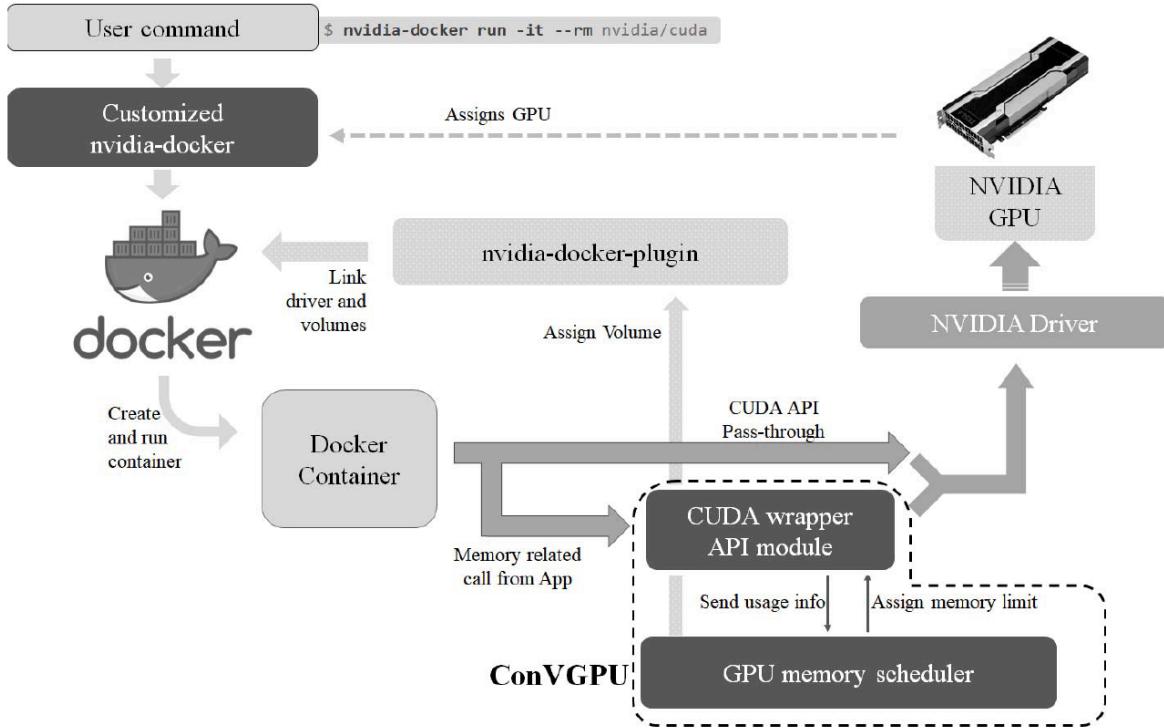


图 3.8 ConVGPU 架构。

行裁剪，腾出新的资源以供新的任务所用（如图 3.9 中的 Gandiva:(3) Grow-shrink）。³⁾ migration。当系统其它节点中存在空闲资源时，Gandiva 会将一个非独占的任务迁移到该空闲资源上（如图 3.9 中的 Gandiva:(2) Migration）。值得注意的是，Gandiva 在实验中发现，深度学习任务的显存占用一般呈周期性涨落的趋势，其峰值显存占用率和谷值显存占用率差距非常大。因此其在迁移任务时会根据任务占用显存的变化趋势，在任务占用显存最小的时候对任务进行迁移，以降低迁移产生的额外开销。

事实上，Gandiva 中所提到的深度学习任务显存占用的周期性涨落趋势，也可以用来实现更细粒度的 GPU 共享。P. Yu 等人在 2020 年提出了 Salus[85]，使用快速任务切换和显存贡献实现 GPU 的共享。Salus 将显存分成多个 Lane，一个 Lane 中可以存在一个或者多个深度学习模型训练任务。由于深度学习模型训练任务都是周期性迭代的过程，Salus 调度的最小单位是任务的一个周期（在模型训练中通常体现为一个 batch）。图 3.10 展示了 Salus 的架构和一个调度示例。Salus 为常用的 ML 框架如 Tensorflow 和 Pytorch 定制了相应的适配器。对于用户的模型训练程序的每一次迭代周期，都会以一个 session 的形式提交到 Salus 的 session 管理器。Salus 根据提交的 session 的显存变化曲线，将 session 调度到合适的 Lane 中。然后调度器根据系统当前显存分配的状况，调度相应的 Lane 在 GPU 上执行。右图中即为一个例子，Job 1 和 Job 2 在显存变化曲线上存在明显的互补性，使得 Job 2 的波峰恰好可以将 Job 1 的波谷填满，因此 Salus 调

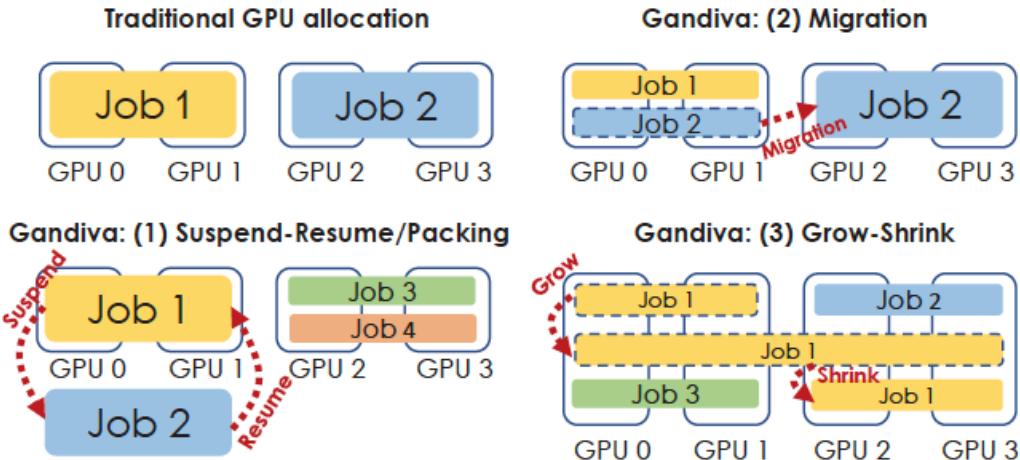


图 3.9 Gandiva grow/shrink 机制。

度其在同一个 Lane 上执行。

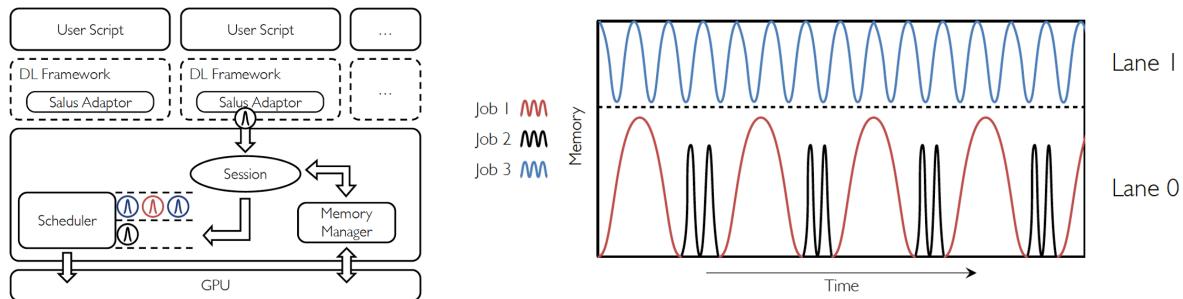


图 3.10 Salus 架构与调度示例。

除了模型训练中对 GPU 的共享之外，近年来也有学者开始研究模型部署阶段对 GPU 共享。D. Mendoza 等人 [86] 在 2021 年提出了一种干扰可感知的模型部署调度方法。该调度方法充分关注模型推断期间的系统指标，例如 CPU 利用率的变化曲线，设计模型学习不同的 ML 任务共同部署时对性能的干扰，进而将该信息应用到调度中，以提升共同部署的模型的推断效率。

3.2 可信执行环境技术的发展对机器学习任务的影响

能够安全可信地使用由第三方云厂商提供的计算服务是云消费者的重要需求。尤其是当前人工智能技术盛行，很多个人开发者、研究团队和中小型公司都有利用公有云算力训练机器学习模型的需求。但是这些用户需要将具有一定私密性的数据上传到云厂商，这在一定程度上是具有潜在的安全性风险的。因此用户需要以一种安全的方式对云资源进行利用。当前，能够满足这一需求的主流解决方案包括同态加密（Homomorphic Encryption）。

morphic Encryption) [87] 和可信执行环境 (Trusted Execution Environment) [88]。同态加密是一种密码学技术，可以对加密后的密文直接进行计算，并且计算结果解密后与明文计算的结果相一致。2009 年斯坦福大学的 C. Gentry 首次提出了通用的同时支持加法同态和乘法同态的全同态加密方法 [89]，在理论上证明了云计算资源安全使用的可能。用户可以将数据加密后在云端进行计算，然后将结果传输回本地进行解密，这样可以同时做到既依赖了云端的强大算力又保证了数据安全性。但由于该方案引入了巨大的计算开销，出于性能原因至今仍然没有得到广泛的使用。

可信执行环境是一种基于硬件的解决方案，其本质上相当于为用户提供了一种安全的沙箱环境。用户可以在可信执行环境中进行计算，并且能够得到机密性和完整性的保障，而包括 Hypervisor、操作系统、主机上可信执行环境以外的其他应用都没有权限读写可信执行环境中的数据，从而保证了用户使用云计算资源的安全性。代表性的可信执行环境实现包括 Intel 的 SGX 技术和 ARM 的 TrustZone[90] 技术。相比于全同态加密，这些技术有着更高的计算效率，近年来在云计算环境下有着强隐私保护需求的许多场景里得到了实际应用。因此，本节主要着眼于可信执行环境这种云计算资源在机器学习场景下的安全性利用方案，以 Intel SGX 技术为重点，对相关技术进行调研。

3.2.1 SGX 技术简介

可信执行环境是解决服务使用者与供应者之间信任问题的一种流行方案。在服务器端，英特尔软件保护扩展 (Intel Software Guard Extensions, SGX) 是目前最主流且被使用最多的可信执行环境技术，用于保护运行在不受信任平台上程序的机密性 (Confidentiality) 和完整性 (Integrity)，于 2015 年在 Intel Skylake 系列的 CPU[33] 中首次被推出。图 3.11 概述了 SGX 的简单特性。SGX 提供了被称为飞地 (Enclave) 的硬件安全沙箱，用于托管用户代码和数据，防止其被飞地外不受信任的特权进程（例如 Hypervisor 和操作系统）窃取或篡改。本章提出的解决方案基于 SGX 设计和实现。

截至 2021 年 3 月，SGX 包括两个主要版本，最初的版本通常被称为 SGX 1.0，另一个版本具有增强的特性，如飞地动态内存管理，被称为 SGX 2.0。由于 SGX 2.0 仅在有限的 CPU 系列上支持，因此本文只讨论 SGX 1.0，其已经包含了 SGX 核心的安全特性。SGX 技术通过一组 CPU 指令扩展和专用硬件架构来构建所谓的飞地。飞地里的代码和数据都运行在特殊的加密内存里，只有飞地里的程序运行在 CPU 里时才会对相应的代码和数据进行解密。因此，即使攻击者有机会接触到硬件，通过窥探内存 (Hardware Snoop) 的方式也只能看到加密后的信息。在一个飞地进行初始化之前，代码和数据保存在主机的非可信区域。同时，SGX 也无法保障飞地以外数据的安全性。因此，为了保护秘密，在使用 SGX 时，数据应该在飞地外进行加密，然后传输到飞地内解密后进

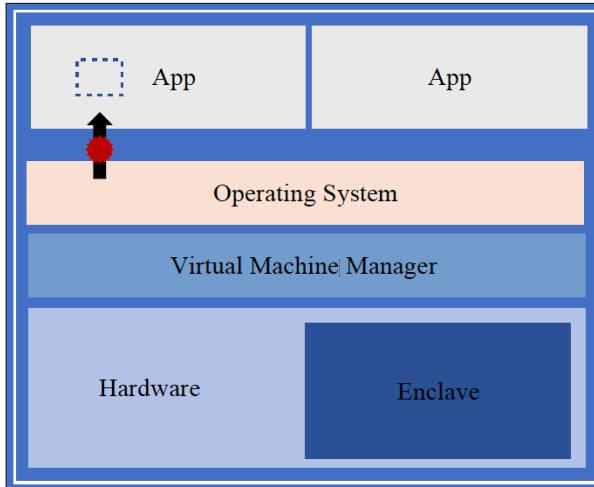


图 3.11 SGX 架构图。

行计算。

认证 (Attestation)：SGX 提供了认证机制，其功能是让用户可以验证一段已知的程序确实是运行在一台支持 SGX 功能的计算机的飞地里的。认证又包括本地认证 (Local Attestation) 和远程认证 (Remote Attestation)。本地认证使得一个飞地可以向运行在同一平台上的另一个飞地证明自己的身份。远程认证使得一个飞地可以向远程第三方实体证明自己的身份。SGX 提供了飞地度量值（即 MRENCLAVE 和 MRSIGNER 两个值）用来在认证过程中表明飞地的身份并验证飞地的完整性。

密封 (Sealing)：在飞地中运行的代码和数据是易失性的。密封是 SGX 提供的一种机制，用于将数据保存到持久化的非可信存储中，例如硬盘。在密封过程中，应用使基于可信执行环境的可信应用快速构建与支撑机制用密封密钥 (Sealing Key) 在飞地中加密数据。密封密钥只能由该应用的飞地程序获得，并且是从根密封密钥 (Root Sealing Key) 衍生而来的。根密封密钥则是硬件编码在 CPU 中，并且每一个支持 SGX 的 CPU 的根密封密钥都是互不相同的，这就决定了某一飞地在某台机器上密封的数据只能在该台机器上进行解密。

飞地页面缓存 (Enclave Page Cache, EPC)：飞地所驻留的特殊加密内存区域被称为 EPC。EPC 由专用硬件加密，禁止所有来自非飞地内存的访问。EPC 以 4KB 的粒度划分为页面进行内存分配。飞地在初始化时申请它需要的所有 EPC 空间，并且在分配之后不能动态修改。EPC 的总大小非常有限，在一台计算机上，SGX 飞地应用程序可以使用的 EPC 的大小是 128MB。在这其中，只有约 93.5MB 的大小可供用户程序和数据使用，剩余空间预留用来存储 SGX 相关的元数据。在当前的大数据时代，EPC 的空间过于稀少，并且单机上的 EPC 会被所有的 SGX 程序分享，这就导致每一个飞地实际可用的 EPC 空间就更小了。在服务器市场主流的 Linux 操作系统上，SGX 驱动支

持通过页交换技术来实现 EPC 超配，每个飞地实际可以申请超过 128MB 的内存使用。当 EPC 中没有空闲页分配给飞地使用时，SGX 驱动程序会基于缓存替换算法将 EPC 中的某些页面加密后放置到非加密的常规内存 DRAM 上去。当这些换出的页面在重新被需要使用时又会被换入到 EPC 中。因为换入换出页面时涉及到完整性校验等高计算开销的过程，因此会导致应用程序性能的显著降低。先前的工作表明，这种开销平均会使系统性能降低 5 倍 [91]。由于 EPC 很小，并且由运行在一台机器上的所有飞地竞争，因此可能会频繁地触发页交换。

SGX 应用程序开发：当前主要有两种方式来开发面向 SGX 的应用程序。第一种是基于功能划分的方式。使用这种方式来开发程序通常需要将整个应用设计为可信与非可信两个部分。敏感数据由运行在飞地内的可信程序处理，其他功能由飞地外的非可信程序完成。使用 Intel 原生 SGX 软件开发工具或如一一类的开源框架来编写软件是这类开发方式的典型代表。这类方式可以更有效地利用 EPC 资源，但需要付出较大的努力对传统非 SGX 环境下的留存应用进行重构。第二种方式是使用库操作系统（LibraryOS, LibOS）[92] 来进行开发。库操作系统通过实现应用所需的系统调用来支持在飞地内运行整个程序。这种方式为留存应用提供了更好的兼容性，对开发人员更加友好。目前主流的面向 SGX 环境设计的库操作系统包括 Haven[93]、Panoply[94]、Graphene-SGX[95] 和 Occlum[96]。

3.2.2 基于 SGX 技术的上层应用

首先在最基础的容器粒度上，S. Arnaudov 等人提出了一种基于 SGX 实现的安全容器 SCONE[97]。SCONE 对 SGX 进行了进一步的抽象来保护容器中的进程。其为开发者提供了 C 语言标准库接口来便利地开发基于 SGX 的应用程序。SCONE 的设计中系统调用在可信执行环境之外进行，但通过加密技术保证了可信执行环境之外的数据也是安全的。进一步地，为了降低在可信执行环境中进行线程切换的开销，SCONE 将操作系统线程映射为逻辑的应用线程，通过在应用线程间调度操作系统线程来最大化线程在可信执行环境中的运行时间。在易用性上，SCONE 兼容 Docker，对 Docker 用户是透明的。在 Apache、Redis、NGINX 等应用上的测试表明，SCONE 可以达到原生应用 0.6 至 1.2 倍的吞吐量。

SCONE 针对的是单机的容器环境，T. Hunt 等人则基于 SGX 技术设计和实现了面向分布式环境的可信计算中间件 Ryoan[98]。Ryoan 针对的是无状态、采用面向请求数据模型的应用，其提出了新的执行模型，对不可信代码模块施加限制，并严格执行防止机密泄露的 I/O 策略。Ryoan 可以使得互不信任的多个参与方能够在不受信任的平台上（例如云平台）以分布式的方式进行敏感数据的计算。Hunt 等人更进一步地基于 Ryoan

开发了包括图像处理系统、垃圾邮件过滤器在内的多个真实应用作为研究案例。

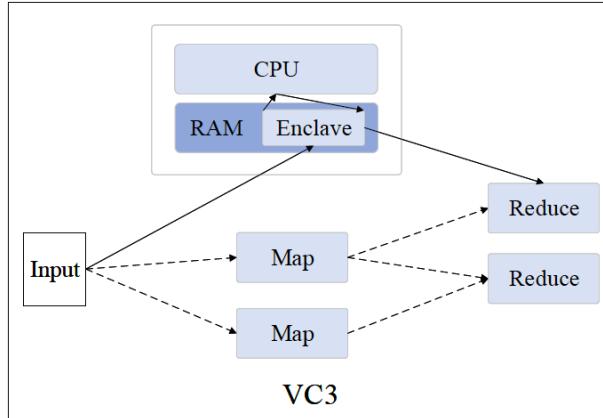


图 3.12 VC3 架构图。

SCONE 和 Ryoan 等都是基于 SGX 在系统软件这个层次所做的工作，用以帮助开发者更便捷地使用 SGX 技术。相比之下，VC3[99] 是更上层的工作，其基于 SGX 开发了一个可信的分布式数据处理框架，可以运行在未修改的 Hadoop 之上。图 3.12 阐述了 VC3 的设计理念：在 VC3 中，数据和代码（例如 Map 和 Reduce 程序）在可信执行环境之外都是加密的。VC3 解决了三方面的问题来使得这个数据处理框架具有实用性：首先，为了实现更轻量级的可信计算基，VC3 的设计只将核心的 Map 和 Reduce 函数运行在可信执行环境中；其次，可信执行环境只能保证单个 Map 或 Reduce 任务的完整性，为此 VC3 提出了专门的作业执行协议来保证整个分布式计算的完整性；最后，VC3 提供了新的编译器支持来防止不安全的内存访问。在通用测试基准数据集上的实验显示，相比于原生 Hadoop，实现“写完整性”保护和“读写完整性”保护的 VC3 仅额外产生了 4.5% 和 8% 的运行时开销。

3.2.3 集群中 SGX 资源的管理

可信执行环境技术的实现离不开新的硬件支持。换言之，在支持可信执行环境的计算机上，操作系统管理除传统的 CPU、内存、I/O 等系统资源以外，还需要管理新型的特殊硬件资源。以 Intel SGX 为例，其使用了一种特殊的被称为 EPC（Enclave Page Cache）的加密内存来运行代码和数据。以 EPC 为代表的新型硬件的出现给云原生共享集群的管理带来了挑战。共享集群通过让不同的分布式应用共享底层硬件资源来优化系统管理、提升集群资源利用率。“共享”意味着管理系统需要基于虚拟化等技术手段来对资源进行抽象和隔离，防止不同应用程序在共享硬件资源时因竞争而产生相互干扰，导致性能下降甚至是程序崩溃等问题。

对于传统的 CPU、内存、I/O 等硬件资源，当前的操作系统已具备成熟的机制（如

容器)对其进行隔离。共享集群管理系统也依赖于操作系统的这种能力来完成资源分配、变更和调度。但遗憾的是,当前的操作系统虚拟化和隔离可信执行环境所依赖的新型硬件资源的能力还较为有限,这给云原生共享集群在利用这些资源时带来了挑战。以现有的共享集群管理系统为例,YARN[100]尽管提出了容器的概念用以进行资源划分和分配,但那只是一种逻辑的抽象,在实际运行时,YARN并没有将任务封装在LXC、Docker之类的操作系统虚拟化容器中。在早期的版本中,YARN只对内存这一维度的资源进行限制。当YARN启动一个任务时,同时还会启动一个监控器对任务进程的内存消耗进行监控。当任务进程消耗的内存超过任务申请的内存时,YARN会将该任务终止。而对于如CPU之类的其他资源,尽管用户在提交作业时也会为每个任务指定申请的资源配额,但这些信息仅仅会被用来进行调度决策,YARN不会对这些资源进行限制。因此,一个指定了1个CPU核数的任务在机器较为空闲时可能会使用超过1个CPU核数的资源。随着时间的发展,在后续版本中,YARN引入了cgroups机制,通过cgroups实现了对CPU、I/O等资源的限制。

因为YARN启动任务就是启动进程,如果想在YARN中运行SGX任务,只需在集群节点上安装好SGX驱动程序等相关环境即可。但当前的YARN缺少接收任务使用EPC资源需求的接口,因此YARN在调度时不会考虑SGX作业需要使用多少EPC资源。进一步地,YARN缺乏隔离EPC的能力,因此调度到同一台机器上的两个SGX程序会竞争EPC使用,导致程序性能下降。

与YARN相比,Kubernetes[101]管理和编排的是以Docker为代表的操作系统虚拟化容器。也就是说,在Kubernetes中,任务进程都是运行在Docker容器里的。对于SGX任务而言,如果想要以Docker的形式运行,需要将主机上的`isgx`设备文件映射到容器里。在Kubernetes里运行SGX任务则更复杂一些,需要使Kubernetes具备管理EPC的能力。

Kubernetes提供了一套被称为设备插件(Device Plugin)的机制来接入新型硬件设备,例如SGX、GPU、FPGA等。设备插件提供一个RPC服务接口向kubelet进行注册,发送管理的设备列表。kubelet是Kubernetes运行在每个节点上的代理,它会进一步地将这些硬件资源信息发送到集群主节点上的API服务器中。用户在请求使用这些新型硬件资源时,可以在配置文件yaml中指定这些设备的配额。Kubernetes的调度器在进行调度时会根据用户请求的资源配额以及从API服务器获取的实时资源容量进行资源分配和任务放置。

阿里云团队的工程师基于Kubernetes的这套机制实现了面向SGX的设备插件。该插件在Kubernetes中定义了一种被称为alibabacloud/sgx_epc_MiB的新资源来表示EPC资源。代码片段3.13是一个使用该SGX设备插件在Kubernetes中提交任务的示例。可以

```

1  apiVersion: v1
2  kind: Pod
3  metadata:
4    name: {POD_NAME}
5    namespace: default
6  spec:
7    containers:
8      - image: {CONTAINER_IMAGE}
9        imagePullPolicy: IfNotPresent
10       name: {CONTAINER_NAME}
11       resources:
12         requests:
13           alibabacloud.com/sgx_epc_MiB: 20
14         limits:
15           alibabacloud.com/sgx_epc_MiB: 20

```

图 3.13 使用 SGX 设备插件在 Kubernetes 中提交任务时编写 yaml 文件。

看到，用户可以在 yaml 文件中通过 resources:requests/limits 字段来指定容器对 SGX EPC 资源的需求和限制。该设备插件使得 Kubernetes 上的任务可以方便地使用 SGX 资源。但由于操作系统和 SGX 驱动缺乏隔离 EPC 的能力，用户通过 resources:requests/limits 字段指定的数值只会用到 Kubernetes 的资源调度中，而无法像传统的 CPU、内存等资源那样，真正地做到对容器使用 EPC 的大小进行限制。

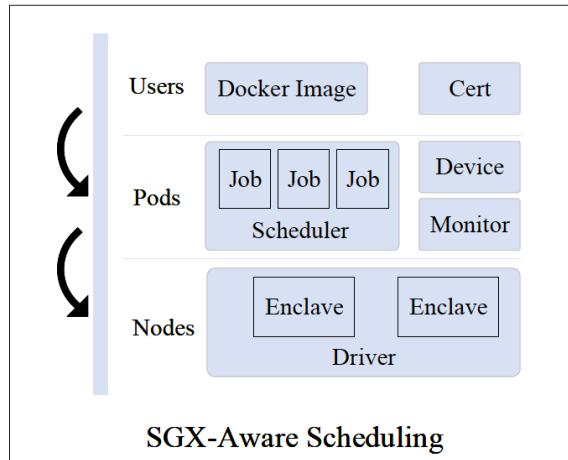


图 3.14 SGX 可感知的调度系统。

Neuchâtel 大学的 S. Vaucher 等人 [102] 在这个方向上做了进一步的工作，基于 Kubernetes 实现了 SGX 可感知的集群管理系统。图是 3.14SGX 可感知的集群管理系统的系统架构，该系统主要在四个方面做出了改进：第一，基于 Kubernetes 的设备插件机制，实现了 SGX 设备的接入。第二，基于节点 EPC 实时使用情况实现 SGX 可感知的容器调度。第三，基于 Kubernetes 的监控模块 Heapster 以及时序数据库 InfluxQL 实现集群对各节点 EPC 使用情况的实时监控。第四，修改 Intel 官方的原生 SGX 驱动程

序，实现 EPC 实时使用数据的信息采集以及限制容器使用 EPC 的大小，防止因 EPC 资源竞争而导致程序性能下降。

3.2.4 在机器学习任务中应用 SGX 技术

由于 SGX EPC 大小的限制（可供应用程序使用的仅有不足 100MB），在实际生产环境中很难直接应用于大型机器学习模型的训练，多数情况下 SGX 被用于有隐私需求的模型部署。尽管如此 O. Ohrimenko 等人 [103] 和 R. Kunkel[104] 等人还是在 SGX 环境下的机器学习模型训练做了若干尝试。O. Ohrimenko 等人在 SGX 环境下实现了若干传统的机器学习算法如 K-means, SVM, decision-tree 等，并证实了其性能在一定程度上是可以接受的。

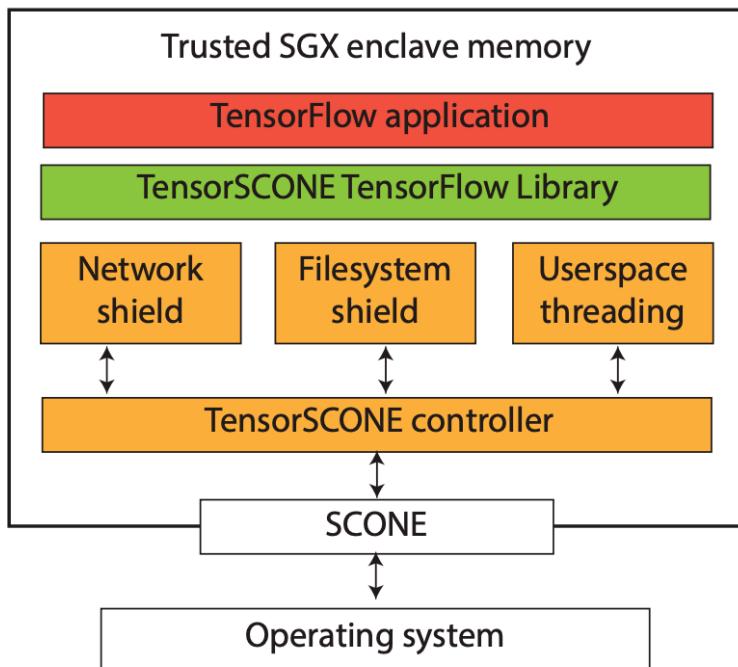


图 3.15 TensorSCONE 架构图。

R. Kunkel 则基于其前序工作 SCONE[97] 实现了支持机器学习任务的安全容器环境 TensorSCONE。图 3.15 阐述了 TensorSCONE 的架构示意图。TensorSCONE 基于的 SCONE 是与 Docker 完全兼容的，且实现了标准的本地认证和远程认证 API。考虑到在 EPC 受限的环境中应该采用尽可能轻量级的框架，其在应用层框架上其选择了较为轻量的机器学习框架 Tensorflow Lite (TF Lite)。其在 SCONE 容器内部实现了一个定制化的 controller，负责重载 TF Lite 的若干功能，并为上层应用提供统一的接口。在其实验中，其仅测试了 ML 任务的模型推断，并称利用 TensorSCONE 框架训练一个 Inception 模型可能需要数月的时间。

J. Ma 在 2020 年提出了 S3ML[105]，基于服务器端的可信执行环境技术 SGX 来实现云端机器学习模型部署的安全可信。图 3.16 表述了 S3ML 的架构。S3ML 从两个方面来提升云原生共享集群对安全可信应用的支持。首先，S3ML 抽象凝练了开发者在使用可信计算环境技术构建应用中所面临的共性需求，将密钥生成、分发、持久化等必备功能实现成独立的安全服务。依赖于该服务，应用开发的效率可以显著提升。其次，在管理可信执行环境设备方面，S3ML 提出了一种方法，在给定一个服务 SLO 的情况下对服务进行离线性能分析，探索服务延时与硬件资源指标的定量定性关系。进一步地，S3ML 提出新的系统架构与机制，合理利用 SGX 特殊硬件资源的实时监控信息，保障在运行着混合负载、存在资源争用的共享集群里依然能够满足服务 SLO。




图 3.16 S3ML 架构示意图。

3.3 小结

本章介绍了加速型硬件 GPU 和安全型硬件 SGX 在云环境中为机器学习带来的新的机遇和挑战。对于 GPU 的利用，本章从两个角度展开。第一个是集群环境中以单个 GPU 为最小调度单位的 GPU 集群调度算法，该类算法一般关注 GPU 之间的连接和拓扑结构，旨在实现一定的任务放置策略使得任务性能最大化、集群吞吐率最大化。同时，结合优先级分级的方法，使得低优先级的任务可以在机会性资源上运行，可以进一步提升集群的资源利用率。另一个角度是多个 ML 任务共用同一个 GPU。从本质上讲，这也是一种 GPU 调度的场景，只不过最小调度单位是部分 GPU。这种场景下，除了传统的 GPU 虚拟化手段，近年来越来越多的研究人员尝试在特定的业务场景下（机器学习模型的训练即为一个典型的场景）实现特定的 GPU 共享机制。SGX 是云环境中支持安全计算的硬件。由于其兴起时间较晚，因此在其上运行机器学习负载的研究还处于探索阶段，未能大规模应用于生产环境。事实上，Intel 计划在不久的未来随着新架构 CPU 的发布对 SGX 技术做同步更新，其所能支持的 EPC 上限可能会大幅度提升，这无疑会给大规模模型的安全训练和部署带来新的潜在解决方案。未来一段时间内，机器学习任务针对 GPU 和 SGX 的研究将持续称为学术界的研究热点。

第四章 人工智能对云计算的增强技术研究

云计算中存在如下两个基本问题。第一，站在用户的视角，如何在浩如烟海的公有云资源池中选择最适合其应用程序的资源，即云配置优化问题。公有云厂商所提供的计算资源类型和计费模式越来越复杂。据不完全统计，截至目前，AWS EC2 提供了超过 400 种配置的虚拟机，阿里云提供了超过 500 种虚拟机。除了虚拟机配置不同之外，其收费模型也存在多种。例如，除了传统的包年包月、按量付费等，还有抢占式实例（在 AWS 中成为 Spot Instance）等计费方式。在此场景中，用户所面临的一个重要问题在于如何为自己的应用程序/负载选择合适配置和收费方式的资源。第二站在公有云运营商的角度，如何调度资源使其满足所有用户的需求，且达到一定的调度目标例如集群资源利用率最高、吞吐率最高等等。

近年来越来越多的学者尝试利用机器学习算法来解决上述两类问题。不同于前两章所述的公有云服务对机器学习负载的支持（Cloud for AI），本章将从“机器学习对云计算的增强技术”（AI for Cloud）着手，研究相关技术。

4.1 基于机器学习算法的云资源配置优化技术

自 2010 年 AWS（Amazon Web Service）将云计算在产业界落地以来，各种云计算模型和应用层出不穷。云计算的高度弹性和海量的资源大大解放了开发者，使他们可以不用费时费力去关注数据中心的运维、物理节点的伸缩。受益于云计算的便捷性，公司、科研机构、事业单位都在将自己的负载向公有云上迁移。尽管云厂商提供了诸如 IaaS、PaaS、SaaS、FaaS 等各种云服务，但受限于绝大多数传统应用的架构和重构代价，大部分应用上云需求对准的都是基础的 IaaS 服务，即将部署在本地私有数据中心的应用迁移在云厂商提供的虚拟机上，以降低运维成本，并使原有的应用具备一定的弹性。

然而，即便云厂商帮助用户完成了集群维护、可靠性保障，但用户仍然需要在庞大的配置空间中选择最适合自己的应用和自己的需求的配置。而且，用户的需求各异，有的需要选择使得其应用完成时间尽可能短的配置，有的需要选择最终总花费尽可能少的配置，还有的可能综合考虑这两点，选择性价比最高的配置。如果仅凭一些启发式的规则，例如，选择配置最高的或者单价最低的，往往难以选择到最优的配置。图 4.1 展示了 Spark-Terasort 这一任务在 55 种云资源配置上（跨越 AWS、阿里云、腾讯云、华为云四大云厂商）的任务完成时间和总花费曲线。该图中，横轴代表不同的配置，其中上面的子图中，配置的单价由左到右单调递增，下面的子图中，配置的规则由左到右




图 4.1 同一任务在不同云配置下的性能和花费。

单调递增。 opt_j , opt_c , opt_p 分别代表最优完成时间、最优花费和最优性价比，JCT 为 Job Completion Time 的缩写，代表任务完成时间。很显然，最优的配置与直觉相违背。因此，此类用户需要一个自动选择最优配置的算法/工具，来帮助他们为自己的应用程序/负载选择最符合他需求（完成时间最短，总体花费最低或者性价比最高）的配置。

尝试解决此类问题的相关工作，其大体可以分为两类：1) 数据驱动的线下建模方法；2) 基于搜索的线上优化方法。本节按照这种分类方法介绍相关工作。

4.1.1 数据驱动的线下建模方法

该类方法旨在通过在线下收集一系列形如 $\langle \text{meta data}, \text{performance} \rangle$ 的键值对，然后利用机器学习算法对上述键值对建立回归模型，以预测性能。其中 meta data 中可能既包括配置信息，如当前运行环境的硬件配置（CPU 核数，CPU 代数，memory 大小等等），又包括可以刻画该 workload 的一些信息，如 workload 运行时某一时刻的 CPU 利用率等等。对于用户而言，使用该类算法的总体流程如图4.2所示。




图 4.2 数据驱动的线下建模方法流程图。

在模型训练阶段，需要对不同的 workload 在不同的 VM 上进行 profile，形成形如 \langle configuration, performance \rangle 的键值对。然后对由该键值对构成的数据集进行模型训练。在预测阶段，用户需要在一个或者多个 test VM 上预运行自己的 workload，并采集一些模型需要的数据，将其输入模型，并得到预测结果。该结果可能是该 workload 在配置集上所有 VM 配置上运行的性能数值或者最有的配置。总的来讲，该种类别中，不同的工作的主要区别在于上图中 Prediction Model 的结构。

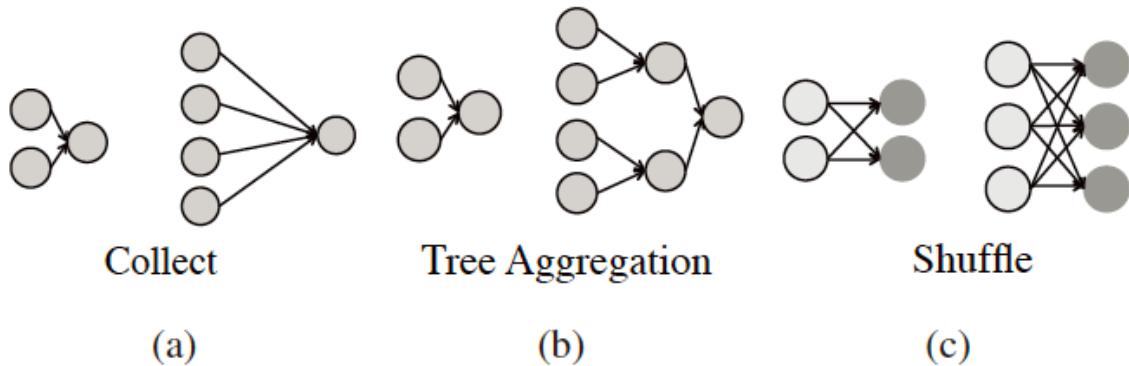


图 4.3 Ernest 中的三种数据流模式。

S. Venkataraman 等人在 2016 年提出了 Ernest[37]，可以称为云上性能建模的开山之作。Ernest 主要关注 Hadoop, Spark 等基于 map-reduce 计算范式的应用程序。Ernest 将基于 map-reduce 计算范式的程序中的数据流模式总结为如图 4.3 所示的 Collect、Tree Aggregation 和 Shuffle 三种模式。其认为三种数据流模式的计算复杂度分别为 $O(\frac{1}{machines})$ ， $O(machines)$ 和 $O(log(machines))$ ，因此使用公式 4.1 对应用程序的性能进行拟合。虽然此模型非常简单，但是 Ernest 通过基于 Spark-MLLib 的实验证明了其模型可以达到较低的预测错误，且 profile 的代价较小。

$$\begin{aligned} time = & \theta_0 + \theta_1 \times (scale \times \frac{1}{machines}) + \\ & \theta_2 \times log(machines) + \\ & \theta_3 \times machines \end{aligned} \quad (4.1)$$

Ernest 虽然可以达到较好的效果，但是其仅针对 Hadoop 和 Spark 等 MR 范式的应用，无法在一般性的场景中得到应用。且 Ernest 并未将资源配置作为输入参数，对于每种资源都需要使用模型建立一个单独的模型进行预测，在复杂的公有云中适用性较低。N. Yadwadkar 等人在 2017 年提出了 PARIS[36]。如图基于随机森林模型和两次预先运行收集到的数据对常用的数据处理任务进行性能建模。不同于 Ernest，PARIS 的输入参数除了资源信息，还包括预运行中收集到的关于当前应用程序的系统指标（最

后一分钟、五分钟和十五分钟的系统指标，例如 CPU 利用率，内存利用率，中断次数等）。同时 PARIS 还不仅支持性能建模，还支持对花费进行建模。用户可以根据自己的需求，使用 PARIS 选择性能最优或者花费最低的云资源。

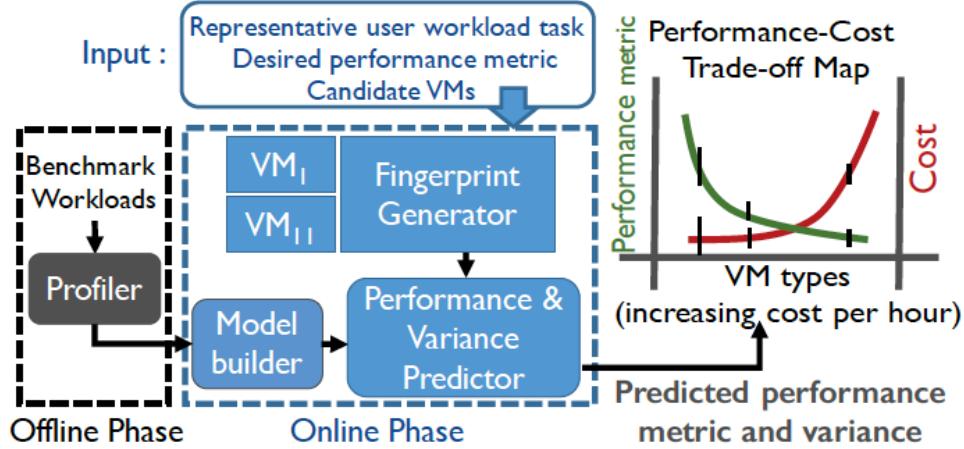


图 4.4 PARIS 系统架构。

从另一个角度来看，云资源的配置优化问题实际上可以视作推荐问题的一个变种，即在配置集合中为用户推荐最适合其应用程序的配置。A. Klimovic 在 2018 年提出了 Selecta[35]，使用隐因子协同过滤算法为用户推荐合适的云资源配置。如图 4.5 所示，Selecta 先使用训练应用集在 20% 的配置上预先运行，用户的目标应用需要在两个配置上预先做运行。上述运行得到的数据（任务完成时间或者最终花费）会形成一个行为不同配置列为不同应用程序的稀疏矩阵。然后 Selecta 利用 SVD（特征值分解）对矩阵进行补全，最后根据最后一行推理出来的结果推荐出最优的配置。在该应用实际运行结束后，其运行结果会补充到该矩阵中以对数据进行增强，使模型的推荐效果更优。

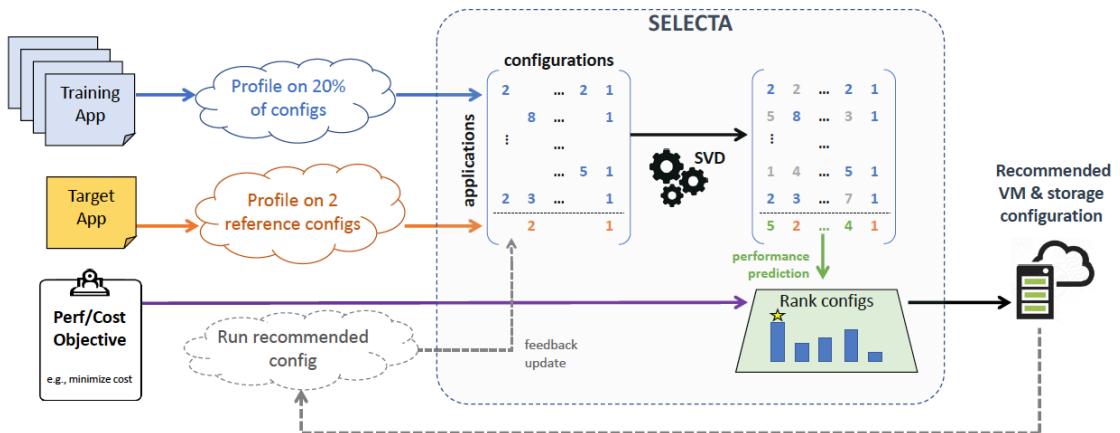


图 4.5 Selecta 系统架构。

随着深度学习模型的流行，也有研究者提出使用深度学习模型对应用性能进行建

模，从而为应用选择最合适的云资源。F. Moradi[38]在2019年提出使用迁移学习算法实现通用的云应用性能预测。该方法先使用一个应用程序在所有的云配置上运行并收集性能数据，然后用深度神经网络对其建立性能模型，并将该模型计作基础模型。当需要为新的应用程序预测性能时，则抽出基础模型中的前若干层中的已训练参数放在新模型中，并使用新应用程序在少量配置上预运行得到结果对该模型进行微调，从而得到一个模型。该方法实际上是将已训练好的模型视作应用程序的特征抽取器，再使用其抽取的特征在新的数据上重新训练得到新模型。




图 4.6 基于 Domain Adaption 的性能预测。

Y. Li 等人 [106] 也提出了一种基于迁移学习的性能预测算法。如图 4.6 所示，不同于 F. Moradi 等人的工作，该工作并未采用重新训练的方法，而是使用特征迁移的方法，直接将训练得到的模型在新的场景中应用。该思想借鉴于计算机视觉中的 CORAL 模型 (covariance alignment)[107]，先通过计算 source domain 和 target domain 的协方差矩阵，然后利用公式 4.2 得到一个转移矩阵，最后利用该转移矩阵对 target domain 的特征做线性变换，应用于在 source domain 中训练得到的模型得到当前应用程序在不同配置上的性能。

$$\begin{aligned}
 A_{ti}^{(S)} &= \operatorname{argmin}_B \|\bar{\Sigma}_s - B^T \Sigma_{ti} B\|_2 \\
 \text{s.t. } \bar{\Sigma}_s &= \frac{1}{|S|} \sum_{s \in S} \Sigma_s
 \end{aligned} \tag{4.2}$$

4.1.2 基于搜索的线上优化方法

该类方法不同于数据驱动的线下建模方法，不需要在线下建立性能模型。其一般使用相关搜索算法（例如贝叶斯优化）在线上不断地搜索，并同时更新一个置信函数，当该函数值大于（或小于）某个阈值时，便停止搜索，用当前的到的数据中最优的一个作为结果。作为无需线下建模的纯线上方法，其固然具有其方便性。但是由于其掌握的信息过少，准确性一般要比基于线下建模的方式略低。




图 4.7 CherryPick 系统架构。

O. Alipourfard 等人在 2016 年提出 CherryPick[40]，使用典型的 BO (Bayes Optimization，即贝叶斯优化) 持续搜索不同的配置，直到其定义的置信函数超过某个阈值，则将当前搜索到的最优值作为最后的结果。图 4.7 描述了 CherryPick 的系统架构，其支持在 AWS, Azure 和 Google Cloud 三家云厂商中对资源进行搜索，且支持用户自定义搜索的目标函数。

在 CherryPick 基础上，M. Casimiro 等人在 2020 年提出了 Lynceus[41]。有别于 CherryPick，Lynceus 没有使用贪心的搜索方法，且不需要事先了解目标应用程序的任何信息。图 4.8 阐述了 Lynceus 与传统贝叶斯优化方法的区别所在。首先，Lynceus 在考虑每一次搜索的 reward 的同时，还考虑了这一次搜索可能造成的 cost。其实，传统的贝叶斯优化在一次尝试后即根据反馈推断下一次搜索的配置，Lynceus 则是先预估一个可能的搜索路径，然后对路径的第一个节点进行尝试，最后得到最优结果。Lynceus 更远的视野和更为精细的回报函数设计使得其相比于传统的贝叶斯优化拥有更高的准确率。




图 4.8 Lynceus 与传统贝叶斯优化的区别。

4.2 基于机器学习算法的云资源调度优化技术

资源调度是操作系统、分布式系统和云计算领域中的经典问题，其本质在于为系统中的每个任务分配合适的资源，从而使得系统达到某种状态，如资源利用率最高、闲置资源最少或者吞吐率最高等。近年来越来越多的学者开始尝试使用机器学习算法，特别是深度学习算法，对调度问题进行建模，试图更精确地解决调度问题。

C. Delimitrou 等人在 2014 年提出了 Quasar[42]，旨在保证作业性能的同时提升云上集群的资源利用率。Quasar 和目前云计算厂商使用的资源预留策略（用户申请一定量的资源后即按照该量分配，即时相当一部分分配的资源处于空载状态）不同，而是要求用户提供一个动态的目标，使得集群调度器可以动态地适配其需要的资源。图 4.9 展示了 Quasar 的系统架构。Quasar 使用了协同过滤算法得到 workload 在满足 QoS 的前提下需要的资源数量和类型，以及会与那些 workload 产生干扰，再利用这一结果贪心地分配资源。通过实验，Quasar 在 200 个 EC2 服务器的集群环境中提高了 47% 的资源利用率。




图 4.9 Quasar 架构示意图。

随着深度学习的进一步发展，也有许多工作尝试将强化学习应用于调度问题。强化学习（Reinforcement Learning）是一种机器学习方法。这种方法通过与环境不断交互获得交互的反馈，从而获得经验，再从经验中不断学习，最终获得最优策略。其中经验（experience）是与环境交互得到的状态 state）、动作 action）和收益 reward 的采样序列。

H. Mao 等人在 2019 年提出了 Decima[43]，利用 message passing 等方法，将 DAG 作业的图结构建模到神经网络中，从而使得神经网络模型具有可扩展性，可适应任意作业队列长度的输入，而后通过 policy gradient 等强化学习方法训练调度器。结果显示 Decima 相比之前的启发式调度算法至少减少了 21% 的平均作业完成时间。

除了使用强化学习算法，Decima 中的另一个核心思想是使用图神经网络将 DAG 图中的作业节点编码成向量（亦称作 embedding），再由这些向量生成 Job 级别的 embedding 和全局的 embedding。这种思想借鉴于自然语言处理中的 word2vec 和图神经网络中的 node2vec。如图 4.10 所示，embedding 生成的依据是 DAG 中各个节点之间的依赖关系。这样做的好处是将图中节点的依赖关系转化为高维空间中向量之间的代数关系，使得模型能够更容易的学习到规律。




图 4.10 Decima 中的 embedding 生成示意图。

F. Li 等人在 2019 年提出了 DeepJS[108]，将问题模型化为选择机器-作业对的问题，每次调度前构造可行的机器作业对列表，由神经网络输出每个对的得分，优先调度得分高的机器作业对。A. Mirhoseini 等 [109] 使用强化学习算法训练了 Tensorflow 计算操作的放置策略（放置于哪个计算设备，如 CPU），它使用了一种循环神经网络去编码状态，而不是采用具有可扩展性的图神经网络。




图 4.11 Neo 系统架构示意图。

受到 Decima 的启发，有一些学者开始考虑将深度学习算法和图神经网络应用到云数据库中的查询优化中，因为数据库中的一次查询所对应的语法树天生就是一个 DAG 图，图的节点对应数据库中的 operator。R. Marcus 等人在 2019 年提出 Neo[110]，一种基于深度学习的数据库查询优化器。图 4.11 阐述了 Neo 的系统架构。与 4.1.1 中所述的基于线下模型训练的性能预测方法类似，Neo 需要先使用 sample workload，通过一个已有的最优优化器（可能是基于专家的经验，也可能基于历史信息），构建一个查询优化的信息库（即图中的 Experience）。当用户发起查询时，Neo 中的特征提取器会结合经验和用户的查询语句对其进行特征提取。此处的特征提取 Neo 使用了树形的卷积网络对语句中的 operator 进行编码，然后做出决策，交由数据库引擎执行。T. Kraska 在 2019 年也提出了一个基于深度学习的数据库系统 SageDB[111]。和 Neo 相比，SageDB 更进一步，其在数据库查询执行、数据预取等阶段都利用机器学习模型做了相关优化。

除了数据库领域，深度强化学习也被应用于其它系统软件领域。例如，L. Cen 等人 [112] 在 2020 年提出基于深度强化学习的垃圾回收优化机制。在 Java，Python 等语言中，垃圾回收是内存管理机制的重要组成部分。Cen 等人利用深度强化学习，专门针对长运行的任务（例如 Web 服务），在其运行过程中不断地利用强化学习算法优化垃圾回收策略，动态地决定何时对内存对象进行回收，以提升服务的质量或者任务的性能。

4.3 小结

本节从用户和云厂商运营者两个角度，研究了云计算中的两个经典问题，即云资源配置优化与云资源调度。基于机器学习的云资源配置优化技术正在经历从支持特定领域应用向支持通用应用的发展历程。未来，关于如何用较小的代价获取通用性较强的资源配置优化模型，将会是研究的重点。基于机器学习的资源调度算法一般都是将

资源调度问题抽象为典型的机器学习领域的问题，例如通过协同过滤算法建立不同实体之间的关系，利用图神经网络对 DAG 图的节点进行编码，利用强化学习不断调整系统的状态等等。事实上，利用机器学习算法解决调度问题目前亦处于探索阶段。大型分布式系统中，往往要求调度器能够快速做出决策，而基于机器学习尤其是深度学习的调度模型，往往具有较高的延时，可能会给系统带来过重的额外开销。未来，除了使调度算法做出更优的决策之外，尝试降低基于 ML 的调度算法的额外开销，也会是一个可能的研究方向。

第五章 重要文献与研究团队总结

5.1 重要文献总结

1. Li M, Andersen D G, Park J W, et al. Scaling distributed machine learning with the parameter server[C]//11th USENIX Symposium on Operating Systems Design and Implementation (OSDI 14). 2014: 583-598. 该论文在 2014 年发表在操作系统顶级会议 OSDI 上。其在文中提出的 Parameter Server 架构 (PS Model)，成为了后续分布式机器学习中所使用的标准架构。PS Model 将集群中的服务器分为存储参数的 server 和负责迭代计算的 worker，通过一些列健壮的设计，是的 ML 模型训练任务能在大规模集群上可靠、高性能地运行。如今，AWS 的 Sagemaker[24]，腾讯的 Angel[28] 等机器学习系统，皆是基于 PS Model 设计和开发的。

2. Harlap A, Tumanov A, Chung A, et al. Proteus: agile ml elasticity through tiered reliability in dynamic resource markets[C]//Proceedings of the Twelfth European Conference on Computer Systems. 2017: 589-604. & Harlap A, Chung A, Tumanov A, et al. Tributary: spot-dancing for elastic services with latency SLOs[C]//2018 USENIX Annual Technical Conference (USENIXATC 18). 2018: 1-14. 这两篇论文出自同一个作者笔下，分别在 2017 和 2018 年发表在操作系统顶级会议 Eurosyst 和 USENIX ATC 上。作者讨论了如何利用公有云上的动态资源进行 ML 模型训练和 ML 模型部署。作者提出了 Proteus 和 Tributary，通过一定的容错设计和基于价格预测的资源选取策略设计，使 ML 模型训练任务和部署任务在保持高效的同时，利用动态资源降低成本。动态资源是云厂商推出的较为新型的资源，这两篇文章是近几年利用动态资源运行机器学习工作流的代表之作，被后续多个工作 [30, 60, 113–117] 所借鉴。

3. Crankshaw D, Wang X, Zhou G, et al. Clipper: A low-latency online prediction serving system[C]//14th USENIX Symposium on Networked Systems Design and Implementation (NSDI 17). 2017: 613-627. 该文章在 2017 年发表于计算机网络顶级会议 NSDI 上。作者提出了一种基于容器的模型部署系统 Clipper，向下兼容了 Tensorflow, Spark 等机器学习框架，向上为用户提供了统一的结果，并通过 adaptive batching 等手段保证模型推断的性能。Clipper 是学术界关于模型部署极具代表性的工作，其基本思想在后续基于云服务进行模型部署的工作中 [31, 65, 118–123] 被不断地借鉴和改进。

4. Zhang C, Yu M, Wang W, et al. Mark: Exploiting cloud services for cost-effective, slo-aware machine learning inference serving[C]//2019 USENIX Annual Technical Confer-

ence (USENIXATC 19). 2019: 1049-1062. 该文章在 2018 年发表于操作系统顶级会议 USENIX ATC 上。作者借鉴 Clipper 中 adaptive batching 的思想提出了模型部署系统 MArk，综合利用了公有云中的 IaaS, CaaS (container as a service), FaaS 等资源，根据请求负载的变化趋势，动态地决定使用何种资源。该工作首次综合考虑了多种类型的资源，并根据其特点的差异性在不同的场合合理利用，使模型部署任务在公有云上高效经济地运行，被后续多篇工作 [124–129] 借鉴。

5. Amaral M, Polo J, Carrera D, et al. Topology-aware gpu scheduling for learning workloads in cloud environments[C]//Proceedings of the International Conference for High Performance Computing, Networking, Storage and Analysis. 2017: 1-12. 该工作在 2017 年发表在高性能计算顶级会议 SC 上。作者首次在 GPU 集群的调度问题中考虑了 GPU 的拓扑关系，并将之与 DAG 类型 Job 的 task 拓扑关系相结合，使用图论中的相关算法，对 GPU 集群中的任务进行调度。该工作关于 GPU 拓扑结构的研究，被后续很多 GPU 调度的相关工作 [79, 130–137] 借鉴和改进。

6. Xiao W, Bhardwaj R, Ramjee R, et al. Gandiva: Introspective cluster scheduling for deep learning[C]//13th USENIX Symposium on Operating Systems Design and Implementation (OSDI 18). 2018: 595-610. 该工作在 2018 年发表于操作系统顶级会议 OSDI 上。作者综合探索了深度学习集群中的调度问题，设计了一种高效调度和共享集群中 GPU 资源的系统 Gandiva。Gandiva 中的两种方法被后续很多相关工作 [85, 86, 138–146] 借鉴和改进：1) 基于 grow-shrink 的深度学习作业横向伸缩方法；2) 基于作业内存利用率周期性变化的作业迁移方法。

7. Vaucher S, Pires R, Felber P, et al. SGX-aware container orchestration for heterogeneous clusters[C]//2018 IEEE 38th International Conference on Distributed Computing Systems (ICDCS). IEEE, 2018: 730-741. 该论文在 2018 年发表在分布式计算顶级会议 ICDCS 上。作者基于 kubernetes，提出了一种 SGX 资源可感知的集群调度系统。该工作首次在学术界将 SGX 资源引入集群资源调度中，其基本的机制被后续多个工作 [105, 147–151] 所参考。

8. Venkataraman S, Yang Z, Franklin M, et al. Ernest: Efficient performance prediction for large-scale advanced analytics[C]//13th USENIX Symposium on Networked Systems Design and Implementation (NSDI 16). 2016: 363-378. 该工作在 2016 年发表在计算机网络顶级会议 NSDI 上。作者针对基于 map-reduce (MR) 范式的应用程序（如 Hadoop, Spark 等），提出了一种性能建模方法 Ernest。Ernest 总结了 MR 范式中典型的集中数据流模式，并用以进行性能拟合，仅需用户若干次的预运行，即可推算出是性能达到最优的系统配置。Ernest 是云环境中对数据处理类应用，使用线下模型训练进行性能建

模的开篇之作。后续的多个工作 [35, 36, 38, 39]，都借鉴了 Ernest 的思想和模型设计。

9. Alipourfard O, Liu H H, Chen J, et al. Cherrypick: Adaptively unearthing the best cloud configurations for big data analytics[C]//14th USENIX Symposium on Networked Systems Design and Implementation (NSDI 17). 2017: 469-482. 该论文在 2017 年发表于计算机网络顶级会议 NSDI 上。与 Ernest 类似，作者同样针对数据处理类作业，利用线上搜索的方法（贝叶斯优化，BO）搜寻适合当前作业的最佳配置。该工作首次将 BO 这类搜索算法应用于云资源配置优化，亦被后续多个工作 [41, 152–155] 借鉴和比较。

10. Mao H, Schwarzkopf M, Venkatakrishnan S B, et al. Learning scheduling algorithms for data processing clusters[M]//Proceedings of the ACM Special Interest Group on Data Communication. 2019: 270-288. 该工作在 2019 年发表于计算机网络顶级会议 SIGCOMM 上。作者首次将利用强化学习模型解决集群中数据处理作业的调度问题，提出了调度算法 Decima。Decima 中最关键的技术要点在于利用图神经网络对 DAG 类作业节点进行编码，再将其应用与强化学习调度算法。其思想被后续多个集群调度领域的相关工作和数据库查询优化的相关工作 [110–112, 139, 156–158] 所借鉴。

5.2 重要研究团队总结

Ion Stoica 团队。 University of California, Berkeley 的 Ion Stoica 教授团队在大数据处理、数据中心资源管理以及人工智能等领域取得了丰硕的研究成果。在数据处理方面，该团队提出开发了 Spark[159]、Shark、SparkR[160]、GraphX[161] 等项目，不仅在学术界产生了影响力，并且在工业界得到了广泛利用。在这些研究成果的基础上，该团队的核心成员还创立以数据处理技术为核心的公司 Databricks，目前估值已经达到了 27.5 亿美元。在数据中心资源管理方面，该团队提出了 DRF、Delay Scheduling 等调度策略，在真实的集群调度器中得到了应用。同时，该团队也是双层调度系统 Mesos[162] 与分布式调度系统 Sparrow[163] 的提出者。在云资源预测与配置方面，该团队提出了 Ernest。近年来，该团队也开始涉足机器学习领域，研究支撑机器学的系统和框架开发，提出了面向机器学习的分布式框架 Ray。

Christos Kozyrakis 团队。 Stanford University 的 Christos Kozyrakis 教授团队在云资源管理领域上取得了丰富的研究成果。该团队在 2013 年时提出的 Paragon[164]，在 2014 年提出的 Quasar[42] 都将基于机器学习的分类技术应用到了集群调度系统中，在保证应用 QoS 的基础上，提高了集群的资源利用率。在 2015 年，该团队又提出了 Tarcil[165] 和 Heracles[166]。Tarcil 是一个分布式调度器。Heracles 则将延迟敏感型作业与批处理型作业运行一起来提升集群资源利用率。在 2016 年，该团队提出了高效的云资源分配系统 HCloud[167]。在 2017 年，该团队提出了面向云安全的 Bolt 系统。在 2018 年，

该团队提出了面向数据处理作业的云计算和存储资源优化配置的工具 Selecta。

CMU PDL 实验室。 Carnegie Mellon University 的 Parallel Data Lab (PDL 实验室) 在分布式系统、机器学习系统、数据库系统等领域获得了丰硕的研究成果。特别地，其 Big Learning 课题组在机器学习系统领域常年走在学术界的最前沿。该团队在 2017 年提出的 Proteus 尝试在公有云动态资源之上构建大规模机器学习系统。在 2018 年提出 Tributary，在公有云动态资源上部署机器学习模型。在分布式机器学习训练加速方面，在 2018 年提出 Pipedream[168]，实现 layer-wise 的并行加速。在 2019 年，该团队又提出了 Parity Models[169]，巧妙地利用纠删码冗余来保证模型部署系统的性能。

MSRA System Group。 微软亚洲研究院的 System Group 在大数据处理、机器学习系统、移动计算和图计算等领域取得了大量的研究成果。2017 年，该团队提出 TuX2[170]，一个面向机器学习的分布式图计算系统。2020 年，其在计算机系统领域的顶级会议 OSDI 上独中五元，提出了大规模 GPU 集群调度系统 HiveD，深度学习编译优化系统 Rammer[171] 等。2021 年，该团队又提出了在移动 CPU 上进行模型推断的系统 AsyMo[172] 和用以预测深度学习任务性能的系统 DNNPerf[173]。

第六章 下一步的研究设想

6.1 研究动机

作者现阶段的研究动机均与机器学习模型部署相关。一个是利用新的云计算服务模式 FaaS 进行模型部署，另一个是在安全计算环境 SGX 中进行模型部署。二者所要达到的目标也类似，即在保证服务质量的前提下，尽量提升集群的资源利用率。

6.1.1 基于 FaaS 的模型部署系统现状

serverless 是一种非常适合部署 ML 模型的计算模式，其具有计费粒度细、横向拓展能力强的特点。但是现有的 serverless 框架用来部署 ML 模型时，仍然存在一定的问题：

- 当前公有云的 serverless 服务仅使用 CPU，单个 serverless 实例没有并发能力，能够满足的吞吐量有限。而横向拓展又会因为冷启动造成延迟增加，可能会违背任务的 SLO。
- serverless 一般是基于容器技术实现的（例如 Docker 等）。而容器使用 GPU 一般是独占的方式（nvidia-docker），这样会造成显存浪费。通过实验可以证明，在满足一定 SLO 的前提下，batching 的上限距离显存大小仍有一定的差距。

如果能解决上述问题，将 GPU 共享机制和基于 SLO 的显存调度机制引入 serverless 系统中，可能可以在保证服务质量的前提下大幅提升系统的资源利用率。

6.1.2 基于 SGX 的模型部署系统现状

基于 SGX 的模型部署系统在真实场景中有着广泛的需求，尽管学术界已经在这方面做了一些探索，但是仍有如下问题需要解决：

- 由于 SGX 目前所支持的 EPC 大小有限，共同部署在同一个 EPC 内的模型之间可能会存在干扰。
- 由于 SGX 本身的封闭性，对于部署 SGX 的 Enclave 内部的应用很难直接对其 EPC 利用率进行直接监测，从而获得该应用的行为信息（例如内存利用率的变化模式）。

如果能解决上述问题，通过一个工具预测应用在 SGX 环境下的干扰情况，再基于此实现调度算法，则可以在保证 SGX 环境下模型部署服务质量的前提下，提升 SGX 集群的资源利用率。

6.2 研究计划

6.2.1 SLO 可感知的 Serverless 机器学习模型部署系统

为了让用户在云上在满足 SLO 的条件下更经济高效地使用 serverless 部署 ML 模型，本文拟提出一种 SLO 可感知的基于 GPU 显存共享的 serverless 框架，解决如下问题：

- 实现一种基于 API 截取的 GPU 显存共享中间件，使得多个容器可以共享同一块 GPU，且相互之间隔离。
- 使用 GPU 的 serverless 实例时，根据服务的 SLO 计算其能容许的 batching 的请求上限，划分一块显存给其使用。
- 基于上述机制，实现一种 SLO 可感知的服务调度算法，将若干服务按照其 SLO 对应的显存上限进行调度，使多个服务可以在一个 GPU 设备上共存，提高系统资源利用率。

6.2.2 SGX 环境下机器学习模型部署干扰及调度策略研究

为了能在 SGX 更高效地部署机器学习模型，本文拟提出一种 SGX 环境下机器学习模型部署干扰的建模方法，以及基于此的模型部署服务调度算法：

- 在非 SGX 的环境中对应用（此处的应用对应机器学习模型部署服务）运行时系统信息（例如 CPU 利用率的变化曲线，与内存相关的指标如换页频率、内存利用率的变化曲线）进行收集，分析应用的行为模式。
- 在 SGX 的环境中部署多个应用，研究其相互干扰的情况。
- 将上述两个信息利用模型建立关系，得到一个预测应用之间干扰程度的工具。
- 利用上述工具，实现一种 SGX 环境下的应用调度算法，通过对应用在非 SGX 环境中采集少许运行时数据，预测其可能与系统中现存的服务之间的干扰关系，将其调度到最合适的节点上。

参考文献

- [1] *Amazon Web Service*. Accessed Apr 12, 2021.
- [2] Peter M. Mell and Timothy Grance. “*The NIST Definition of Cloud Computing*”. *Special Publication (NIST SP) - 800-145*, **2011**, 23(6): 50–50.
- [3] AWS EC2. Accessed Apr 12, 2021.
- [4] Google Compute Engine. Accessed Apr 12, 2021.
- [5] AWS EC2. Accessed Apr 12, 2021.
- [6] Mayra Samaniego and Ralph Deters. “*Blockchain as a Service for IoT*”. In: *2016 IEEE International Conference on Internet of Things (iThings) and IEEE Green Computing and Communications (GreenCom) and IEEE Cyber, Physical and Social Computing (CPSCom) and IEEE Smart Data (SmartData)*. **2016**: 433–436.
- [7] Charith Perera, Arkady Zaslavsky, Peter Christen *et al*. “*Sensing as a service model for smart cities supported by Internet of Things*”. In: *Transactions on Emerging Telecommunications Technologies archive*. **2014**: 81–93.
- [8] Bo An, Xudong Shan, Zhicheng Cui *et al*. “*Workspace as a Service: An Online Working Environment for Private Cloud*”. In: *2017 IEEE Symposium on Service-Oriented System Engineering (SOSE)*. **2017**: 19–27.
- [9] Ioana Baldini, Paul C. Castro, Kerry Shih-Ping Chang *et al*. “*Serverless Computing: Current Trends and Open Problems*”. In: *Research Advances in Cloud Computing*. **2017**: 1–20.
- [10] Markus Klems. *AWS Lambda Quick Start Guide*. **2018**.
- [11] Arthur L. Samuel. *Some studies in machine learning using the game of checkers*. **1995**: 391–414.
- [12] Leo Breiman, Jerome H Friedman, Richard A Olshen *et al*. *Classification and regression trees*. **1983**.
- [13] D. E. Rumelhart. “*Learning internal representations by back-propagating errors*”. *Parallel Distributed Processing: Explorations in the Microstructure of Cognition*, **1986**: 318–362.
- [14] Y. LeCun, B. Boser, J. S. Denker *et al*. “*Backpropagation applied to handwritten zip code recognition*”. *Neural Computation*, **1989**, 1(4): 541–551.
- [15] Corinna Cortes and Vladimir Vapnik. “*Support-Vector Networks*”. *Machine Learning*, **1995**, 20(3): 273–297.
- [16] Yoav Freund. “*Boosting a weak learning algorithm by majority*”. *Information & Computation*, **1995**, 121(2): 256–285.
- [17] Sepp Hochreiter and Jürgen Schmidhuber. “*Long short-term memory*”. *Neural Computation*, **1997**, 9(8): 1735–1780.
- [18] Sam T. Roweis and Lawrence K. Saul. “*Nonlinear dimensionality reduction by locally linear embedding*.” *Science*, **2000**, 290(5500): 2323–2326.

- [19] Leo Breiman. “*Random Forests*”. *Machine Learning archive*, **2001**, 45(1): 5–32.
- [20] Alex Krizhevsky, Ilya Sutskever and Geoffrey E. Hinton. “*ImageNet classification with deep convolutional neural networks*”. *Communications of The ACM*, **2017**, 60(6): 84–90.
- [21] G. E. Hinton and R. R. Salakhutdinov. “*Reducing the Dimensionality of Data with Neural Networks*”. *Science*, **2006**, 313(5786): 504–507.
- [22] David Silver, Aja Huang, Christopher J. Maddison *et al.* “*Mastering the game of Go with deep neural networks and tree search*”. *Nature*, **2016**, 529(7587): 484–489.
- [23] Ian Goodfellow, Jean Pouget-Abadie, Mehdi Mirza *et al.* “*Generative Adversarial Nets*”. In: *Advances in Neural Information Processing Systems 27*. **2014**: 2672–2680.
- [24] Ameet V Joshi. “*Amazon’s Machine Learning Toolkit: Sagemaker*”. **2020**: 233–243.
- [25] Edo Liberty, Zohar Karnin, Bing Xiang *et al.* “*Elastic Machine Learning Algorithms in Amazon SageMaker*”. In: *Proceedings of the 2020 ACM SIGMOD International Conference on Management of Data*. **2020**: 731–737.
- [26] Valerio Perrone, Huibin Shen, Aida Zolic *et al.* “*Amazon SageMaker Automatic Model Tuning: Scalable Black-box Optimization*.” *arXiv preprint arXiv:2012.08489*, **2020**.
- [27] Leila Etaati. “*Azure Machine Learning Studio*”. **2019**: 201–223.
- [28] Jie Jiang, Lele Yu, Jiawei Jiang *et al.* “*Angel: a new large-scale machine learning system*”. *National Science Review*, **2018**, 5(2): 216–236.
- [29] Aaron Harlap, Alexey Tumanov, Andrew Chung *et al.* “*Proteus: agile ML elasticity through tiered reliability in dynamic resource markets*”. In: *Proceedings of the Twelfth European Conference on Computer Systems*. **2017**: 589–604.
- [30] Yan Li, Bo An, Junming Ma *et al.* “*SpotTune: Leveraging Transient Resources for Cost-efficient Hyper-parameter Tuning in the Public Cloud*”. In: *2020 IEEE 40th International Conference on Distributed Computing Systems (ICDCS)*. **2020**.
- [31] Chengliang Zhang, Minchen Yu, Wei Wang *et al.* “*MArk: Exploiting Cloud Services for Cost-Effective, SLO-Aware Machine Learning Inference Serving*.” In: *2019 USENIX Annual Technical Conference (USENIX ATC 19)*. **2019**: 1049–1062.
- [32] Hao Wang, Di Niu and Baochun Li. “*Distributed Machine Learning with a Serverless Architecture*”. In: *IEEE INFOCOM 2019 - IEEE Conference on Computer Communications*. **2019**: 1288–1296.
- [33] Victor Costan and Srinivas Devadas. “*Intel SGX Explained*.” *IACR Cryptology ePrint Archive*, **2016**, 2016: 86.
- [34] AWS EC2 Spot Instances. Accessed Apr 12, 2021.
- [35] Ana Klimovic, Heiner Litz and Christos Kozyrakis. “*Selecta: heterogeneous cloud storage configuration for data analytics*”. In: *2018 {USENIX} Annual Technical Conference ({USENIX} {ATC} 18)*. **2018**: 759–773.
- [36] Neeraja J Yadwadkar, Bharath Hariharan, Joseph E Gonzalez *et al.* “*Selecting the best vm across multiple public clouds: A data-driven performance modeling approach*”. In: *Proceedings of the 2017 Symposium on Cloud Computing*. **2017**: 452–465.

-
- [37] Shivaram Venkataraman, Zongheng Yang, Michael Franklin *et al.* “Ernest: efficient performance prediction for large-scale advanced analytics”. In: *13th {USENIX} Symposium on Networked Systems Design and Implementation ({NSDI} 16)*. **2016**: 363–378.
 - [38] Farnaz Moradi, Rolf Stadler and Andreas Johnsson. “Performance Prediction in Dynamic Clouds using Transfer Learning”. In: *2019 IFIP/IEEE Symposium on Integrated Network and Service Management (IM)*. **2019**: 242–250.
 - [39] Bingbing Zheng, Li Pan, Shijun Liu *et al.* “An Online Mechanism for Purchasing IaaS Instances and Scheduling Pleasingly Parallel Jobs in Cloud Computing Environments”. In: *2019 IEEE 39th International Conference on Distributed Computing Systems (ICDCS)*. **2019**: 35–45.
 - [40] Omid Alipourfard, Hongqiang Harry Liu, Jianshu Chen *et al.* “Cherrypick: Adaptively unearthing the best cloud configurations for big data analytics”. In: *14th {USENIX} Symposium on Networked Systems Design and Implementation ({NSDI} 17)*. **2017**: 469–482.
 - [41] Maria Casimiro, Diego Didona, Paolo Romano *et al.* “Lynceus: Cost-efficient Tuning and Provisioning of Data Analytic Jobs”. *arXiv: Distributed, Parallel, and Cluster Computing*, **2019**.
 - [42] Christina Delimitrou and Christos Kozyrakis. “Quasar: resource-efficient and QoS-aware cluster management”. In: *Proceedings of the 19th international conference on Architectural support for programming languages and operating systems*. **2014**: 127–144.
 - [43] Hongzi Mao, Malte Schwarzkopf, Shaileshh Bojja Venkatakrishnan *et al.* “Learning scheduling algorithms for data processing clusters”. In: *Proceedings of the ACM Special Interest Group on Data Communication*. **2019**: 270–288.
 - [44] Andrew Chung, Jun Woo Park and Gregory R. Ganger. “Stratus: cost-aware container scheduling in the public cloud”. In: *Proceedings of the ACM Symposium on Cloud Computing*. **2018**: 121–134.
 - [45] Alexander Smola and Shravan Narayananurthy. “An architecture for parallel topic models”. In: *Proceedings of the VLDB Endowment*. **2010**: 703–710.
 - [46] Mu Li, David G. Andersen, Jun Woo Park *et al.* “Scaling Distributed Machine Learning with the Parameter Server”. In: *11th USENIX Symposium on Operating Systems Design and Implementation (OSDI 14)*. Broomfield, CO: USENIX Association, 2014-10: 583–598. https://www.usenix.org/conference/osdi14/technical-sessions/presentation/li_mu.
 - [47] William Gropp, Ewing Lusk and Anthony Skjellum. *Using MPI: Portable Parallel Programming with the Message-Passing Interface*. **1994**.
 - [48] Alexander Sergeev and Mike Del Balso. “Horovod: fast and easy distributed deep learning in TensorFlow”. *arXiv preprint arXiv:1802.05799*, **2018**.
 - [49] Yimin Jiang, Yibo Zhu, Chang Lan *et al.* “A Unified Architecture for Accelerating Distributed DNN Training in Heterogeneous GPU/CPU Clusters”. In: *14th USENIX Symposium on Operating Systems Design and Implementation (OSDI 20)*. **2020**: 463–479.
 - [50] Zhihao Jia, Matei Zaharia and Alex Aiken. *Beyond Data and Model Parallelism for Deep Neural Networks*. **2018**.

- [51] Yanping Huang, Youlong Cheng, Ankur Bapna *et al.* “*GPipe: Efficient Training of Giant Neural Networks using Pipeline Parallelism*”. In: *Advances in Neural Information Processing Systems*. **2019**: 103–112.
- [52] Steffen Rendle. “*Factorization Machines*”. In: *2010 IEEE International Conference on Data Mining*. **2010**: 995–1000.
- [53] Anil K. Jain. “*Data clustering: 50 years beyond K-means*”. *international conference on pattern recognition*, **2010**, 31(8): 651–666.
- [54] J. B. Tenenbaum, V. de Silva and J. C. Langford. “*A Global Geometric Framework for Nonlinear Dimensionality Reduction*”. *Science*, **2000**, 290(5500): 2319–2323.
- [55] Valentin Flunkert, David Salinas and Jan Gasthaus. “*DeepAR: Probabilistic Forecasting with Autoregressive Recurrent Networks*”. *International Journal of Forecasting*, **2020**, 36(3): 1181–1191.
- [56] Tianqi Chen, Mu Li, Yutian Li *et al.* “*MXNet: A Flexible and Efficient Machine Learning Library for Heterogeneous Distributed Systems*”. *arXiv preprint arXiv:1512.01274*, **2015**.
- [57] R mi Bardenet, M ty s Brendel, Bal zs K gl *et al.* “*Collaborative hyperparameter tuning*”. In: *Proceedings of The 30th International Conference on Machine Learning*. **2013**: 199–207.
- [58] Martín Abadi, Paul Barham, Jianmin Chen *et al.* “*TensorFlow: a system for large-scale machine learning*”. In: *Proceedings of the 12th USENIX conference on Operating Systems Design and Implementation*. **2016**: 265–283.
- [59] Adam Paszke, Sam Gross, Francisco Massa *et al.* “*PyTorch: An Imperative Style, High-Performance Deep Learning Library*”. In: *Advances in Neural Information Processing Systems*. **2019**: 8026–8037.
- [60] Yanghua Peng, Yixin Bao, Yangrui Chen *et al.* “*Optimus: an efficient dynamic resource scheduler for deep learning clusters*”. In: *Proceedings of the Thirteenth EuroSys Conference on*. **2018**: 3.
- [61] Lang Feng, Prabhakar Kudva, Dilma Da Silva *et al.* “*Exploring Serverless Computing for Neural Network Training*”. In: *2018 IEEE 11th International Conference on Cloud Computing (CLOUD)*. **2018**: 334–341.
- [62] Joao Carreira, Pedro Fonseca, Alexey Tumanov *et al.* “*Cirrus: a Serverless Framework for End-to-end ML Workflows*”. In: *Proceedings of the ACM Symposium on Cloud Computing*. **2019**: 13–24.
- [63] Aaron Harlap, Andrew Chung, Alexey Tumanov *et al.* “*Tributary: spot-dancing for elastic services with latency SLOs*”. In: *2018 {USENIX} Annual Technical Conference ({USENIX} {ATC} 18)*. **2018**: 1–14.
- [64] Daniel Crankshaw, Xin Wang, Giulio Zhou *et al.* “*Clipper: a low-latency online prediction serving system*”. In: *NSDI’17 Proceedings of the 14th USENIX Conference on Networked Systems Design and Implementation*. **2017**: 613–627.
- [65] Vatche Ishakian, Vinod Muthusamy and Aleksander Slominski. “*Serving Deep Learning Models in a Serverless Platform*”. In: *2018 IEEE International Conference on Cloud Engineering (IC2E)*. **2018**: 257–262.

-
- [66] Zhucheng Tu, Mengping Li and Jimmy Lin. “Pay-Per-Request Deployment of Neural Network Models Using Serverless Architectures”. In: *Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: Demonstrations*. **2018**: 6–10.
 - [67] Francisco Romero, Qian Li, Neeraja J. Yadwadkar *et al.* “INFaaS: A Model-less Inference Serving System”. *arXiv preprint arXiv:1905.13348*, **2019**.
 - [68] Minchen Yu, Zhifeng Jiang, Hok Chun Ng *et al.* “Gillis: Serving Large Neural Networks in Serverless Functions with Automatic Model Partitioning”. In: *2021 IEEE 41th International Conference on Distributed Computing Systems (ICDCS)*. **2021**.
 - [69] Andrew Putnam, Adrian M. Caulfield, Eric S. Chung *et al.* “A reconfigurable fabric for accelerating large-scale datacenter services”. *Communications of The ACM*, **2016**, 59(11): 114–122.
 - [70] Stephen Cass. “Taking AI to the edge: Google’s TPU now comes in a maker-friendly package”. *IEEE Spectrum*, **2019**, 56(5): 16–17.
 - [71] Cheol-Ho Hong, Ivor Spence and Dimitrios S. Nikolopoulos. “GPU Virtualization and Scheduling Methods: A Comprehensive Survey”. *ACM Computing Surveys*, **2017**, 50(3): 35.
 - [72] Ian Buck, Tim Foley, Daniel Horn *et al.* “Brook for GPUs: stream computing on graphics hardware”. In: *ACM Transactions on Graphics (TOG)*. **2004**: 777–786.
 - [73] David Blythe. “The Direct3D 10 system”. In: *ACM Transactions on Graphics (TOG)*. **2006**: 724–734.
 - [74] John Nickolls, Ian Buck, Michael Garland *et al.* “Scalable Parallel Programming with CUDA”. In: *ACM SIGGRAPH 2008 classes on*. **2008**: 40–53.
 - [75] John E Stone, David Gohara and Guochun Shi. “OpenCL: A Parallel Programming Standard for Heterogeneous Computing Systems”. *computational science and engineering*, **2010**, 12(3): 66–73.
 - [76] A. Demers, S. Keshav and S. Shenker. “Analysis and simulation of a fair queueing algorithm”. *acm special interest group on data communication*, **1989**, 19(4): 1–12.
 - [77] Denis Foley and John Danskin. “Ultra-Performance Pascal GPU and NVLink Interconnect”. *IEEE Micro*, **2017**, 37(2): 7–17.
 - [78] Marcelo Amaral, Jordà Polo, David Carrera *et al.* “Topology-aware GPU scheduling for learning workloads in cloud environments”. In: *Proceedings of the International Conference for High Performance Computing, Networking, Storage and Analysis on*. **2017**: 17.
 - [79] Hanyu Zhao, Zhenhua Han, Zhi Yang *et al.* “HiveD: Sharing a GPU Cluster for Deep Learning with Guarantees”. In: *14th USENIX Symposium on Operating Systems Design and Implementation (OSDI 20)*. **2020**: 515–532.
 - [80] Robert P. Goldberg. “Survey of virtual machine research”. *IEEE Computer*, **1974**, 7(9): 34–45.
 - [81] Paul Barham, Boris Dragovic, Keir Fraser *et al.* “Xen and the art of virtualization”. In: *Proceedings of the nineteenth ACM symposium on Operating systems principles*. **2003**: 164–177.
 - [82] Daeyoun Kang, Tae Joon Jun, Dohyeun Kim *et al.* “ConVGPU: GPU Management Middleware in Container Based Virtualized Environment”. In: *2017 IEEE International Conference on Cluster Computing (CLUSTER)*. **2017**: 301–309.

- [83] Dirk Merkel. “*Docker: lightweight Linux containers for consistent development and deployment*”. *Linux Journal*, **2014**, 2014(239): 2.
- [84] Wencong Xiao, Romil Bhardwaj, Ramachandran Ramjee et al. “*Gandiva: introspective cluster scheduling for deep learning*”. In: *Proceedings of the 12th USENIX conference on Operating Systems Design and Implementation*. **2018**: 595–610.
- [85] Peifeng Yu and Mosharaf Chowdhury. “*Salus: Fine-Grained GPU Sharing Primitives for Deep Learning Applications*”. *Proceedings of Machine Learning and Systems*, **2020**, 2: 98–111.
- [86] Daniel Mendoza, Francisco Romero, Qian Li et al. “*Interference-Aware Scheduling for Inference Serving*”. In: *Proceedings of the 1st Workshop on Machine Learning and Systems*. Online, United Kingdom: Association for Computing Machinery, **2021**: 80–88. <https://doi.org/10.1145/3437984.3458837>.
- [87] Hovav Shacham and Brent Waters. “*Compact Proofs of Retrievability*”. *Journal of Cryptology*, **2013**, 26(3): 442–483.
- [88] James Seibel, Kevin Laflamme, Fred Koschara et al. *Trusted execution environment*. **2017**.
- [89] Craig Gentry. “*Fully homomorphic encryption using ideal lattices*”. In: *Proceedings of the forty-first annual ACM symposium on Theory of computing*. **2009**: 169–178.
- [90] Ahmed M. Azab, Peng Ning, Jitesh Shah et al. “*Hypervision Across Worlds: Real-time Kernel Protection from the ARM TrustZone Secure World*”. In: *Proceedings of the 2014 ACM SIGSAC Conference on Computer and Communications Security*. **2014**: 90–102.
- [91] Meysam Taassori, Ali Shafiee and Rajeev Balasubramonian. “*VAULT: Reducing Paging Overheads in SGX with Efficient Integrity Verification Structures*”. In: *Proceedings of the Twenty-Third International Conference on Architectural Support for Programming Languages and Operating Systems*. **2018**: 665–678.
- [92] D. R. Engler, M. F. Kaashoek and J. O’Toole. “*Exokernel: an operating system architecture for application-level resource management*”. In: *Proceedings of the fifteenth ACM symposium on Operating systems principles*. **1995**: 251–266.
- [93] Andrew Baumann, Marcus Peinado and Galen Hunt. “*Shielding Applications from an Untrusted Cloud with Haven*”. *ACM Transactions on Computer Systems*, **2015**, 33(3): 8.
- [94] Shweta Shinde, Dat Le Tien, Shruti Tople et al. “*Panoply: Low-TCB Linux Applications With SGX Enclaves*.” In: *Network and Distributed System Security Symposium*. **2017**.
- [95] Chia-Che Tsai, Donald E. Porter and Mona Vij. “*Graphene-SGX: a practical library OS for unmodified applications on SGX*”. In: *USENIX ATC ’17 Proceedings of the 2017 USENIX Conference on Usenix Annual Technical Conference*. **2017**: 645–658.
- [96] Youren Shen, Hongliang Tian, Yu Chen et al. “*Occlum: Secure and Efficient Multitasking Inside a Single Enclave of Intel SGX*”. In: *Proceedings of the Twenty-Fifth International Conference on Architectural Support for Programming Languages and Operating Systems*. **2020**: 955–970.
- [97] Sergei Arnautov, Bohdan Trach, Franz Gregor et al. “*SCONE: secure Linux containers with Intel SGX*”. In: *Proceedings of the 12th USENIX conference on Operating Systems Design and Implementation*. **2016**: 689–703.

-
- [98] Tyler Hunt, Zhiting Zhu, Yuanzhong Xu *et al.* “Ryoan: A Distributed Sandbox for Untrusted Computation on Secret Data”. *ACM Transactions on Computer Systems*, **2018**, 35(4): 13.
 - [99] Felix Schuster, Manuel Costa, Cedric Fournet *et al.* “VC3: Trustworthy Data Analytics in the Cloud Using SGX”. In: *2015 IEEE Symposium on Security and Privacy*. **2015**: 38–54.
 - [100] Vinod Kumar Vavilapalli, Arun C. Murthy, Chris Douglas *et al.* “Apache Hadoop YARN: yet another resource negotiator”. In: *Proceedings of the 4th annual Symposium on Cloud Computing*. **2013**: 5.
 - [101] David Bernstein. “Containers and Cloud: From LXC to Docker to Kubernetes”. *IEEE Cloud Computing*, **2014**, 1(3): 81–84.
 - [102] Sebastien Vaucher, Rafael Pires, Pascal Felber *et al.* “SGX-Aware Container Orchestration for Heterogeneous Clusters”. In: *2018 IEEE 38th International Conference on Distributed Computing Systems (ICDCS)*. **2018**: 730–741.
 - [103] Olga Ohrimenko, Felix Schuster, Cedric Fournet *et al.* “Oblivious Multi-Party Machine Learning on Trusted Processors”. In: *25th USENIX Security Symposium (USENIX Security 16)*. Austin, TX: USENIX Association, 2016-08: 619–636. <https://www.usenix.org/conference/usenixsecurity16/technical-sessions/presentation/ohrimenko>.
 - [104] Roland Kunkel, Do Le Quoc, Franz Gregor *et al.* “TensorSCONE: A Secure TensorFlow Framework using Intel SGX.” *arXiv preprint arXiv:1902.04413*, **2019**.
 - [105] Junming Ma, Chaofan Yu, Aihui Zhou *et al.* “S3ML: A Secure Serving System for Machine Learning Inference.” *arXiv preprint arXiv:2010.06212*, **2020**.
 - [106] Yan Li, Junming Ma and Donggang Cao. “Cross-Domain Workloads Performance Prediction via Runtime Metrics Transferring”. In: *2020 IEEE International Conference on Joint Cloud Computing*. **2020**.
 - [107] Baochen Sun, Jiashi Feng and Kate Saenko. “Correlation Alignment for Unsupervised Domain Adaptation”. *Domain Adaptation in Computer Vision Applications*, **2017**: 153–171.
 - [108] Fengcun Li and Bo Hu. “DeepJS: Job Scheduling Based on Deep Reinforcement Learning in Cloud Data Center”. In: *Proceedings of the 2019 4th International Conference on Big Data and Computing*. **2019**: 48–53.
 - [109] Azalia Mirhoseini, Hieu Pham, Quoc V. Le *et al.* “Device placement optimization with reinforcement learning”. In: *ICML’17 Proceedings of the 34th International Conference on Machine Learning - Volume 70*. **2017**: 2430–2439.
 - [110] Ryan Marcus, Parimarjan Negi, Hongzi Mao *et al.* “Neo: a learned query optimizer”. In: *Proceedings of the VLDB Endowment*. **2019**: 1705–1718.
 - [111] Tim Kraska, Mohammad Alizadeh, Alex Beutel *et al.* “SageDB: A Learned Database System”. In: **2019**.
 - [112] Lujing Cen, Ryan Marcus, Hongzi Mao *et al.* “Learned garbage collection”. In: *Proceedings of the 4th ACM SIGPLAN International Workshop on Machine Learning and Programming Languages*. **2020**: 38–44.

- [113] Prateek Sharma, David Irwin and Prashant Shenoy. “*Portfolio-driven Resource Management for Transient Cloud Servers*”. In: *Proceedings of the 2017 ACM SIGMETRICS / International Conference on Measurement and Modeling of Computer Systems*. **2017**: 59–59.
- [114] Yue Cheng, Zheng Chai and Ali Anwar. “*Characterizing Co-located Datacenter Workloads: An Alibaba Case Study*”. In: *Proceedings of the 9th Asia-Pacific Workshop on Systems*. **2018**.
- [115] Shijian Li, Robert J. Walls, Lijie Xu *et al.* “*Speeding up Deep Learning with Transient Servers*”. In: *2019 IEEE International Conference on Autonomic Computing (ICAC)*. **2019**: 125–135.
- [116] Supreeth Shastry and David Irwin. “*HotSpot: automated server hopping in cloud spot markets*”. In: *Proceedings of the 2017 Symposium on Cloud Computing*. **2017**: 493–505.
- [117] Ruben Mayer and Hans-Arno Jacobsen. “*Scalable Deep Learning on Distributed Infrastructures: Challenges, Techniques, and Tools*”. *ACM Computing Surveys*, **2020**, 53(1): 1–37.
- [118] Joseph M. Hellerstein, Jose M. Faleiro, Joseph E. Gonzalez *et al.* “*Serverless Computing: One Step Forward, Two Steps Back.*” In: *CIDR*. **2018**.
- [119] Ryan Chard, Zhuozhao Li, Kyle Chard *et al.* “*DLHub: Model and Data Serving for Science*”. In: *2019 IEEE International Parallel and Distributed Processing Symposium (IPDPS)*. **2019**: 283–292.
- [120] Ion Stoica, Dawn Song, Raluca Ada Popa *et al.* “*A Berkeley View of Systems Challenges for AI*”. *arXiv preprint arXiv:1712.05855*, **2017**.
- [121] Justin Gottschlich, Armando Solar-Lezama, Nesime Tatbul *et al.* “*The three pillars of machine programming*”. In: *Proceedings of the 2nd ACM SIGPLAN International Workshop on Machine Learning and Programming Languages*. **2018**: 69–80.
- [122] Matthew Halpern, Behzad Boroujerdian, Todd Mummert *et al.* “*One Size Does Not Fit All: Quantifying and Exposing the Accuracy-Latency Trade-Off in Machine Learning Cloud Service APIs via Tolerance Tiers*”. In: *2019 IEEE International Symposium on Performance Analysis of Systems and Software (ISPASS)*. **2019**: 34–47.
- [123] Saurabh Bagchi, Tarek F. Abdelzaher, Ramesh Govindan *et al.* “*New Frontiers in IoT: Networking, Systems, Reliability, and Security Challenges*”. *IEEE Internet of Things Journal*, **2020**, 7(12): 11330–11346.
- [124] Jashwant Raj Gunasekaran, Prashanth Thinakaran, Nachiappan Chidamabaram Nachiappan *et al.* “*Characterizing Bottlenecks in Scheduling Microservices on Serverless Platforms*”. In: *2020 IEEE 40th International Conference on Distributed Computing Systems (ICDCS)*. **2020**: 1197–1198.
- [125] Mehrdad Khani Shirkoohi, Pouya Hamadanian, Arash Nasr-Esfahany *et al.* “*Real-Time Video Inference on Edge Devices via Adaptive Model Streaming.*” *arXiv preprint arXiv:2006.06628*, **2020**.
- [126] Shijun Qin, Heng Wu, Yuewen Wu *et al.* “*Nuka: A Generic Engine with Millisecond Initialization for Serverless Computing*”. In: *2020 IEEE International Conference on Joint Cloud Computing*. **2020**.
- [127] Jianfeng Zhang, Wensheng Zhang, Lingjun Pu *et al.* “*QoS Optimization of DNN Serving Systems Based on Per-Request Latency Characteristics*”. In: *2020 16th International Conference on Mobility, Sensing and Networking (MSN)*. **2020**.

- [128] Jashwant Raj Gunasekaran, Prashanth Thinakaran, Nachiappan C. Nachiappan *et al.* “*Fifer: Tackling Resource Underutilization in the Serverless Era*”. In: *Proceedings of the 21st International Middleware Conference*. **2020**: 280–295.
- [129] Huaizheng Zhang, Yuanming Li, Qiming Ai *et al.* “*Hysia: Serving DNN-Based Video-to-Retail Applications in Cloud*”. In: *Proceedings of the 28th ACM International Conference on Multimedia*. **2020**: 4457–4460.
- [130] Arezoo Jahani, Marco Lattuada, Michele Ciavotta *et al.* “*Optimizing on-demand GPUs in the Cloud for Deep Learning Applications Training*”. In: *2019 4th International Conference on Computing, Communications and Security (ICCCS)*. **2019**: 1–8.
- [131] Jingoo Han, Luna Xu, M. Mustafa Rafique *et al.* “*A Quantitative Study of Deep Learning Training on Heterogeneous Supercomputers*”. In: *2019 IEEE International Conference on Cluster Computing (CLUSTER)*. **2019**: 1–12.
- [132] Qin Zhang, Li Zha, Xiaohua Wan *et al.* “*A GPU Inference System Scheduling Algorithm with Asynchronous Data Transfer*”. In: *2019 IEEE International Parallel and Distributed Processing Symposium Workshops (IPDPSW)*. **2019**: 438–445.
- [133] Wang Hui. *Device and method for freely switching GPU server topology*. **2018**.
- [134] Zhaoyun Chen, Wei Quan, Mei Wen *et al.* “*Deep Learning Research and Development Platform: Characterizing and Scheduling with QoS Guarantees on GPU Clusters*”. *IEEE Transactions on Parallel and Distributed Systems*, **2020**, 31(1): 34–50.
- [135] Federica Filippini, Marco Lattuada, Arezoo Jahani *et al.* “*Hierarchical Scheduling in on-demand GPU-as-a-Service Systems*”. In: *2020 22nd International Symposium on Symbolic and Numeric Algorithms for Scientific Computing (SYNASC)*. **2020**: 125–132.
- [136] Xin Geng, Haitao Zhang, Zhengyang Zhao *et al.* “*Interference-aware parallelization for deep learning workload in GPU cluster*”. *Cluster Computing*, **2020**, 23(4): 2689–2702.
- [137] Gingfung Yeung, Damian Borowiec, Renyu Yang *et al.* “*Horus: An Interference-aware Resource Manager for Deep Learning Systems*”. In: *International Conference on Algorithms and Architectures for Parallel Processing*. **2020**: 492–508.
- [138] Richard Liaw, Romil Bhardwaj, Lisa Dunlap *et al.* “*HyperSched: Dynamic Resource Reallocation for Model Development on a Deadline*”. In: *Proceedings of the ACM Symposium on Cloud Computing*. **2019**: 61–73.
- [139] Deepak Narayanan, Keshav Santhanam, Fiodar Kazhamiaka *et al.* “*Heterogeneity-Aware Cluster Scheduling Policies for Deep Learning Workloads*”. In: *14th USENIX Symposium on Operating Systems Design and Implementation (OSDI 20)*. **2020**: 481–498.
- [140] Guanhua Wang, Shivaram Venkataraman, Amar Phanishayee *et al.* “*Blink: Fast and Generic Collectives for Distributed ML*”. *Conference on Machine Learning and Systems (MLSys)*, **2020**, 2: 172–186.
- [141] Myeongjae Jeon, Shivaram Venkataraman, Amar Phanishayee *et al.* “*Analysis of Large-Scale Multi-Tenant GPU Clusters for DNN Training Workloads*”. In: *2019 USENIX Annual Technical Conference (USENIX ATC 19)*. **2019**: 947–960.

- [142] Haichen Shen, Lequn Chen, Yuchen Jin *et al.* “*Nexus: a GPU cluster engine for accelerating DNN-based video analysis*”. In: *Proceedings of the 27th ACM Symposium on Operating Systems Principles*. **2019**: 322–337.
- [143] Yiwen Han, Shihao Shen, Xiaofei Wang *et al.* “*Tailored Learning-Based Scheduling for Kubernetes-Oriented Edge-Cloud System*”. In: *INFOCOM 2021 : International Conference on Computer Communications*. **2021**.
- [144] Liam Li, Kevin G. Jamieson, Afshin Rostamizadeh *et al.* “*Massively Parallel Hyperparameter Tuning*”. **2018**.
- [145] Kshiteej Mahajan, Arjun Balasubramanian, Arjun Singhvi *et al.* “*Themis: Fair and Efficient GPU Cluster Scheduling*”. In: *17th USENIX Symposium on Networked Systems Design and Implementation (NSDI 20)*. **2020**: 289–304.
- [146] K. R. Jayaram, Vinod Muthusamy, Parijat Dube *et al.* “*FfDL: A Flexible Multi-tenant Deep Learning Platform*”. In: *Proceedings of the 20th International Middleware Conference on*. **2019**: 82–95.
- [147] Fritz Alder, N. Asokan, Arseny Kurnikov *et al.* “*S-FaaS: Trustworthy and Accountable Function-as-a-Service using Intel SGX*”. In: *Proceedings of the 2019 ACM SIGSAC Conference on Cloud Computing Security Workshop*. **2019**: 185–199.
- [148] Jing Gu, Shengbo Song, Ying Li *et al.* “*GaiaGPU: Sharing GPUs in Container Clouds*”. In: *2018 IEEE Intl Conf on Parallel & Distributed Processing with Applications, Ubiquitous Computing & Communications, Big Data & Cloud Computing, Social Computing & Networking, Sustainable Computing & Communications (ISPA/IUCC/BDCloud/SocialCom/SustainCom)*. **2018**: 469–476.
- [149] Andrey Brito, Christof Fetzer, Stefan Köpsell *et al.* “*Secure end-to-end processing of smart metering data*”. *Journal of Cloud Computing*, **2019**, 8(1): 1–13.
- [150] Robert Krahn, Donald Dragoti, Franz Gregor *et al.* “*TEEMon: A continuous performance monitoring framework for TEEs*”. In: *Proceedings of the 21st International Middleware Conference*. **2020**: 178–192.
- [151] Stefan Contiu, Sébastien Vaucher, Rafael Pires *et al.* “*Anonymous and Confidential File Sharing over Untrusted Clouds*”. In: *2019 38th Symposium on Reliable Distributed Systems (SRDS)*. **2019**: 21–31.
- [152] Ana Klimovic, Yawen Wang, Patrick Stuedi *et al.* “*Pocket: elastic ephemeral storage for serverless analytics*”. In: *Proceedings of the 12th USENIX conference on Operating Systems Design and Implementation*. **2018**: 427–444.
- [153] Haoyu Zhang, Logan Stafman, Andrew Or *et al.* “*SLAQ: quality-driven scheduling for distributed machine learning*”. In: *Proceedings of the 2017 Symposium on Cloud Computing*. **2017**: 390–404.
- [154] Chin-Jung Hsu, Vivek Nair, Vincent W. Freeh *et al.* “*Arrow: Low-Level Augmented Bayesian Optimization for Finding the Best Cloud VM*”. In: *2018 IEEE 38th International Conference on Distributed Computing Systems (ICDCS)*. **2018**: 660–670.
- [155] Ben Zhang, Xin Jin, Sylvia Ratnasamy *et al.* “*AWStream: adaptive wide-area streaming analytics*”. In: *Proceedings of the 2018 Conference of the ACM Special Interest Group on Data Communication*. **2018**: 236–252.

-
- [156] Vijay Prakash Dwivedi, Chaitanya K. Joshi, Thomas Laurent *et al.* “Benchmarking Graph Neural Networks”. *arXiv preprint arXiv:2003.00982*, **2020**.
 - [157] Emmanuel Amaro, Christopher Branner-Augmon, Zhihong Luo *et al.* “Can far memory improve job throughput”. In: *Proceedings of the Fifteenth European Conference on Computer Systems*. **2020**.
 - [158] Zili Meng, Minhu Wang, Jiasong Bai *et al.* “Interpreting Deep Learning-Based Networking Systems”. In: *Proceedings of the Annual conference of the ACM Special Interest Group on Data Communication on the applications, technologies, architectures, and protocols for computer communication*. **2020**: 154–171.
 - [159] Matei Zaharia, Mosharaf Chowdhury, Tathagata Das *et al.* “Resilient distributed datasets: a fault-tolerant abstraction for in-memory cluster computing”. In: *NSDI’12 Proceedings of the 9th USENIX conference on Networked Systems Design and Implementation*. **2012**: 2–2.
 - [160] Shivaram Venkataraman, Zongheng Yang, Davies Liu *et al.* “SparkR: Scaling R Programs with Spark”. In: *Proceedings of the 2016 International Conference on Management of Data*. **2016**: 1099–1104.
 - [161] Joseph E. Gonzalez, Reynold S. Xin, Ankur Dave *et al.* “GraphX: graph processing in a distributed dataflow framework”. In: *Proceedings of the 11th USENIX conference on Operating Systems Design and Implementation*. **2014**: 599–613.
 - [162] Benjamin Hindman, Andy Konwinski, Matei Zaharia *et al.* “Mesos: a platform for fine-grained resource sharing in the data center”. In: *Proceedings of the 8th USENIX conference on Networked systems design and implementation*. **2011**: 295–308.
 - [163] Kay Ousterhout, Patrick Wendell, Matei Zaharia *et al.* “Sparrow: distributed, low latency scheduling”. In: *Proceedings of the Twenty-Fourth ACM Symposium on Operating Systems Principles*. **2013**: 69–84.
 - [164] Christina Delimitrou and Christos Kozyrakis. “Paragon: QoS-aware scheduling for heterogeneous datacenters”. In: *Proceedings of the eighteenth international conference on Architectural support for programming languages and operating systems*. **2013**: 77–88.
 - [165] Christina Delimitrou, Daniel Sanchez and Christos Kozyrakis. “Tarcil: reconciling scheduling speed and quality in large shared clusters”. In: *Proceedings of the Sixth ACM Symposium on Cloud Computing*. **2015**: 97–110.
 - [166] David Lo, Liqun Cheng, Rama Govindaraju *et al.* “Heracles: improving resource efficiency at scale”. In: *2015 ACM/IEEE 42nd Annual International Symposium on Computer Architecture (ISCA)*. **2015**: 450–462.
 - [167] Christina Delimitrou and Christos Kozyrakis. “HCloud: Resource-Efficient Provisioning in Shared Cloud Systems”. In: *Proceedings of the Twenty-First International Conference on Architectural Support for Programming Languages and Operating Systems*. **2016**: 473–488.
 - [168] Deepak Narayanan, Aaron Harlap, Amar Phanishayee *et al.* “PipeDream: generalized pipeline parallelism for DNN training”. In: *Proceedings of the 27th ACM Symposium on Operating Systems Principles*. **2019**: 1–15.

- [169] Jack Kosaian, K. V. Rashmi and Shivaram Venkataraman. “*Parity models: erasure-coded resilience for prediction serving systems*”. In: *Proceedings of the 27th ACM Symposium on Operating Systems Principles*. **2019**: 30–46.
- [170] Wencong Xiao, Jilong Xue, Youshan Miao *et al.* “*TUX 2 : distributed graph computation for machine learning*”. In: *NSDI’17 Proceedings of the 14th USENIX Conference on Networked Systems Design and Implementation*. **2017**: 669–682.
- [171] Lingxiao Ma, Zhiqiang Xie, Zhi Yang *et al.* “*Rammer: Enabling Holistic Deep Learning Compiler Optimizations with rTasks*”. In: *14th USENIX Symposium on Operating Systems Design and Implementation (OSDI 20)*. **2020**: 881–897.
- [172] Manni Wang, Shaohua Ding, Ting Cao *et al.* “*AsyMo: scalable and efficient deep-learning inference on asymmetric mobile CPUs*”. In: *Proceedings of the 27th Annual International Conference on Mobile Computing and Networking*. **2021**.
- [173] Yanjie Gao, Xianyu Gu, Hongyu Zhang *et al.* “*Runtime Performance Prediction for Deep Learning Models with Graph Neural Network*”. **2021**.